

**Разработка программного средства прогнозирования продаж на основе
исторических данных**

АННОТАЦИЯ

Выпускная квалификационная работа посвящена разработке программного средства прогнозирования продаж на основе исторических данных с применением методов машинного обучения.

В работе рассмотрены процессы прогнозирования продаж на предприятии, выполнен анализ временного ряда на основе данных интернет-ритейла Retailrocket, проведена подготовка и преобразование данных, включая агрегацию, масштабирование и формирование лаговых признаков. Разработаны и сравнены модели прогнозирования: ARIMA, LSTM, Random Forest и XGBoost. Оценка качества моделей выполнена с использованием метрик RMSE, MAE и MAPE, на основе которых установлено, что модель LSTM демонстрирует наилучшие результаты по точности прогнозирования.

Также разработан интерактивный веб-интерфейс на базе Streamlit, обеспечивающий загрузку данных, выбор модели и визуализацию результатов. Проведено тестирование программного средства и предложен план внедрения в информационную систему предприятия. Полученные результаты подтверждают эффективность применения методов машинного обучения для повышения точности прогнозирования продаж и оптимизации управленческих решений.

Содержание

ВВЕДЕНИЕ	4
1 РЕАЛИЗАЦИЯ ПРОЦЕССА ПРОГНОЗИРОВАНИЯ ПРОДАЖ НА ПРЕДПРИЯТИИ.....	6
1.1 Общая характеристика предприятия.....	6
1.2 Обзор аналогов и описание процесса прогнозирования продаж на предприятии	9
1.3 Применение методов машинного обучения для прогнозирования продаж	12
2 РАЗРАБОТКА И СРАВНИТЕЛЬНЫЙ АНАЛИЗ МОДЕЛЕЙ ДЛЯ АВТОМАТИЗАЦИИ ПРОЦЕССА ПРОГНОЗИРОВАНИЯ ПРОДАЖ НА ОСНОВЕ ИСТОРИЧЕСКИХ ДАННЫХ	32
2.1 Сбор и подготовка исходных данных	32
2.2 Обучение и оценка качества моделей прогнозирования	35
2.3 Сравнительный анализ результатов прогнозирования моделей	39
3 РАЗРАБОТКА ПРОГРАММНОГО ИНТЕРФЕЙСА И ТЕСТИРОВАНИЕ МОДЕЛЕЙ ПРОГНОЗИРОВАНИЯ	51
3.1 Разработка интерфейса и тестирование моделей прогнозирования	51
3.2 Внедрение моделей прогнозирования в информационную систему предприятия	54
ЗАКЛЮЧЕНИЕ	60
СПИСОК ЛИТЕРАТУРЫ.....	62
ПРИЛОЖЕНИЕ	

ВВЕДЕНИЕ

Современные организации сталкиваются с необходимостью постоянной оптимизации своих аналитических процессов для эффективного взаимодействия с рынком и достижения конкурентных преимуществ. В условиях быстро меняющейся технологической среды и разнообразных потребительских предпочтений организациям становится сложнее эффективно планировать, анализировать и реализовывать свои управленческие стратегии. Искусственный интеллект в этом контексте представляет собой перспективную технологию, способную оптимизировать аналитические процессы и повысить эффективность деятельности.

Актуальность разработки модели прогнозирования продаж предприятия при помощи методов машинного обучения обусловлена рядом факторов:

- прогнозирование возможных итоговых показателей деятельности, в частности объемов продаж, позволяет выявить и предотвратить возможные отрицательные результаты;
- необходимость оценки перспектив компании в условиях развития национальной и мировой экономики, ужесточения конкурентной борьбы, ограниченности доступа к ресурсам и капиталу на мировых рынках;
- возможность разрабатывать обоснованную финансовую стратегию и устанавливать приемлемые границы реализации финансовых планов компании;
- получение ожидаемых параметров финансово-хозяйственной деятельности для разработки финансовых планов предприятия на среднесрочную и краткосрочную перспективу.

Методы машинного обучения позволяют учитывать большее количество факторов и взаимосвязей, чем традиционные методы, что обеспечивает более точные и надежные прогнозы. Также они позволяют автоматизировать многие рутинные задачи обработки данных, что повышает эффективность работы бизнес-аналитиков и предоставляет им возможность проводить более

глубокий анализ. Таким образом, актуальность разработки модели прогнозирования продаж предприятия связана с необходимостью принятия взвешенных управленческих решений и оптимизации деятельности компании в целом.

Цель выпускной квалификационной работы – разработка программного средства прогнозирования продаж на основе исторических данных. Для достижения поставленной цели необходимо решить следующие задачи:

- раскрыть особенности реализации процесса прогнозирования продаж на предприятии;
- разработать модель для автоматизации процесса прогнозирования продаж на основе исторических данных;
- внедрить модель прогнозирования в деятельность предприятия и оценить экономический эффект.

Объект исследования – процесс прогнозирования продаж предприятия. Предмет исследования – методы, алгоритмы, и программное средство прогнозирования продаж на основе исторических данных. Методы исследования – моделирование процессов, анализ и синтез, индукция.

Теоретическая значимость работы обусловлена тем, что предложенная модель прогнозирования продаж может быть использована в дальнейшем компаниями для разработки и обоснования финансовой стратегии развития.

Выпускная квалификационная работа состоит из введения, трех глав, заключения, списка литературы и приложения. В первой главе представлена общая характеристика предприятия, проведен обзор аналогов и описание процесса прогнозирования продаж на предприятии, рассмотрено применение методов машинного обучения для прогнозирования продаж. Во второй главе собраны все данные и выбрана архитектура модели, выполнено обучение и оценка качества моделей, проанализированы результаты работы моделей. В третьей главе произведено внедрение модели прогнозирования в информационную систему предприятия, а также оценен экономический эффект от внедрения модели прогнозирования продаж.

1 РЕАЛИЗАЦИЯ ПРОЦЕССА ПРОГНОЗИРОВАНИЯ ПРОДАЖ НА ПРЕДПРИЯТИИ

1.1 Общая характеристика предприятия

Для целей выпускной квалификационной работы рассматривается виртуальное предприятие - крупная розничная сеть, специализирующаяся на продаже непродовольственных товаров, таких как одежда, обувь, товары для дома, хозяйственные товары и сезонные предметы. Выбор именно этой категории товаров обусловлен необходимостью исключения дополнительных факторов, характерных для продуктовой розницы, таких как срок годности продукции, особенности хранения и утилизация, которые могут существенно влиять на динамику продаж и усложнять построение моделей прогнозирования. Фокус на непродовольственных товарах позволяет провести исследование на основе чистых временных рядов и сосредоточиться на выявлении закономерностей в поведении покупателей, сезонных колебаний спроса и эффективности методов машинного обучения для прогнозирования.

Для моделирования работы предприятия используется открытый датасет Retailrocket eCommerce Dataset, содержащий исторические данные о событиях пользователей интернет-магазина, специализирующегося на продаже одежды, обуви и аксессуаров, за период с 2014 по 2015 годы. Основной файл events.csv включает информацию о времени события, типе события (view, addtocart, transaction), идентификаторе товара, категории товара и идентификаторе пользователя. Для целей прогнозирования используются только события типа transaction, которые агрегируются по дате и товару, формируя ежедневное количество проданных единиц (штук). Дополнительно доступны файлы item_properties.csv с информацией о свойствах товаров, включая категорию, бренд и другие характеристики, что позволяет учитывать ассортимент при анализе и построении моделей прогнозирования. Такой набор данных обеспечивает возможность

формирования временных рядов ежедневных продаж по каждому товару, что особенно важно для анализа динамики спроса, выявления сезонных закономерностей и построения моделей прогнозирования с использованием методов машинного обучения.

Структура предприятия в модели виртуальной сети магазинов отражает реальную организацию крупной розничной компании: каждый магазин функционирует как отдельный объект с индивидуальными характеристиками, включая численность покупателей, ассортимент товаров и особенности спроса. В данном датасете информация о конкретных магазинах отсутствует, однако идентификаторы товаров и их категорий позволяют смоделировать работу различных торговых точек, сегментировать продажи по категориям и создавать репрезентативные временные ряды для анализа. Это создаёт возможность моделирования различных сценариев развития спроса и позволяет проверять устойчивость моделей прогнозирования к разнообразию условий ведения торговой деятельности.

Ассортимент предприятия охватывает широкий спектр непродовольственных товаров, которые делятся на основные категории и подкатегории. Основные категории включают: одежду, обувь, аксессуары, товары для дома и сезонные товары. Подкатегории позволяют выявлять более детальные закономерности спроса и анализировать динамику продаж внутри каждого сегмента. Временные ряды по каждому товару формируют основу для построения моделей прогнозирования. Ежедневные данные о продажах обеспечивают возможность анализа краткосрочных и долгосрочных колебаний спроса, выявления сезонных закономерностей и трендов.

Предварительный анализ данных показывает, что объемы продаж существенно различаются как по категориям товаров, так и по отдельным товарам в рамках каждой категории. Наибольший спрос наблюдается на наиболее востребованные товары, такие как базовая одежда и обувь, в то время как сезонные товары демонстрируют выраженные колебания спроса в определенные периоды года. Среднее количество проданных единиц за день

варьируется в зависимости от категории товара, что отражает разнообразие клиентской базы и характер сезонного спроса. Одежда и обувь демонстрируют повышенный спрос перед сезонными распродажами, праздниками и сменой сезонов, а товары для дома могут показывать пики продаж в преддверии школьного сезона или периодов переезда. Эти наблюдения подтверждают необходимость использования методов машинного обучения для точного прогнозирования продаж и планирования закупок, поскольку традиционные статистические модели могут быть недостаточно гибкими при наличии высокой волатильности и разнородности данных. Включение сезонных факторов и характеристик товаров в модели прогнозирования обеспечивает повышение точности предсказаний и позволяет снизить вероятность недостатка или избыточного запаса товаров.

Использование макроэкономических факторов в данной работе не является ключевым, так как основной анализ сосредоточен на внутренних характеристиках товаров и их продаж. Однако при необходимости данные о свойствах товаров, категориях, брендах и пользовательских активностях могут быть интегрированы в модели как дополнительные признаки, повышая точность прогнозирования и качество рекомендаций.

Таким образом, виртуальное предприятие, представленное на основе данных Retailrocket, позволяет создать репрезентативную модель работы крупной розничной сети непродовольственных товаров. Данные обеспечивают возможность анализа динамики спроса по товарам и категориям, выявления сезонных колебаний, трендов и аномалий, а также создания прогнозных моделей, учитывающих исторические зависимости и мультифакторные влияния.

Использование данного датасета обеспечивает:

- высокую методическую корректность: данные полные, репрезентативные, с достаточным горизонтом наблюдений для статистического анализа;
- возможность построения временных рядов: агрегированные

ежедневные продажи позволяют выявлять краткосрочные и долгосрочные закономерности;

- разнообразие признаков: данные по товарам, категориям, брендам и свойствам;
- возможность сравнения методов: традиционные статистические модели (ARIMA) и методы машинного обучения;
- полноту анализа: можно выявлять закономерности на уровне отдельных товаров, категорий и сегментов пользователей.

В совокупности данные обеспечивают полноценное моделирование процесса прогнозирования продаж, демонстрируя преимущества применения современных методов машинного обучения перед классическими статистическими подходами.

1.2 Обзор аналогов и описание процесса прогнозирования продаж на предприятии

Процесс прогнозирования продаж является важной частью управленческой деятельности в ритейле и позволяет предприятиям планировать закупки, управлять запасами и оптимизировать доходы. Для виртуального предприятия на основе данных датасета прогнозирование продаж строится на аналогичных принципах, которые применяются в реальных сетях и в научных исследованиях.

В основе таких процессов лежит последовательность действий, направленных на использование исторических данных для предсказания будущих продаж. Сначала осуществляется сбор информации о продажах, транзакциях и маркетинговых активностях. В реальных компаниях информация включает данные о ежедневных продажах по каждому магазину и товару, сведения о проведенных акциях, сезонные факторы и другие показатели, влияющие на спрос. Аналогично, в нашем виртуальном предприятии все эти аспекты моделируются через данные из датасета.

После сбора данных проводится их обработка и очистка. Этап включает выявление пропусков в данных, аномальных значений и несоответствий, а также подготовку данных к анализу. В ритейле процесс необходим для того, чтобы прогнозы были точными и надежными, а решения на их основе - эффективными. Например, пропуски в данных о продажах определенного товара в конкретный день могут быть скорректированы с помощью интерполяции или средних значений, чтобы не исказить общий прогноз.

Следующим шагом является анализ исторических данных для выявления закономерностей. В практических случаях это означает исследование сезонных колебаний, влияний промо-акций, праздников, а также других факторов, которые могут изменить покупательское поведение. Виртуальное предприятие, представленное датасетом, также демонстрирует такие закономерности: продажи определённых категорий товаров повышаются в преддверии праздников, в выходные наблюдаются более высокие объёмы транзакций, а участие товара в промо-акции вызывает заметный рост продаж. Анализ этих факторов позволяет понять, какие переменные следует учитывать при построении прогнозов, и как они влияют на будущие показатели выручки.

На основании собранных и обработанных данных формируется модель прогнозирования. На реальных предприятиях это может быть, как простая статистическая модель, основанная на средних значениях и сезонных коэффициентах, так и более сложные алгоритмы машинного обучения. Процесс прогнозирования всегда включает использование исторической информации для предсказания будущих событий, независимо от конкретного метода, который будет применяться. Виртуальное предприятие моделирует этот процесс: сначала формируется агрегированный ряд данных по ежедневным продажам, затем выявляются ключевые факторы, влияющие на колебания спроса, и подготавливается информация для построения модели.

Для наглядного понимания существующих подходов и методов прогнозирования продаж в таблице 1 представлен обзор аналогов

статистических методов.

Таблица 1 – Обзор статистических подходов и методов прогнозирования продаж

Метод	Тип метода	Краткое описание	Цель применения
Скользящие средние	Статистический	Применяются для сглаживания временного ряда продаж и краткосрочного прогнозирования	Планирование закупок, учет сезонных колебаний
Экспоненциальное сглаживание	Статистический	Взвешивание прошлых значений с уменьшением веса для более старых данных	Предсказание краткосрочных продаж с учётом тенденций
ARIMA / SARIMA	Статистический	Модели временных рядов с учётом автокорреляции и сезонности	Прогнозирование ежедневных или недельных продаж товаров

Предприятия, которые систематически используют исторические данные для прогнозирования, получают значительное преимущество. В научной литературе описаны кейсы применения статистических методов, таких как скользящие средние и ARIMA, для краткосрочного планирования закупок и оптимизации складских запасов. В коммерческих сетях подобные методы помогают прогнозировать продажи продуктов повседневного спроса, снижать количество списаний и избыточных запасов, а также планировать промо-акции.

Таким образом, обзор аналогов позволяет выделить общие этапы процесса прогнозирования: сбор и очистка данных, выявление закономерностей в продажах, построение прогнозов и использование полученных результатов для управленческих решений. Виртуальное предприятие, представленное датасетом, полностью воспроизводит эти этапы, что делает его подходящим объектом исследования для демонстрации возможностей автоматизации процесса прогнозирования выручки на основе исторических данных.

Помимо классических статистических методов, современные подходы машинного обучения обладают потенциалом более точного прогнозирования на больших и разнородных наборах данных. Данные методы будут подробно рассмотрены в следующем параграфе.

1.3 Применение методов машинного обучения для прогнозирования продаж

Процесс прогнозирования продаж начинается с исследования исторических данных. Для виртуального предприятия, представленном данными онлайн-ритейла Retailrocket, основным показателем выступает количество покупок товаров (transaction) по дням.

Сначала агрегируем события покупок (event = 'transaction') по дням и товарам, чтобы получить временные ряды. Код представлен далее.

```
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.stattools import adfuller
events = pd.read_csv('events.csv')
purchases = events[events['event'] == 'transaction'].copy()
if purchases.empty:
    raise ValueError("В датасете нет ни одной покупки!")
purchases['date'] = pd.to_datetime(purchases['timestamp'], unit='ms', origin='unix')
print("Min date:", purchases['date'].min())
print("Max date:", purchases['date'].max())
daily_sales = purchases.groupby(purchases['date'].dt.date).size()
full_range = pd.date_range(start=daily_sales.index.min(), end=daily_sales.index.max())
daily_sales = daily_sales.reindex(full_range, fill_value=0)
daily_sales.index = pd.to_datetime(daily_sales.index)
plt.figure(figsize=(12,6))
daily_sales.plot()
plt.title("Динамика ежедневных продаж ")
plt.xlabel("Дата")
```

```
plt.ylabel("Количество покупок")
plt.grid(True)
plt.show()
```



Рисунок 1 – Временной ряд ежедневных продаж

Основные статистические характеристики временного ряда:

- среднее значение продаж - 161,6 единиц в день;
- медианное значение - 162 единицы, что указывает на симметричность распределения;
- минимальное значение - 15 продаж в день;
- максимальное значение - 276 продаж в день;
- стандартное отклонение - 58,2, что свидетельствует о заметной волатильности спроса.

Таким образом, объём продаж характеризуется существенными колебаниями, что типично для онлайн-ритейла и подтверждает необходимость применения методов прогнозирования, способных учитывать изменчивость временных рядов.

Для оценки стационарности временного ряда был применён расширенный тест Дики–Фуллера (ADF).

Код представлен далее.

```
result = adfuller(daily_sales)
```

```
print("ADF Statistic:", result[0])
print("p-value:", result[1])
print("Critical Values:", result[4])
```

Получены следующие результаты:

- ADF-статистика: $-2,82$;
- p-value: $0,056$
- критическое значение на уровне значимости 5%: $-2,88$

Так как значение p-value превышает $0,05$, нулевая гипотеза о наличии единичного корня не отвергается на уровне значимости 5%. Это означает, что временной ряд не является строго стационарным, хотя находится близко к границе стационарности.

Следовательно, при построении прогнозных моделей необходимо либо применять преобразования временного ряда (например, дифференцирование), либо использовать методы машинного обучения, устойчивые к нестационарности (деревья решений, градиентный бустинг, рекуррентные и трансформерные нейронные сети).

Анализ автокорреляции и частичной автокорреляции

Код представлен далее.

```
lags = 30
acf_values = acf(daily_sales, nlags=lags)
plt.figure(figsize=(12,4))
plt.bar(range(lags+1), acf_values)
plt.title("ACF - автокорреляция")
plt.xlabel("Лar")
plt.ylabel("ACF")
plt.grid(True)
plt.show()
pacf_values = pacf(daily_sales, nlags=lags)
plt.figure(figsize=(12,4))
plt.bar(range(lags+1), pacf_values)
plt.title("PACF - частичная автокорреляция")
```

```
plt.xlabel("Лar")
plt.ylabel("PACF")
plt.grid(True)
plt.show()
```




Рисунок 2 – График автокорреляции (ACF) временного ряда

Анализ автокорреляционной функции выявил следующие закономерности:

- высокая положительная автокорреляция на лаге 1 (0,496), что говорит о сильной зависимости текущих продаж от предыдущего дня;
- выраженные пики автокорреляции на лагах 7, 14, 21 и 28 (значения от 0,59 до 0,67);
- чередование положительных и отрицательных значений между этими лагами.

Наличие устойчивых пиков через каждые 7 дней указывает на ярко выраженную недельную сезонность, характерную для онлайн-ритейла, где поведение покупателей существенно различается по дням недели.



Рисунок 3 – График частичной автокорреляции (PACF) временного ряда

Анализ частичной автокорреляционной функции показал умеренную прямую зависимость на лаге 1, выраженные пики на лагах 7, 14, 21 и 28 (значения до 0,31). Это подтверждает, что основной вклад в динамику продаж вносят недельные лаги, хотя и с уменьшением прямого влияния, а не краткосрочные случайные колебания. Данный результат обосновывает использование лагов, кратных 7, при формировании признаков для моделей прогнозирования.

Код для оценки разнородности данных по товарам и категориям представлен далее.

```
plt.figure(figsize=(12,6))
plt.hist(item_sales[item_sales <= 15], bins=15)
plt.title('Распределение объема продаж по товарам')
plt.xlabel('Количество продаж')
plt.ylabel('Число товаров')
plt.grid(True)
plt.show()
```





Рисунок 4 – Гистограмма распределения объема продаж по товарам

Распределение количества продаж по товарам демонстрирует высокую степень разнородности:

- общее число товаров - 12 025;
- медианное количество продаж на товар - 1;
- 75% товаров имеют не более 2 продаж за весь период.

Таким образом, ассортимент характеризуется длинным хвостом: небольшое число товаров формирует основную долю продаж, в то время как большинство товаров продаётся редко. Это типичная особенность онлайн-ритейла и важный фактор при выборе методов прогнозирования.

Проведённый анализ временных рядов продаж показал, что данные онлайн-ритейла Retailrocket обладают следующими характеристиками: умеренная нестационарность, выраженная недельная сезонность, высокая волатильность, значительная разнородность спроса по товарам.

Полученные результаты подтверждают целесообразность использования моделей машинного обучения, способных учитывать лаговые зависимости, сезонность и неоднородность данных.

Машинное обучение (machine learning, ML) представляет собой совокупность методов искусственного интеллекта, которые позволяют

формировать самообучающиеся компьютерные системы (например, нейронные сети).

Создатели этих технологий не разрабатывают алгоритмы для решения определенных задач; вместо этого они готовят набор данных и определяют критерии успешного решения. Затем нейронные сети обучаются в соответствии с установленными критериями.

В отличие от обычного программирования, когда разработчик создает алгоритм для решения конкретной задачи и затем трансформирует его в программный код, в случае машинного обучения специалист обучает машину анализировать информацию также, как человек, и находить решение самостоятельно.

Задача регрессии заключается в формировании прогноза на основе аппроксимации. В процессе решения регрессионных задач машинное обучение обрабатывает массивные объемы данных и строит прогнозы на основе проведенного анализа. К примеру, с помощью такого анализа можно предсказать динамику стоимости акций конкретной компании как на текущий год, так и на будущие периоды, основываясь на динамике за многолетний временной интервал. Задача регрессии в машинном обучении также применяется для планирования продаж и прогнозирования изменений в ключевых финансовых показателях компании.

Основные компоненты, необходимые для реализации алгоритма машинного обучения, это наборы данных, функции и алгоритм (рисунок 5).

Компоненты машинного обучения

Наборы данных -

специализированные коллекции, используемые в системах машинного обучения. Эти группы могут включать разнообразные виды объектов - от числовых значений и изображений до текстовых данных. Качественно структурированный набор данных играет ключевую роль в эффективности обучения модели, так как именно от него зависят результаты последующего анализа.

Функции -

выполняют критически важную задачу, указывая алгоритму машинного обучения, на какие аспекты следует обратить внимание. Например, при решении задачи прогнозирования стоимости недвижимости целесообразно предварительно исследовать корреляцию между ценой объекта и его местоположением. Такой подход позволяет оптимизировать модель.

Алгоритм -

набор команд, которые принимают исходные данные, обрабатывают их и выдают результаты. Каждая конкретная задача может быть решена с помощью различных алгоритмов, что позволяет выбирать наиболее подходящий метод для достижения желаемого результата. Эта вариативность в подходах открывает широкие возможности для дальнейших исследований в области машинного обучения.

Рисунок 5 - Компоненты машинного обучения

Далее в параграфе будут рассмотрены некоторые алгоритмы построения регрессионных моделей

Линейная регрессия

Линейная регрессия является одной из самых простых и широко используемых моделей регрессии. Она строит прогноз как линейную комбинацию входных признаков, где каждому признаку сопоставляется коэффициент, определяющий его влияние на целевую переменную. Алгоритм подбирает эти коэффициенты таким образом, чтобы минимизировать среднеквадратичную ошибку между прогнозом и историческими данными. В прогнозировании временных рядов в качестве признаков обычно используют

лаговые значения, скользящие средние и календарные индикаторы, которые помогают модели учитывать прошлые события и сезонные колебания.

Регрессионный анализ осуществляется путем оценки коэффициента линейного уравнения. При этом может быть одна или несколько независимых переменных, которые коррелируют и лучше всех подходят для прогнозирования значения зависимой переменной [11].

Можно считать, что регрессионный анализ выполняется путем подгонки прямой линии к данным, которые стремятся к уменьшению расхождения между фактическими и прогнозируемыми значениями зависимой переменной (рисунок 6).




Рисунок 6 – Линейная регрессия

Из множества методов обучения линейных регрессионных моделей по данным наиболее распространенным является метод наименьших квадратов. Он также называется регрессией наименьших квадратов.

С работой любой линейной регрессионной модели принято связывать четыре основных допущения.

Линейность. Между средним значением зависимой переменной и независимыми переменными должна существовать линейная связь. Эта связь измеряется путем выявления изменений зависимой переменной в связи с изменениями независимых переменных.

Гомоскедастичность. В линейной регрессии гомоскедастичность имеет важное значение, поскольку представляет собой степень подгонки модели под данные. Она определяет дисперсию по величине погрешности или остатков: если дисперсия увеличивается, значит модель подождена плохо.

Независимость. Собранные точки данных должны быть независимы друг от друга.

Нормальность. Должно быть нормальное распределение для любого из фиксированных значений зависимой и независимой переменных.

Линейная регрессия хорошо справляется с краткосрочными прогнозами, когда тенденции относительно стабильны и зависимости линейны. Однако при долгосрочных прогнозах и сложных сезонных изменениях её точность снижается, так как модель не способна самостоятельно выявлять нелинейные закономерности и учитывать внезапные аномальные события, например, резкие всплески спроса или акции. Кроме того, линейная регрессия чувствительна к выбросам, которые могут существенно смещать прогноз, и требует внимательной подготовки признаков, включая нормализацию и кодирование категориальных данных. Несмотря на это, модель остаётся популярной благодаря простоте интерпретации результатов и скорости обучения на больших объёмах данных [21].

Деревья решений

Дерево решений — это иерархический алгоритм машинного обучения, который последовательно разделяет данные на группы на основе значений признаков. Структурно дерево состоит из узлов (node), ветвей (branch) и листьев (leaf). Каждый узел представляет собой проверку определенного признака, ветви — возможные результаты этой проверки, а листья — конечные решения или предсказания.

По своей сути, дерево решений моделирует процесс принятия решений человеком: задавая последовательность вопросов, приходи к определенному выводу. Этот интуитивно понятный подход делает деревья решений одним из самых интерпретируемых алгоритмов машинного обучения.

Деревья решений можно применять для различных типов задач [16]:

- классификация — когда требуется отнести объект к одному из predetermined классов (например, спам/не спам);
- регрессия — для предсказания числовых значений (например, стоимость жилья);
- ранжирование — для определения порядка объектов в выдаче;
- кластеризация — для группировки схожих объектов.

Процесс построения дерева решений для задачи классификации можно представить как последовательное разделение пространства признаков на области, где каждая область соответствует определенному классу.

На верхнем уровне (корневой узел) дерево решений анализирует все обучающие данные и ищет оптимальный признак и значение для разделения данных. После нахождения оптимального разделения, данные делятся на две (или более) группы, образуя дочерние узлы.

Для каждого дочернего узла процесс повторяется рекурсивно: алгоритм ищет новое оптимальное разделение среди оставшихся признаков. Процесс продолжается до тех пор, пока не будет достигнуто условие остановки, например, достигнута максимальная глубина дерева, в узле осталось меньше минимального числа образцов, все образцы в узле принадлежат одному классу, дальнейшее разделение не улучшает качество модели.

Когда процесс построения завершен, конечные узлы (листья) содержат правила классификации. Предсказание для нового объекта выполняется путем прохождения по дереву от корня до листа согласно значениям признаков объекта.

Математически процесс классификации с помощью дерева решений можно описать следующим образом.

Для каждого узла определяется правило разделения вида "признак $X <$ порог" (для числовых признаков) или "признак $X =$ категория" (для категориальных). После построения дерева, для каждого листа вычисляется распределение вероятностей классов на основе статистики обучающих

примеров, попавших в этот лист. При предсказании нового объекта, модель проходит от корня до листа согласно значениям признаков и возвращает либо наиболее вероятный класс, либо распределение вероятностей классов для этого объекта [14].

Ключевая особенность деревьев решений — способность автоматически выбирать наиболее информативные признаки и игнорировать несущественные. Это делает их мощным инструментом для задач с большим количеством потенциально избыточных признаков.

Модель используется в банковской сфере для оценки кредитного риска, в e-commerce для персонализации предложений, в производстве для обнаружения дефектов. В ритейле деревья помогают выявлять правила влияния категорий, магазина и цен на объем продаж.

Деревья решений хорошо выявляют локальные закономерности и позволяют интерпретировать влияние отдельных признаков на прогноз, что делает их эффективными для краткосрочных прогнозов. Однако при долгосрочном прогнозировании без дополнительных признаков точность модели снижается, так как дерево не имеет встроенного механизма сохранения информации о предыдущих временных интервалах. Деревья чувствительны к переобучению на малых выборках и могут быть нестабильными при наличии шума или редких событий, хотя их простая структура и визуализация делают модель удобной для анализа и понимания влияния отдельных факторов на результат.

Случайный лес

Метод случайного леса (Random Forest) — ансамблевый алгоритм машинного обучения, основанный на построении множества деревьев решений. Ключевая идея заключается в том, что комбинация нескольких простых моделей (деревьев) обычно даёт более точный результат, чем одна сложная модель. Важно понимать, что каждое дерево в лесу тренируется независимо от других на своём уникальном наборе данных, созданном с помощью двух ключевых техник:

Бэггинг (Bagging) — обучение каждого дерева на случайной выборке с повторением из оригинального набора данных (bootstrap-выборка)

Случайный выбор признаков (Feature randomness) — для каждого узла дерева алгоритм рассматривает лишь случайное подмножество доступных признаков [8].

Эти техники обеспечивают разнообразие деревьев в ансамбле, что приводит к снижению дисперсии модели без увеличения смещения, тем самым уменьшая риск переобучения.




Рисунок 7 - Схематичное представление архитектуры модели «Случайный лес»

Работу случайного леса можно описать следующими шагами.

1. Создание N bootstrap-выборок из исходного набора данных.
2. Построение N деревьев решений, где для каждого узла:
 - случайно выбирается подмножество из m признаков (обычно $m \approx \sqrt{p}$, где p — общее число признаков);
 - определяется лучший признак и точка разделения из доступных m признаков.
3. Узел делится на два дочерних узла.

4. Получение предсказаний от каждого дерева и их агрегация:

- для классификации: голосование большинства;
- для регрессии: среднее значение.

Выбор случайного леса особенно оправдан, когда требуется баланс между точностью, скоростью обучения и интерпретируемостью, данные имеют нелинейные зависимости и сложную структуру, необходимо определить важность признаков, присутствуют шумы и выбросы в данных [5].

Ключевая особенность случайного леса — создание разнообразного ансамбля деревьев, каждое из которых обучается на уникальной подвыборке данных.

Математически, для набора данных с n наблюдениями и p признаками, процесс построения случайного леса можно описать следующими шагами.

Формирование bootstrap-выборки. Для каждого дерева из исходного набора данных размера n случайным образом с возвращением выбирается n наблюдений. В среднем каждая bootstrap-выборка содержит около 63.2% уникальных наблюдений из исходного набора, а остальные являются дубликатами.

Построение дерева решений. На каждом этапе разбиения узла случайно выбирается $mtry$ признаков из p доступных (обычно $mtry = \sqrt{p}$ для задач классификации и $mtry = p/3$ для регрессии). Определяется оптимальный признак и точка разбиения, максимизирующие информационный прирост: для классификации - уменьшение индекса Джини или энтропии; для регрессии - уменьшение дисперсии целевой переменной.

Остановка роста дерева. Процесс разбиения продолжается до достижения критерия остановки - максимальная глубина дерева достигнута, в узле осталось меньше минимального числа наблюдений, все наблюдения в узле принадлежат одному классу, информационный прирост ниже порогового значения

После построения всего ансамбля, предсказания для новых данных получаются следующим образом. Для классификации: каждое дерево

"голосует" за определенный класс, и итоговым предсказанием становится класс, получивший большинство голосов. Для регрессии итоговое предсказание — среднее арифметическое предсказаний всех деревьев [12].

Случайный лес демонстрирует высокую точность на краткосрочных прогнозах, особенно когда данные содержат шум и выбросы, поскольку усреднение деревьев сглаживает аномальные значения. Однако для долгосрочных прогнозов модель ограничена, так как не может эффективно учитывать долгосрочные тренды и сложные нелинейные зависимости между периодами. В целом, случайный лес хорошо подходит для анализа сложных структур данных со множеством признаков и высокой вариативностью, сохраняя при этом интерпретируемость через оценку важности признаков.

Бустинг

Бустинг — это ансамблевый метод, который строит последовательность деревьев, где каждое последующее дерево обучается исправлять ошибки предыдущего. Такой подход позволяет модели выявлять сложные нелинейные зависимости и учитывать взаимодействие признаков, что делает её высокоэффективной для прогнозирования как краткосрочных, так и долгосрочных трендов. Для временных рядов необходимо заранее формировать лаговые признаки и учитывать сезонные показатели, так как сама модель не сохраняет последовательность данных (рисунок 8).




Рисунок 8 - Схематичное представление архитектуры модели «Бустинг»

Процесс обучения бустинга можно разделить на несколько

последовательных этапов: инициализация начального приближения; вычисление ошибок текущей модели; обучение новой модели на ошибках предыдущей; добавление новой модели к ансамблю с определенным весом; повторение процесса до достижения целевых показателей [15].

Сначала создается базовая модель, которая делает первичные предсказания. Затем рассчитываются ошибки этой модели, и следующая модель фокусируется именно на этих проблемных облаках. Этот процесс повторяется заданное количество раз или до достижения определенного уровня точности.

Анализируя различные реализации бустинга, можно выделить несколько ключевых технических аспектов, которые существенно влияют на эффективность работы алгоритма. Прежде всего, важно понимать, как происходит расчет весов для каждой новой модели в ансамбле. Существует несколько популярных подходов к этому процессу, представленных в таблице.

Таблица 2 – Методы расчета весов в ансамбле

Метод расчета весов	Преимущества	Ограничения
Градиентный бустинг	Универсальность, высокая точность	Высокая вычислительная сложность
AdaBoost	Простота реализации	Чувствительность к шуму
XGBoost	Оптимизированная производительность	Сложность настройки параметров

Каждый из этих методов имеет свою область применения и специфические требования к данным. Например, градиентный бустинг особенно эффективен при работе с большими объемами данных и сложными зависимостями, в то время как AdaBoost может быть предпочтительнее для задач с относительно чистыми данными и небольшим количеством признаков

[11].

Применение на практике - финансовые прогнозы (скоринг клиентов, предсказание дефолтов); E-commerce: прогнозирование спроса, динамическое ценообразование; логистика: прогнозирование объемов перевозок и запасов.

Бустинг показывает высокую точность прогнозов на краткосрочных интервалах, корректно учитывая локальные аномалии и всплески спроса. При долгосрочном прогнозировании эффективность зависит от качества признаков и настройки гиперпараметров, таких как глубина деревьев, скорость обучения и регуляризация. Модель устойчива к выбросам и шуму, но требует тщательной настройки и более сложна для интерпретации по сравнению с деревьями решений или линейной регрессией.

Рекуррентные нейронные сети (LSTM)

Нейронные сети представляют собой математическую конструкцию, состоящую из множества взаимосвязанных нейронов, организованных в слои. Связь между этими слоями осуществляется через синапсы. В определённой степени данная структура напоминает работу человеческого мозга, хотя и является значительно упрощённой его моделью. Нейронные сети в ходе планирования продаж изучают доступные финансовые данные компании (чеки, платёжные поручения, графики платежей, счета и договоры за прошлые периоды), находят скрытые закономерности и строят прогноз продаж на будущие периоды.

Принципиальная идея нейронных сетей заключается в применении одной и той же функции для каждого элемента последовательности, при этом учитывая результаты предыдущих вычислений. Эта рекуррентная природа позволяет сети обрабатывать последовательности произвольной длины — критически важное свойство для работы с текстом, речью и временными рядами.

Фундаментальные характеристики рекуррентных нейросетей разделяемые параметры — одни и те же веса применяются на каждом шаге, что существенно сокращает количество параметров модели; внутреннее

состояние — сеть поддерживает "контекст" через скрытое состояние, которое обновляется на каждом временном шаге; способность к обобщению — возможность работать с последовательностями различной длины после обучения на фиксированном наборе; сквозная архитектура — прямая обработка от входных данных к выходным без ручного конструирования признаков [6].

Преимущества рекуррентных архитектур особенно заметны при работе с данными, где важна временная или последовательная зависимость — будь то предсказание следующего слова в предложении или прогнозирование цен акций на основе исторических данных.

Для преодоления фундаментальных ограничений стандартных рекуррентных нейросетей были разработаны специализированные архитектуры, способные эффективно обрабатывать длинные последовательности. Наиболее значимые из них — LSTM (Long Short-Term Memory) и GRU (Gated Recurrent Unit).

Сети долго-краткосрочной памяти (Long Short Term Memory) – это особый вид нейронных сетей, которые способны обучаться различным долгосрочным зависимостям. Данный вид сетей достаточно эффективен в самых различных случаях, на современном этапе именно этот вид сетей наиболее популярен. LSTM – сети были специально спроектированы так, чтобы в ходе решения различных задач нивелировались проблемы, которые возникают при долгосрочных зависимостях (рисунок 9).




Рисунок 9 - Схематичное представление LSTM-архитектуры

Архитектура LSTM включает три основных вентиля. Вентиль забывания (forget gate) определяет, какую информацию следует удалить из состояния ячейки. Входной вентиль (input gate) контролирует, какая новая информация будет сохранена в состоянии ячейки. Выходной вентиль (output gate) определяет, какая часть информации из ячейки будет использована для формирования выходного сигнала [18].

LSTM сети позволяют избежать возникновения такой проблемы, как проблема, связанная с исчезновением, а также с зашкаливанием градиентов. Проблема появляется в ходе обучения сети при применении так называемого метода обратного распространения ошибки. Рекуррентные вентили, которые используются в каждой сети LSTM, позволяют решить эту проблему. Благодаря им происходит возвращение всех возникающих ошибок через практически неограниченное число сформированных слоёв нейронной сети. Нейронная сеть обучается, и в ходе обучения сохраняется информация обо всех прошедших интервалах времени.

В таблице 3 представлено сравнение рассмотренных моделей машинного обучения.

Таблица 3 - Сравнение моделей машинного обучения

Модель	Преимущества	Недостатки
Линейная регрессия	Простота реализации и интерпретации. Быстрая обучаемость на больших наборах данных.	Не учитывает сложные нелинейные зависимости. Слабо подходит для редких и высоковолатильных товаров.
Деревья решений	Хорошо работает с разнородными и неполными данными. Легко визуализировать и интерпретировать.	Может переобучаться на малых выборках. Для прогнозов временных рядов требуется явное создание лагов.
Случайный лес	Устойчивость к выбросам и шуму. Не требует строгих предположений о распределении данных. Легко интерпретировать важность признаков.	Не так хорошо моделирует долгосрочные зависимости, как LSTM. Требует существенного объема вычислений при большом числе деревьев и признаков.
Бустинг	Высокая точность прогнозов. Устойчивость к разнородным данным и выбросам.	Требует настройки гиперпараметров. Более сложная интерпретация по сравнению с простыми деревьями или регрессией.
Нейронные сети	Хорошо работает с неоднородными данными. Потенциально наиболее точный метод решения.	Вычислительная сложность. Сложность настройки.

Таким образом, конечное решение об использовании той или иной модели для решения задачи планирования продаж возможно после проведения экспериментов по обучению моделей на данных процесса.

2 РАЗРАБОТКА И СРАВНИТЕЛЬНЫЙ АНАЛИЗ МОДЕЛЕЙ ДЛЯ АВТОМАТИЗАЦИИ ПРОЦЕССА ПРОГНОЗИРОВАНИЯ ПРОДАЖ НА ОСНОВЕ ИСТОРИЧЕСКИХ ДАННЫХ

2.1 Сбор и подготовка исходных данных

Первым этапом в разработке модели стало формирование ежедневного временного ряда продаж. Для этого временные метки событий были преобразованы в календарный формат, данные агрегировались по дням, подсчитывалось количество продаж каждого дня. В случае отсутствия продаж на определённые дни пропуски заполнялись нулями, чтобы временной ряд оставался непрерывным.

Для дальнейшего построения модели данные были масштабированы с использованием метода MinMax из библиотеки scikit-learn, который преобразует данные в диапазон [0,1]. Масштабирование особенно важно для LSTM, так как эта сеть использует функции активации, чувствительные к большим значениям входа, что может привести к затухающим или взрывным градиентам в процессе обратного распространения ошибки.

Код масштабирования приведён ниже.

```
from sklearn.preprocessing import MinMaxScaler
sales_df = daily_sales.to_frame(name='sales')
scaler = MinMaxScaler(feature_range=(0, 1))
sales_scaled = scaler.fit_transform(sales_df)
sales_scaled_df = pd.DataFrame(sales_scaled, index=daily_sales.index,
                               columns=['sales_scaled'])
plt.figure(figsize=(12,6))
plt.plot(sales_scaled_df.index, sales_scaled_df['sales_scaled'], color='blue')
plt.title('Масштабированные продажи')
plt.xlabel('Дата')
plt.ylabel('Масштабированные продажи')
```



```
plt.grid(True)
plt.show()
```

После масштабирования данные были визуализированы (рисунок 10). На графике масштабированные продажи сохраняют динамику исходного ряда, но находятся в диапазоне $[0, 1]$, что позволяет нейронной сети эффективно обучаться без искажения закономерностей временного ряда.




Рисунок 10 – Данные после масштабирования

Для обучения LSTM использовался метод временных лагов, позволяющий сети учитывать, как краткосрочные, так и долгосрочные зависимости в продажах:

```
def create_lags(data, lags=[1,7,14,21]):
    X, y = [], []
    for i in range(max(lags), len(data)):
        X.append([data[i-l] for l in lags])
        y.append(data[i])
    return np.array(X), np.array(y)
X_train_lstm, y_train_lstm = create_lags(train_scaled)
def create_lags_test(train_end, test_data, lags=[1,7,14,21]):
    X, y = [], []
    full_data = np.concatenate([train_end, test_data])
```

```

start_idx = len(train_end)
for i in range(start_idx, len(full_data)):
    if i >= max(lags):
        X.append([full_data[i-l] for l in lags])
        y.append(full_data[i])
return np.array(X), np.array(y)

```

На вход модели подаются лаги [1, 7, 14, 21], что позволяет учитывать продажи предыдущего дня, неделю, две и три недели назад. Преобразование в форму (samples, timesteps, features) необходимо для корректной работы LSTM. Такой подход усиливает способность модели учитывать сезонные колебания и тренды на разных временных интервалах.

Выбор архитектуры был основан на необходимости обрабатывать последовательности с несколькими лагами, учитывать, как краткосрочные, так и среднесрочные закономерности, минимизировать риск переобучения.

Процесс настройки модели для обучения представлен следующим образом:

```

model = Sequential()
model.add(LSTM(64, return_sequences = True, input_shape = (X_train_lstm.shape [1],
1)))
model.add(Dropout(0.2))
model.add(LSTM(32))
model.add(Dropout(0.2))
model.add(Dense(1))
model.compile(optimizer='adam', loss=Huber())

```

В таблице 4 продемонстрированы ключевые параметры сети.

Таблица 4 – Параметры сети

Параметр	Значение	Примечание
Количество LSTM-нейронов	64 (первый слой), 32 (второй слой)	Оптимальное число нейронов для обучения и запоминания зависимостей
Функция активации	tanh	Обеспечивает ненасыщаемую активацию, ускоряет обучение
Dropout	0,2	Предотвращает переобучение
Выходной слой	Dense(1)	Прогноз на следующий день
Функция потерь	Huber	-
Оптимизатор	Adam	Эффективен при небольших батчах и нестабильных градиентах
Эпохи	до 100	Используется ранняя остановка для предотвращения переобучения
Размер батча	16	Обеспечивает баланс между скоростью обучения и стабильностью градиентов
Валидация	20%	Для контроля способности модели к обобщению

Для предотвращения переобучения используется коллбек EarlyStopping, который останавливает обучение, если валидационная ошибка не улучшается в течение 10 эпох.

Выбор модели LSTM и ее параметров обусловлен следующими факторами - наличие выраженной недельной сезонности и волатильности спроса, возможность работы с долгими временными рядами и нелинейными зависимостями.

Для более полного анализа эффективности различных методов машинного обучения были реализованы ещё две модели прогнозирования: Random Forest (случайный лес) и XGBoost (градиентный бустинг). Параллельно проведено обучение базовой модели ARIMA для последующего сравнения результатов.

2.2 Обучение и оценка качества моделей прогнозирования

После подготовки данных и формирования входных последовательностей с использованием временных лагов была выполнена обучающая процедура нейронной сети LSTM.

Обучение LSTM-модели осуществлялось с использованием функции потерь MSE (среднеквадратичная ошибка) и оптимизатора Adam, который обеспечивает адаптивное обновление весов и ускоряет сходимость сети.

Параметры обучения установлены следующим образом:

- количество эпох: до 100, с ранней остановкой;
- размер батча: 16 наблюдений;
- валидационная выборка: 20% от обучающей выборки;
- функция потерь: Huber;
- оптимизатор: Adam.

Код представлен далее.

```
early_stop = EarlyStopping(monitor='val_loss', patience=10, restore_best_weights=True)
history = model.fit(X_train_lstm, y_train_lstm, epochs=100, batch_size=16,
validation_split=0.2, verbose=0, callbacks=[early_stop])
lstm_pred_scaled = model.predict(X_test_lstm)
lstm_pred = scaler.inverse_transform(lstm_pred_scaled)
lstm_pred = np.expml(lstm_pred)
```

Данный подход обеспечивает стабильное и качественное обучение сети, учитывающее как краткосрочные, так и недельные зависимости в данных о продажах.

Была обучена модель случайного леса (Random Forest). Алгоритм использует ансамбль деревьев решений и способен выявлять сложные нелинейные зависимости между лаговыми признаками и будущими значениями продаж.

```
lags = [1,2,3,4,5,6,7,14,21]
for lag in lags:
    df[f'lag_{lag}'] = df['y'].shift(lag)
df['rolling_mean_7'] = df['y'].rolling(7).mean()
df['rolling_std_7'] = df['y'].rolling(7).std()
df = df.dropna()
X_rf = df.drop(columns=['y']).values
y_rf = df['y'].values
```

```

split = train_size - max(lags)
X_train_rf, y_train_rf = X_rf[:split], y_rf[:split]
X_test_rf, y_test_rf = X_rf[split:], y_rf[split:]
rf_model = RandomForestRegressor(n_estimators=300, max_depth=10,
random_state=42)
rf_model.fit(X_train_rf, y_train_rf)
rf_pred = np.exp(1/(rf_model.predict(X_test_rf)))

```

Была реализована модель градиентного бустинга XGBoost, которая строит последовательность деревьев решений, постепенно уменьшая ошибку прогноза.

```

xgb_model = XGBRegressor(n_estimators=300, max_depth=6, learning_rate=0.05,
subsample=0.8, colsample_bytree=0.8, random_state=42)
xgb_model.fit(X_train_rf, y_train_rf)
xgb_pred = np.exp(1/(xgb_model.predict(X_test_rf)))

```

Для объективной оценки качества прогнозирования было решено параллельно обучить модель ARIMA, которая является стандартным статистическим инструментом для прогнозирования временных рядов. Модель ARIMA учитывает автокорреляцию и сезонность, но не способна работать с большим числом признаков и сложными нелинейными зависимостями, как LSTM.

Выбор параметров ARIMA (p, d, q) основан на анализе ACF и PACF, а также на минимизации критерия информационного правдоподобия (AIC):

- d = 1 – однократное дифференцирование для приведения ряда к стационарному виду, так как ADF-тест показал, что ряд не является строго стационарным (p-value = 0,056);
- p = 7 – порядки авторегрессии выбраны на основе анализа PACF, где наблюдаются выраженные пики на лаге 7, 14, 21, что указывает на недельную сезонность;
- q = 0 – порядки скользящей средней не включены, так как ACF

показывает слабую корреляцию ошибок.

Код для обучения ARIMA:

```
arima_model = ARIMA(train, order=(7,1,0))  
arima_fit = arima_model.fit()  
arima_pred_log = arima_fit.forecast(steps=len(test))  
arima_pred = np.exp(m1(arima_pred_log))
```

Использование всех моделей одновременно позволяет сравнивать традиционный статистический подход с машинным обучением, выявлять преимущества при учёте сложных зависимостей и сезонности, а также оценивать качество прогноза с использованием стандартных метрик.

Для всех моделей подготовлена система расчёта основных метрик точности прогнозирования.

1. Среднеквадратичная ошибка (RMSE, Root Mean Squared Error)

Показывает среднеквадратичное отклонение прогноза от фактических значений. Чем меньше RMSE, тем точнее модель воспроизводит динамику продаж. Эта метрика особенно чувствительна к большим отклонениям, поэтому хорошо отражает влияние редких резких пиков продаж.

2. Средняя абсолютная ошибка (MAE, Mean Absolute Error)

Отображает среднее абсолютное расхождение между прогнозом и фактическими значениями. MAE менее чувствительна к выбросам по сравнению с RMSE и позволяет оценить среднюю величину ошибки в тех же единицах измерения, что и данные.

3. Средняя абсолютная процентная ошибка (MAPE, Mean Absolute Percentage Error)

Выражает среднюю ошибку в процентах относительно фактических значений. MAPE удобна для интерпретации, так как показывает относительную точность модели, и особенно полезна для сравнения моделей между собой, например, LSTM и ARIMA.

Применение этих метрик обеспечивает комплексную оценку модели: RMSE учитывает большие колебания, MAE отражает среднюю ошибку, а

MAPE показывает относительную точность. Все три метрики вместе позволяют определить, насколько хорошо модель способна предсказывать динамику продаж на основе исторических данных и выявленных лагов.

2.3 Сравнительный анализ результатов прогнозирования моделей

После обучения и настройки моделей были получены прогнозы на тестовый период временного ряда ежедневных продаж для двух вариантов обработки данных:

- исходный ряд с нулями, где пропуски не интерполировались;
- ряд, в котором пропуски после reindex заполнены интерполяцией и малые значения (<30 продаж) удалены.

Метрики точности прогнозов (RMSE, MAE, MAPE) рассчитаны отдельно для обоих вариантов и приведены далее в таблицах.

Таблица 5 – Метрики качества прогнозов моделей (вариант 1)

Модель	RMSE	MAE	MAPE (%)
ARIMA	47,82	33,99	62,01
LSTM	40,26	31,38	51,06
Случайный лес	45,14	29,9	54,48
Градиентный бустинг	42,99	28,93	51,74

Таблица 6 – Метрики качества прогнозов моделей (вариант 2)

Модель	RMSE	MAE	MAPE (%)
ARIMA	45,03	32,92	37,99
LSTM	37,85	30,57	31,72
Случайный лес	42,54	28,83	32,85
Градиентный бустинг	40,57	27,89	31,54

Рассмотрим результаты прогнозирования ежедневных продаж для двух вариантов обработки временного ряда.

Вариант 1

Модель LSTM показала наименьшие значения всех метрик ($RMSE = 40.26$, $MAE = 31.38$, $MAPE = 51.06\%$), что свидетельствует о высокой точности предсказания и способности учитывать сложные краткосрочные и среднесрочные зависимости в данных о продажах. Использование лагов 1, 7, 14 и 21 день позволило сети моделировать недельную сезонность и повторяющиеся пики продаж. Прогноз LSTM лучше отражает резкие колебания спроса и пики, что делает модель предпочтительной для оперативного планирования закупок и прогнозирования спроса.

ARIMA показала высокие значения ошибок, что указывает на менее точное предсказание по сравнению с LSTM. Модель хорошо отражает общую тенденцию и сезонные колебания, однако отстаёт в периоды резких скачков продаж, создавая более сглаженный прогноз. Модель Random Forest способна учитывать нелинейные зависимости и взаимодействие признаков, но не всегда точно прогнозирует экстремальные значения. Результаты XGBoost подтверждают устойчивость бустингового метода к сложным зависимостям и его способность давать конкурентные прогнозы по сравнению с другими моделями машинного обучения.

Вариант 2

LSTM вновь показала лучшие результаты по всем метрикам ($RMSE = 37.85$, $MAE = 30.57$, $MAPE = 31.72\%$), что подтверждает высокую точность модели при сглаживании редких пропусков и удалении малых продаж. Модель эффективно учитывает сезонные паттерны и резкие колебания продаж, обеспечивая более стабильный прогноз.

ARIMA заметно улучшила показатели по сравнению с вариантом 1, что связано с тем, что интерполяция ряда устранила нулевые значения, влияющие на точность модели. Прогноз стал лучше отражать краткосрочные изменения, хотя все ещё остаётся более сглаженным по сравнению с LSTM.

Модель Random Forest демонстрирует улучшение точности по сравнению с вариантом без интерполяции. Модель сохраняет способность учитывать нелинейные зависимости между признаками, а удаление малых

значений улучшило качество прогноза. XGBoost продемонстрировал наилучшую точность среди моделей с бустингом, подтверждая устойчивость к сложным зависимостям.

Сравнение двух вариантов обработки данных показывает, что интерполяция пропусков и удаление малых продаж существенно улучшает точность всех моделей, особенно LSTM и ARIMA. Наибольшей точностью прогнозирования обладает LSTM, которая стабильно демонстрирует лучшие значения всех метрик и способна учитывать сложные краткосрочные и среднесрочные зависимости в данных о продажах.

Для наглядного сравнения работы моделей были построены графики фактических продаж и прогнозов моделей.

Код представлен в приложении.




Рисунок 11 – Прогноз по модели ARIMA (вариант 1)




Рисунок 12 – Прогноз по модели ARIMA (вариант 2)




Рисунок 13 – Прогноз по модели LSTM (вариант 1)




Рисунок 14 – Прогноз по модели LSTM (вариант 2)




Рисунок 15 – Прогноз по модели Случайный лес (вариант 1)



Рисунок 16 – Прогноз по модели Случайный лес (вариант 2)




Рисунок 17 – Прогноз по модели Градиентный бустинг (вариант 1)




Рисунок 18 – Прогноз по модели Градиентный бустинг (вариант 2)



Рисунок 19 - Сравнение прогнозов моделей (вариант 1)



Рисунок 20 - Сравнение прогнозов моделей (вариант 2)

На графиках прогнозов видно, что модель ARIMA хорошо отражает общую динамику продаж, учитывая недельную сезонность, однако при резких скачках спроса её прогноз несколько отстаёт от фактических значений.

Прогноз LSTM демонстрирует более точное повторение фактических колебаний, включая краткосрочные пики и падения, благодаря использованию лагов и слоёв LSTM, способных запоминать сложные зависимости во временном ряду.

Модели Случайный лес и Градиентный бустинг также показывают

способность учитывать сложные нелинейные зависимости и сезонные колебания. Их прогнозы в целом повторяют тенденции продаж, но наблюдаются небольшие смещения в моменты резких скачков и падений, что связано с особенностями деревьев решений — они лучше работают при более сглаженных и регулярных закономерностях, чем при резких изменениях данных.

Все отмеченные тенденции наблюдаются в обоих вариантах обработки ряда: без интерполяции и с заполнением пропусков и интерполяцией. Визуально различия между вариантами минимальны.

Для детального анализа точности моделей были построены графики ошибок прогнозов (разница между фактическими продажами и предсказанными значениями) для каждого дня периода.

Код представлен далее.

```
plt.figure(figsize=(12,4))
plt.plot(test_common_index, arima_error, label='Ошибка ARIMA', color='orange')
plt.title('Ошибка прогноза ARIMA')
plt.xlabel('Дата')
plt.ylabel('Ошибка')
plt.grid(True)
plt.legend()
plt.show()

plt.figure(figsize=(12,4))
plt.plot(test_common_index, lstm_error, label='Ошибка LSTM', color='green')
plt.title('Ошибка прогноза LSTM')
plt.xlabel('Дата')
plt.ylabel('Ошибка')
plt.grid(True)
plt.legend()
plt.show()

plt.figure(figsize=(12,4))
plt.plot(test_common_index, rf_error, label='Ошибка Random Forest', color='red')
plt.title('Ошибка прогноза Random Forest')
plt.xlabel('Дата')
```

```

plt.ylabel('Ошибка')
plt.grid(True)
plt.legend()
plt.show()

plt.figure(figsize=(12,4))
plt.plot(test_common_index, xgb_error, label='Ошибка XGBoost', color='purple')
plt.title('Ошибка прогноза XGBoost')
plt.xlabel('Дата')
plt.ylabel('Ошибка')
plt.grid(True)
plt.legend()
plt.show()

plt.figure(figsize=(14,6))
plt.plot(test_common_index, arima_error, label='ARIMA', color='red')
plt.plot(test_common_index, lstm_error, label='LSTM', color='green')
plt.plot(test_common_index, rf_error, label='Random Forest', color='orange')
plt.plot(test_common_index, xgb_error, label='XGBoost', color='purple')
plt.title('Сравнение ошибок всех моделей')
plt.xlabel('Дата')
plt.ylabel('Ошибка')
plt.legend()
plt.grid(True)
plt.show()

```




Рисунок 21 – Динамика ошибок модели ARIMA (вариант 1)




Рисунок 22 – Динамика ошибок модели ARIMA (вариант 2)




Рисунок 23 – Динамика ошибок модели LSTM (вариант 1)




Рисунок 24 – Динамика ошибок модели LSTM (вариант 2)




Рисунок 25 – Динамика ошибок модели Случайный лес (вариант 1)




Рисунок 26 – Динамика ошибок модели Случайный лес (вариант 2)




Рисунок 27 – Динамика ошибок модели Градиентный бустинг (вариант 1)




Рисунок 28 – Динамика ошибок модели Градиентный бустинг (вариант 2)




Рисунок 29 – График ошибок моделей (вариант 1)




Рисунок 30 – График ошибок моделей (вариант 2)

На графиках ошибок видно, что прогноз LSTM в обоих вариантах демонстрирует наименьшие отклонения от фактических значений и распределён более равномерно по всему тестовому периоду. В то же время ошибки моделей ARIMA, Random Forest и XGBoost заметно увеличиваются в периоды резких колебаний продаж, что отражает их меньшую способность точно повторять краткосрочные пики и спады спроса.

Анализ метрик и графиков позволяет сделать следующие выводы. Модель LSTM показала наименьшие значения RMSE, MAE и MAPE среди всех рассмотренных моделей, что свидетельствует о её высокой способности учитывать краткосрочные и среднесрочные закономерности в данных о продажах. Благодаря использованию лагов 1, 7, 14 и 21 день, LSTM эффективно моделирует недельную сезонность и повторяющиеся пики спроса.

Модели Random Forest и XGBoost также демонстрируют удовлетворительные результаты, значительно превосходя ARIMA по точности в моменты резких колебаний продаж, однако уступают LSTM по суммарной точности и способности воспроизводить краткосрочные пики. Модель ARIMA обеспечивает более сглаженный прогноз, хорошо отражая общую динамику и сезонность, но менее чувствительна к краткосрочным изменениям.

В совокупности полученные результаты подтверждают целесообразность применения LSTM для точного прогнозирования продаж, особенно при наличии выраженной сезонности и высокой волатильности данных, а также показывают, что модели машинного обучения, такие как Random Forest и XGBoost, могут служить полезным дополнением для сравнения и резервного анализа прогноза. Использование этих моделей позволяет более обоснованно планировать закупки и управлять запасами, обеспечивая экономический эффект при внедрении системы прогнозирования.

3 РАЗРАБОТКА ПРОГРАММНОГО ИНТЕРФЕЙСА И ТЕСТИРОВАНИЕ МОДЕЛЕЙ ПРОГНОЗИРОВАНИЯ

3.1 Разработка интерфейса и тестирование моделей прогнозирования

Для удобного использования разработанных моделей прогнозирования продаж был создан интерактивный пользовательский интерфейс. Интерфейс предоставляет возможность самостоятельно загружать данные, запускать прогнозирование и визуализировать результаты.

В качестве платформы для реализации интерфейса была выбрана библиотека Streamlit, которая позволяет быстро создавать веб-приложения на Python с минимальными усилиями по разработке фронтенда. Streamlit обеспечивает интерактивность, автоматическую визуализацию графиков и простоту развёртывания: приложения можно запускать локально или размещать на сервере для удалённого доступа.

Структура интерфейса включает следующие элементы:

- панель загрузки данных (CSV-файл с историей продаж);
- выбор модели прогнозирования: ARIMA, LSTM, Random Forest или XGBoost;
- кнопка запуска прогнозирования и вычисления метрик качества;
- графическая визуализация результатов: фактические и прогнозные значения, отдельные графики ошибок для каждой модели;
- таблица с основными метриками RMSE, MAE и MAPE для выбранной модели.

Интерфейс реализован при помощи следующих компонентов:

- элемент `st.file_uploader` для загрузки данных, поддерживает CSV-файлы;
- элемент `st.multiselect` для выбора моделей прогнозирования;
- `st.line_chart` для отображения исходных данных;

- `st.dataframe` для вывода таблицы метрик качества;
- библиотека `Matplotlib` и функции `st.pyplot` для визуализации результатов прогнозирования.

Загрузка данных осуществляется пользователем в формате CSV. После загрузки выполняется автоматическая фильтрация событий, выделение транзакций и преобразование временных меток в календарный формат. Далее формируется ежедневный временной ряд продаж, который приводится к непрерывному виду с заполнением пропусков.

После выбора моделей пользователь может запустить процесс прогнозирования. В приложении реализована поддержка четырёх моделей: ARIMA, LSTM, Random Forest и XGBoost. Для каждой модели автоматически рассчитываются метрики качества (RMSE, MAE, MAPE), которые выводятся в виде таблицы.

Реализована визуализация результатов. Графики строятся динамически и отображают как фактические значения продаж, так и прогнозы выбранных моделей.




Рисунок 31 – Загрузка данных и выбор моделей




Рисунок 32 – Построение прогноза




Рисунок 33 – Построение прогноза

В процессе разработки было проведено тестирование интерфейса. Функциональное тестирование включало проверку корректности загрузки входных данных, работы всех моделей и правильности расчёта метрик. В ходе тестирования установлено, что приложение корректно обрабатывает входные CSV-файлы, формирует временной ряд и выполняет прогнозирование без ошибок.

Тестирование пользовательского интерфейса показало, что структура приложения является интуитивно понятной: пользователь последовательно выполняет загрузку данных, выбор моделей и анализ результатов. Время отклика системы остаётся приемлемым даже при использовании нескольких моделей одновременно.

Таким образом, разработанный интерфейс обеспечивает удобное взаимодействие пользователя с системой прогнозирования, позволяет быстро получать результаты анализа и визуализировать прогнозы моделей. Минималистичный дизайн и автоматизация основных этапов обработки данных делают приложение эффективным инструментом для практического использования.

3.2 Внедрение моделей прогнозирования в информационную систему предприятия

Для последующего использования моделей необходимо осуществить ряд мероприятий по внедрению программного компонента в эксплуатацию путем интеграции с существующей информационной системой.

Итоговый перечень работ в предварительной форме представлен в таблице.

Таблица 7 - Предварительный план мероприятий по введению программного средства прогнозирования продаж в эксплуатацию

Этап	Производимые работы
Разработка программы	Программирование и отладка программы.
Разработка программной документации	Разработка программных документов в соответствии с требованиями ГОСТ 19.101-77.
Испытания программы	Разработка, согласование и утверждение порядка и методики испытаний. Корректировка программы и программной документации по результатам испытаний.
Ввод в действие	Подготовка ИС к внедрению дополнительного функционала.
	Подготовка персонала.
	Проведение предварительных испытаний.
	Проведение опытной эксплуатации.
	Проведение приемочных работ.
Сопровождение	Выполнение работ по сопровождению программного обеспечения.

Далее для составления плана по внедрению программы необходимо подробно разобрать и оценить каждый этап предварительного плана мероприятий по введению программы в эксплуатацию.

Разработка программы – данный этап включает в себя программирование и отладку программы, оптимизацию кода и его адаптацию к используемому программному обеспечению.

Разработка программной документации – составление документов в соответствии с ГОСТ 19.101-77. К данным работам должен быть привлечен инженер по машинному обучению и сотрудники. Для эксплуатации и внедрения программы в компании необходим следующий перечень документов в соответствии с внутренними требованиями и стандартами.

1. Спецификация.

2. Текст программы.
3. Описание программы.
4. Пояснительная записка.

Эксплуатационные документы:

5. Формуляр.
6. Описание применения.
7. Руководство системного программиста.
8. Руководство программиста.
9. Руководство оператора.
10. Руководство по техническому обслуживанию.

В дополнение к упомянутым документам – необходимы документы, свидетельствующие о проведении оценки рисков информационной безопасности по внутренним стандартам предприятия.

Испытания программы – данный этап соответствует понятию модульного тестирования – процесс в программировании, позволяющий проверить на корректность отдельные модули исходного кода программы, наборы из одного или более программных модулей вместе с соответствующими управляющими данными, процедурами использования и обработки.

К нему вновь привлекается инженер по машинному обучению. Фактически составом работ будет проверка на корректность работы методов конечного интерфейса, с которым будет взаимодействовать информационная система.

Внедрение дополнительного функционала в ИС. Для использования нового функционала информационной системы будет необходимо произвести доработки интерфейса информационной системы, внести изменения в программный код ИС и документацию, интегрировать программный код. По завершении технических работ начнется составление руководства пользователя для последующего обучения персонала, далее следует провести модульное тестирование нового интерфейса.

К данным работам будут привлечены сотрудники – как конечные пользователи данного функционала и основной источник требований к интерфейсу, специалист по внедрению и разработчик информационной системы.

Подготовка персонала. Осуществляется специалистом по внедрению и сотрудниками. В рамках данного этапа производится обучение персонала к эксплуатации нового интерфейса информационной системы, производится ознакомление с руководством пользователя и объясняются вносимые в процесс изменения, этапы проведения тестирования и последующего ввода в эксплуатацию.

Проведение предварительных испытаний. Производится рабочей группой при поддержке специалиста по внедрению. На данном этапе пользователи тестируют новый интерфейс и функционал самостоятельно, в случае возникновения ошибок производится их исправление программистом. На данном этапе важно произвести полное тестирование функциональных возможностей интерфейса.

Проведение опытной эксплуатации. Следующим шагом, на протяжении периода тестирования, соответствующего одному периоду планирования, производится пилотный ввод в эксплуатацию нового функционала в отдельном выбранном подразделении компании. В данном этапе принимает участие сотрудник службы финансового мониторинга.

Параллельно используется как старая форма процесса, так и новая, что приводит к дополнительным временным затратам только у одного участника этапа – сотрудника Службы финансового мониторинга. По завершении этапа формируются итоговые отчеты, содержащие статистику и аналитику принимаемых новым модулем решений, их сравнение с результатами расчетов.

Проведение приемочных работ. Условный этап, на котором производится анализ отчета о проведении опытной эксплуатации, после чего принимается финальное решение о переходе на новый процесс.

Итоговый план внедрения программы в эксплуатацию с оценкой трудозатрат каждого этапа представлен в таблице.

Таблица 8 - План ввода программного средства прогнозирования продаж в эксплуатацию

Этап	Производимые работы	Сотрудники	Трудозатраты
Разработка программного модуля	Финализация программного кода Модульное тестирование Разработка документации	Инженер по машинному обучению	56 часов
Внедрении дополнительного функционала в ИС	Разработка пользовательского интерфейса Разработка кода автоматизированного управления процессом планирования	Специалист по внедрению Разработчик ИС Служба финансового мониторинга	48 часов
Обучение сотрудников	Ознакомление с новым интерфейсом Обучение работе с новым функционалом Ознакомление с руководствами и новой процедурой	Специалист по внедрению Служба финансового мониторинга	10 часов
Проведение предварительных испытаний	Тестирование нового интерфейса и функционала пользователями	Специалист по внедрению Служба финансового мониторинга	4 часа
Проведение опытной эксплуатации	Наблюдение и анализ метрик, принимаемых системой автоматизированного управления решениями, сравнение с экспертной оценкой.	Служба финансового мониторинга	9 часов
Проведение приемочных работ	Проведение закрывающих проект встреч	IT-отдел Служба финансового мониторинга	2 часа
Итого	-	-	129 часов

Из возможных рисков, которые могут привести к затратам на обслуживание системы стоит выделить несколько случаев, рассмотренных далее.

Миграция ИС.

Данные риски связаны с возможностью обновления или изменения платформы. Все работы по миграции системы осуществляются в рамках проекта по миграции разработчиком информационной системы, совместно со специалистами предприятия.

Проблемы с эксплуатацией программного модуля.

Данный риск связан с внесениями изменений в саму ИС и возможными конфликтами этих изменений с конфигурацией программного модуля. В таком случае будет необходимо привлечение специалиста по внедрению и / или инженера по машинному обучению. Стоит учитывать риск как возникающий раз в два года.

Некорректная работа модели.

Данный риск связан с изменением в экономике, которые могут привести к значительному изменению поведения расходов на персонал в долгосрочном периоде. Для проведения нового исследования и корректировки модели машинного обучения будет необходимо привлечение инженера по машинному обучению, специалиста по внедрению. Данный риск целесообразно учитывать, как возникающий раз в пять лет.

ЗАКЛЮЧЕНИЕ

Таким образом, объектом проведенного исследования стало предприятие розничной торговли, для которого была разработана система прогнозирования ежедневных продаж на основе исторических данных. Целью работы являлось повышение точности прогнозирования продаж, оптимизация процессов планирования и снижение трудозатрат сотрудников.

В рамках работы была сформирована база данных ежедневных продаж предприятия, выполнена обработка временного ряда и его масштабирование. Для реализации прогнозирования использовались четыре модели.

LSTM (Long Short-Term Memory) – рекуррентная нейронная сеть, способная учитывать, как краткосрочные, так и долгосрочные зависимости во временных рядах. Сети LSTM решают проблему исчезновения и взрыва градиентов за счет рекуррентных вентилей («вентили забывания»), что позволяет сохранять память о тысячах прошедших временных интервалах.

Random Forest (Случайный лес) – ансамблевая модель деревьев решений, эффективно выявляющая нелинейные зависимости между лаговыми признаками и будущими продажами.

XGBoost (градиентный бустинг) – последовательное построение деревьев решений для уменьшения ошибки прогноза, устойчивое к сложным зависимостям в данных.

ARIMA – статистическая модель временных рядов, учитывающая автокорреляцию и сезонность, хорошо отражающая общие тенденции, но менее чувствительная к резким краткосрочным колебаниям.

Для подготовки данных применялись методы агрегирования, масштабирования с помощью MinMaxScaler, формирование временных лагов (1, 7, 14 и 21 день) и интерполяция пропусков. Обучение моделей проводилось с использованием Python и библиотек: NumPy, Pandas, Matplotlib, scikit-learn, XGBoost, Keras. Для предотвращения переобучения LSTM применялись методы Dropout и EarlyStopping.

Анализ метрик точности (RMSE, MAE, MAPE) показал, что модель LSTM демонстрирует наименьшие ошибки прогнозирования и наиболее точно воспроизводит как краткосрочные колебания, так и недельные сезонные пики продаж. Random Forest и XGBoost также показали высокую точность, особенно в предсказании нелинейных зависимостей, но уступают LSTM по суммарной точности. ARIMA обеспечила сглаженный прогноз, отражающий общую динамику и сезонность, однако менее точна при резких изменениях спроса.

Для практического использования разработан интерактивный интерфейс на платформе Streamlit, позволяющий загружать данные, выбирать модель прогнозирования, запускать расчет и визуализировать результаты. Создан план внедрения, включающий: разработку и тестирование программного модуля, интеграцию в информационную систему предприятия, обучение сотрудников, предварительные испытания, опытную эксплуатацию и приемочные работы.

Все поставленные задачи выпускной квалификационной работы выполнены: разработаны и обучены модели прогнозирования, создан пользовательский интерфейс для их применения, проведен анализ экономического эффекта.

СПИСОК ЛИТЕРАТУРЫ

1. Андреас, М. Введение в машинное обучение с помощью Python. Руководство для специалистов по работе с данными / М. Андреас. - М.: Альфа-книга, 2017. - 244 с.
2. Антонова, П. Введение в искусственный интеллект: Теоретические основы СИИ / П. Антонова. - LAMBERT Academic Publishing, 2019. – 412 с.
3. Васильев, А.Н. Принципы и техника нейросетевого моделирования / А.Н. Васильев. - Москва: Машиностроение, 2023. - 861 с.
4. Вьюгин, В.В. Математические основы машинного обучения и прогнозирования / В.В. Вьюгин. - М.: Московский центр непрерывного математического образования (МЦНМО), 2018. - 844 с.
5. Гелиг, А. Х. Введение в математическую теорию обучаемых распознающих систем и нейронных сетей. Учебное пособие / А.Х. Гелиг, А.С. Матвеев. - М.: Издательство СПбГУ, 2020. - 224 с.
6. Круглов, В. В. Искусственные нейронные сети. Теория и практика / В.В. Круглов, В.В. Борисов. - М.: Горячая линия - Телеком, **2019**. - 382 с.
7. Лабусов, М.В. Нейронные сети долгой краткосрочной памяти и их использование для моделирования финансовых временных рядов // Инновации и инвестиции. – 2020. – № 3. – С. 167-171.
8. Лабусов, М.В. Обзор моделей анализа и прогнозирования высокочастотных финансовых временных рядов // Экономика и предпринимательство. – 2019. – № 6 (107). – С. 1256-1258.
9. Лысцов, Н.А. Нейронные сети: применение и перспективы Н.А. Лысцов, А.И. Мартышкин // «Студенческий научный форум 2019»: мат-лы XI междунар. студ. науч. конф. Научное обозрение. – 2019. – № 3. – С. 35-38.
10. Любанович, Б. Простой Python. Современный стиль программирования 2-е издание / Б. Любанович; Пер. с англ. – СПб.: ООО

«Прогресс книга», 2021. – 592 с.

11. Машинное обучение в финансах: учебник / С. Ю. Богатырев, А. А. Помулев, А. В. Затевахина [и др.]; под. ред. С. Ю. Богатырева. - Москва: Прометей, 2024. - 224 с.

12. Неустроев, Д.Д. Интерпретируемость моделей машинного обучения / Д.Д. Неустроев, Д.И. Курманова // Язык в сфере профессиональной коммуникации: сб. матер. междунаrod. науч.-практ. конф. преподавателей, аспирантов и студентов (Екатеринбург, 18 апреля 2019 г.). – Екатеринбург: Ажур, 2019. – С. 484–488.

13. Омату, Сигеру Нейроуправление и его приложения. Книга 2 / Сигеру Омату. - М.: Радиотехника, 2019.- 325 с.

14. Перминов, Н.К. Интерпретация результатов машинного обучения для задачи регрессии / Н.К. Перминов // Информатика: проблемы, методы, технологии: материалы XXII Международ. науч.-практ. конф. им. Э. К. Алгазинова, 2022. – С. 1185–1196.

15. Редько, В.Г. Подходы к моделированию мышления / В.Г. Редько. - Москва: Мир, 2021. - 218 с.

16. Редько, В.Г. Эволюция, нейронные сети, интеллект: Модели и концепции эволюционной кибернетики / В.Г. Редько. - Москва: РГГУ, 2020. - 224 с.

17. Саттон, Р.С. Обучение с подкреплением: Введение / Р.С. Саттон, Э. Дж. Барто. - М.: ДМК Пресс, 2020.

18. Сидорова, М. Н. Искусственный интеллект в маркетинге / М. Н. Сидорова // Восточно-Европейский научный вестник. – 2023. – Т. 19, № 2. – С. 28-30.

19. Суханова, О.Н. Эконометрические модели как инструмент анализа в управлении экономическими системами / О.Н. Суханова, О.В. Ментюкова // Модели, системы, сети в экономике, технике, природе и обществе. – 2016. – №1 (17). – С. 125–134. EDN VTYLSV

20. Таганов, А. И. Нейросетевые системы искусственного интеллекта

в задачах обработки изображений / А.И. Таганов. - М.: Горячая линия - Телеком, 2023. - 654 с.

21. Флах, П. Машинное обучение. Наука и искусство построения алгоритмов, которые извлекают знания из данных / П. Флах. - М.: ДМК Пресс, 2015.

22. Шалев-Шварц, Ш. Идеи машинного обучения: от теории к алгоритмам / Ш. Шалев-Шварц, Ш. Бен-Давид. - М.: ДМК Пресс, 2019.

23. Шарден, Б. Крупномасштабное машинное обучение вместе с Python / Б. Шарден. - М.: ДМК Пресс, 2016. - 814 с.

24. Bellec G. Deep Rewiring: Training Very Sparse Deep Networks / G. Bellec. – B: International Conference on Learning Representations, 2018. – 298 с.

25. Bohanec M., Borštnar M.K., Robnik-Šikonja M. Explaining machine learning models in sales predictions / M. Bohanec, M.K. Borštnar, M. Robnik-Šikonja // Expert Systems with Applications. – 2017. – Vol. 71. – P. 456–465.

26. Breiman L. Random Forests // Machine Learning. - 2001. № 45 (1) С. 5 32.

27. Bughin J., Hazan E., Ramaswamy S., Chui M., Allas T., Dahlström P., Henke N., Trench M. Artificial Intelligence: The Next Digital Frontier? / J. Bughin и др. – McKinsey Global Institute, 2017.

28. Chen I.F., Lu C.J. Sales forecasting by combining clustering and machine-learning techniques for computer retailing / I.F. Chen, C.J. Lu // Neural Computing and Applications. – 2017. – Vol. 28. – P. 1–11.

29. Cheriyan S., Ibrahim S., Mohanan S. [и др.]. Intelligent sales prediction using machine learning techniques / S. Cheriyan [и др.] // 2018 International Conference on Computing, Electronics & Communications Engineering (iCCECE). – IEEE, 2018. – P. 65–70.

30. Chettier T.M., Boyina V.A.K. Integrating machine learning with fullstack development using ML .NET / T.M. Chettier, V.A.K. Boyina // ResearchGate. – 2025

31. Dankorpho P. Sales forecasting for retail business using XGBoost

algorithm / P. Dankorpo // Journal of Computer Science and Technology Studies. – 2024. – Vol. 6, № 2. – P. 15.

32. Falatouri T., Darbanian F., Brandtner P. [и др.]. Predictive analytics for demand forecasting—a comparison of SARIMA and LSTM in retail SCM / T. Falatouri [и др.] // Procedia Computer Science. – 2022. – Vol. 200. – P. 1482–1491.

33. Fomenko, S. I. The influence of water evaporation on surface acoustic waves in soils / S.I. Fomenko, R.B. Jana // 2023 Days on Diffraction (DD). – 2023, P. 1-4

34. Gurusamy A., Mohamed I.A. The evolution of full stack development: trends and technologies shaping the future / A. Gurusamy, I.A. Mohamed // Journal of Knowledge Learning and Science Technology. – 2020. – Vol. 9, № 2. – P. 129–142.

35. Kearns M., Nevmyvaka Y. Machine Learning for Market Microstructure and High Frequency Trading / M. Kearns, Y. Nevmyvaka. – High Frequency Trading, 2013. – 263 с.

36. Khan M.A., Saqib S., Alyas T., Rehman A.U. [и др.]. Effective demand forecasting model using business intelligence empowered with machine learning / M.A. Khan [и др.] // IEEE Access. – 2020. – Vol. 8. – P. 116013–116023.

37. Madeh, S. Piryonesi Role of Data Analytics in Infrastructure Asset Management: Overcoming Data Size and Quality Problems / S. Madeh Piryonesi, Tamer E. El-Diraby // Journal of Transportation Engineering, Part B: Pavements. – 2020. № 146 (2).

38. Massaro A., Panarese A., Giannone D., Galiano A. Augmented data and XGBoost improvement for sales forecasting in the large-scale retail sector / A. Massaro [и др.] // Applied Sciences. – 2021. – Vol. 11, № 17. – P. 7793.

39. Nasser M., Falatouri T., Brandtner P., Darbanian F. Applying machine learning in retail demand prediction—A comparison of tree-based ensembles and long short-term memory-based deep learning / M. Nasser [и др.] // Applied Sciences. – 2023. – Vol. 13, № 19. – P. 11112

40. Oliveira J.M., Ramos P. Evaluating the effectiveness of time series

transformers for demand forecasting in retail / J.M. Oliveira, P. Ramos // Mathematics. – 2024. – Vol. 12, № 17. – P. 2728.

41. Pavlyshenko B.M. Machine-learning models for sales time series forecasting / B.M. Pavlyshenko // Data. – 2019. – Vol. 4, № 1. – P. 15.

42. Soltaninejad M., Aghazadeh R. [и др.]. Using machine learning techniques to forecast Mehram company's sales: A case study / M. Soltaninejad [и др.] // Journal of Business and Management Studies. – 2024. – Vol. 6, № 1. – P. 31–45.

43. Zhang, X. Character-level convolutional networks for text classification / Xiang Zhang, Junbo Zhao, Yann LeCun // In Advances in Neural Information Processing Systems. — 2015. — Feb. — 649 - 657 p.

ПРИЛОЖЕНИЕ

Код для построения графиков по моделям

```
import matplotlib.pyplot as plt
plt.style.use('seaborn-darkgrid')
plt.figure(figsize=(12,6))
plt.plot(series.index, series.values, label='Фактические продажи', color='black',
linewidth=1.5)
plt.plot(test.index, arima_pred, label='ARIMA', color='orange')
plt.plot(test.index[-len(lstm_pred):], lstm_pred.flatten(), label='LSTM', color='green')
plt.plot(test.index[-len(rf_pred):], rf_pred, label='Random Forest', color='red')
plt.plot(test.index[-len(xgb_pred):], xgb_pred, label='XGBoost', color='purple')
plt.title('Сравнение прогнозов всех моделей')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.tight_layout()
plt.show()

plt.figure(figsize=(12,4))
plt.plot(series.index, series.values, label='Фактические продажи', color='black')
plt.plot(test.index, arima_pred, label='ARIMA', color='orange')
plt.title('Прогноз ARIMA')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.tight_layout()
plt.show()

plt.figure(figsize=(12,4))
plt.plot(series.index, series.values, label='Фактические продажи', color='black')
plt.plot(test.index[-len(lstm_pred):], lstm_pred.flatten(), label='LSTM', color='green')
plt.title('Прогноз LSTM')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.tight_layout()
```

```

plt.show()
plt.figure(figsize=(12,4))
plt.plot(series.index, series.values, label='Фактические продажи', color='black')
plt.plot(test.index[-len(rf_pred):], rf_pred, label='Random Forest', color='red')
plt.title('Прогноз Random Forest')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.tight_layout()
plt.show()

plt.figure(figsize=(12,4))
plt.plot(series.index, series.values, label='Фактические продажи', color='black')
plt.plot(test.index[-len(xgb_pred):], xgb_pred, label='XGBoost', color='purple')
plt.title('Прогноз XGBoost')
plt.xlabel('Дата')
plt.ylabel('Продажи')
plt.legend()
plt.tight_layout()
plt.show()

```