

Автоматизация процесса прогнозирования продаж на основе исторических данных

Содержание

Введение.....	5
Глава 1. Теоретические основы прогнозирования продаж.....	8
1.1. Понятие и роль прогнозирования в бизнес-процессах	8
1.2. Методы прогнозирования продаж.....	8
1.3. Машинное обучение в прогнозировании временных рядов....	9
1.4. Подходы к автоматизации прогнозирования	9
Глава 2. Анализ предметной области и постановка задачи.....	11
2.1. Характеристика данных о продажах.....	11
2.2. Факторы, влияющие на объёмы продаж.....	11
2.3. Формулировка цели, задач и требований к системе автоматизации	13
Глава 3. Разработка методики автоматизированного прогнозирования	15
3.1. Архитектура системы автоматизации.....	15
3.2. Предобработка и подготовка данных	17
3.3. Выбор и обучение моделей прогнозирования	20
3.4. Создание AutoML / ML-пайплайна.....	22
3.5. Система валидации и мониторинга моделей	23
Глава 4. Экспериментальная часть.....	26
4.1. Описание используемого датасета.....	26
4.2. Анализ исходных данных.....	26

4.3. Реализация алгоритмов и получение прогнозов.....	27
4.4. Сравнение качества моделей	28
4.5. Внедрение автоматизированного решения	29
Заключение	32
Список использованных источников	35
Приложения	36

Введение

Современные предприятия функционируют в условиях высокой динамики рыночной среды, постоянного изменения спроса и усиления конкуренции. Эффективное управление процессами продаж и запасов требует точного понимания будущего спроса на продукцию и услуги, что делает прогнозирование продаж одним из ключевых инструментов стратегического и оперативного управления. Прогнозирование позволяет предприятиям принимать обоснованные решения в области планирования закупок, производства, логистики и маркетинга, снижая риски избыточных запасов или недопоставок. В условиях глобализации рынков, быстрого изменения потребительских предпочтений и влияния внешних факторов, таких как экономическая нестабильность или сезонные колебания, точность прогнозирования становится критически важной для обеспечения устойчивости и конкурентоспособности компании.

Исторически прогнозирование продаж опиралось на методы экспертной оценки и классические статистические модели временных рядов. Эти подходы, хотя и сохраняют актуальность, имеют существенные ограничения при анализе больших объёмов данных, сложных взаимосвязей между признаками и нестабильного спроса. Экспертные методы основаны на субъективной оценке специалистов и требуют значительных временных и интеллектуальных ресурсов, а классические статистические методы, такие как скользящее среднее, экспоненциальное сглаживание или модели ARIMA, ограничены в способности учитывать большое количество внешних факторов и сложные нелинейные зависимости.

Современные технологии машинного обучения и искусственного интеллекта открывают новые возможности для прогнозирования продаж, позволяя обрабатывать большие массивы данных, выявлять скрытые закономерности и моделировать сложные взаимодействия между признаками. Алгоритмы градиентного бустинга, случайного леса, нейронные сети и рекуррентные модели LSTM демонстрируют высокую точность прогнозов даже в условиях интермиттирующего спроса, сезонных колебаний и значительного количества категориальных и числовых признаков. Эти методы позволяют формировать как индивидуальные прогнозы для отдельных товаров, так и глобальные прогнозы на уровне категорий, регионов и всей продуктовой линейки, что обеспечивает гибкость и масштабируемость системы.

Однако внедрение современных моделей машинного обучения в практику требует решения ряда задач, связанных с автоматизацией процесса прогнозирования. Под автоматизацией понимается создание интегрированных систем, способных автоматически обрабатывать данные, генерировать признаки,

обучать модели, формировать прогнозы и обеспечивать их валидацию и мониторинг в реальном времени. Автоматизация обеспечивает воспроизводимость результатов, сокращает трудозатраты специалистов и позволяет своевременно реагировать на изменения в рыночной среде. Современные решения включают построение ML-пайплайнов, внедрение AutoML для автоматического выбора и оптимизации моделей, интеграцию с корпоративными информационными системами и настройку модулей мониторинга качества прогнозов.

Актуальность темы исследования определяется возрастающей потребностью бизнеса в точных и оперативных прогнозах продаж, а также необходимостью снижения человеческого фактора и ошибок при обработке больших объёмов данных. Многие компании сталкиваются с проблемой несоответствия плановых и фактических показателей продаж, что ведет к финансовым потерям, неэффективному управлению запасами и снижению качества обслуживания клиентов. Внедрение автоматизированных систем прогнозирования позволяет минимизировать эти риски и повысить эффективность работы предприятия на всех уровнях управления.

Целью настоящего исследования является разработка методики автоматизированного прогнозирования продаж на основе исторических данных, которая обеспечивает высокую точность прогнозов, воспроизводимость результатов и возможность интеграции в корпоративные бизнес-процессы. Для достижения данной цели необходимо решить следующие задачи: провести анализ предметной области и характеристику данных о продажах, определить ключевые факторы, влияющие на спрос, выбрать методы и алгоритмы прогнозирования, разработать архитектуру автоматизированной системы, реализовать ML-пайплайн с генерацией признаков, обучением моделей и их валидацией, а также провести экспериментальную проверку точности прогнозов и оценку эффективности предложенной методики.

Научная новизна работы заключается в комплексном подходе к автоматизации процесса прогнозирования продаж с использованием современных методов машинного обучения и систем AutoML, включающих автоматическую генерацию признаков, подбор моделей и гиперпараметров, а также интеграцию модулей мониторинга качества прогнозов. Предлагаемая методика позволяет объединить статистические и ML-подходы, что обеспечивает высокую точность прогнозов для различных категорий товаров, регионов и горизонтов прогнозирования.

Практическая значимость работы состоит в возможности применения разработанной методики в корпоративных информационных системах для планирования закупок, управления запасами, формирования маркетинговых стратегий и поддержки принятия управленческих решений на всех уровнях компании. Реализация автоматизированного процесса прогнозирования

способствует сокращению издержек, повышению качества обслуживания клиентов и укреплению конкурентных преимуществ предприятия на рынке.

Таким образом, проведение данного исследования позволяет не только обосновать необходимость автоматизации прогнозирования продаж и выявить современные подходы к её реализации, но и создать практическое решение, способное повысить точность прогнозов, ускорить процесс их получения и интегрировать результаты в бизнес-процессы компании, обеспечивая устойчивое развитие и повышение эффективности управления продажами.

Глава 1. Теоретические основы прогнозирования продаж

1.1. Понятие и роль прогнозирования в бизнес-процессах

Прогнозирование продаж представляет собой систематический процесс оценки будущих объёмов реализации продукции на основе анализа исторических данных, выявления закономерностей и учёта влияния внешних факторов. Оно играет ключевую роль в бизнес-процессах, поскольку напрямую влияет на принятие управленческих решений, планирование закупок, управление запасами, финансовое планирование и формирование маркетинговой стратегии.

Прогнозирование позволяет компаниям снижать риски, связанные с неопределённостью рынка, оптимизировать ресурсы и минимизировать издержки. Точные прогнозы помогают избежать как дефицита товаров, так и избыточных запасов, что повышает эффективность работы предприятия и удовлетворённость клиентов. В стратегическом аспекте прогнозирование продаж способствует выявлению долгосрочных тенденций, пониманию сезонных колебаний спроса, влияния макроэкономических условий и поведения конкурентов. В оперативной сфере прогнозирование обеспечивает своевременное принятие решений по закупкам, корректировке цен, проведению маркетинговых кампаний и управлению цепочками поставок.

Прогнозирование также играет важную роль в планировании финансовых потоков, распределении бюджета и оценке эффективности бизнес-процессов. Компании, использующие точные и регулярные прогнозы, получают возможность более точно оценивать будущие доходы, формировать планы инвестиций и принимать решения о расширении производственных мощностей или диверсификации ассортимента.

1.2. Методы прогнозирования продаж

Методы прогнозирования продаж традиционно делятся на два больших направления: статистические методы и методы экспертного оценивания. Статистические методы основываются на анализе исторических данных и выявлении закономерностей во временных рядах. Классические методы включают скользящее среднее, экспоненциальное сглаживание, модели ARIMA и SARIMA. Эти методы позволяют учитывать сезонные колебания, тренды и циклические изменения спроса. Скользящее среднее и экспоненциальное сглаживание просты в реализации и обеспечивают быстрые прогнозы, однако имеют ограничения при наличии сильной нестабильности данных и внешних факторов. Модели ARIMA и SARIMA более гибкие, позволяют учитывать автокорреляцию и сезонность, однако требуют детальной настройки параметров и чувствительны к шуму в данных.

Экспертные методы основаны на субъективной оценке специалистов, включают методы дельфи, мозгового штурма и экспертных опросов. Они полезны в ситуациях, когда исторические данные ограничены или рынок характеризуется высокой динамикой, а также для оценки влияния новых факторов, для которых нет исторических аналогов. Недостатком экспертных методов является их субъективность и зависимость от опыта специалистов.

Современные методы прогнозирования включают алгоритмы машинного обучения, которые позволяют учитывать большое количество факторов и выявлять сложные нелинейные зависимости между ними. Алгоритмы градиентного бустинга, случайного леса, нейронные сети и рекуррентные модели LSTM позволяют получать более точные прогнозы в условиях нестабильного спроса и наличия множества внешних факторов. Эти методы способны автоматически выявлять значимые признаки, строить ансамбли моделей и обрабатывать большие объёмы данных, что делает их особенно актуальными для современных предприятий с большим ассортиментом товаров и распределённой сетью продаж.

1.3. Машинное обучение в прогнозировании временных рядов

Машинное обучение представляет собой подход к построению моделей, основанный на выявлении закономерностей и зависимости целевой переменной от признаков без явного задания формулы. В прогнозировании временных рядов машинное обучение позволяет учитывать сложные взаимосвязи между историческими продажами, сезонностью, календарными и внешними факторами, которые традиционные статистические методы учитывать не могут.

Процесс применения машинного обучения в прогнозировании временных рядов включает несколько этапов: подготовку и очистку данных, создание признаков, обучение модели, валидацию, прогнозирование и интеграцию результатов в бизнес-процессы. Важной частью является генерация признаков, включающая временные лаги, скользящие статистики, календарные признаки и внешние факторы, такие как погодные условия или промо-акции. Нейросетевые модели, включая LSTM и GRU, способны выявлять долгосрочные зависимости и учитывать последовательности данных, что особенно важно для товаров с сезонным или интермиттирующим спросом.

Машинное обучение позволяет создавать как индивидуальные модели для отдельных SKU, так и глобальные модели для целых категорий товаров, что повышает точность прогнозов и снижает необходимость ручной настройки. Важным преимуществом является возможность построения ансамблей моделей, когда результаты нескольких алгоритмов комбинируются для улучшения точности прогнозов.

1.4. Подходы к автоматизации прогнозирования

Автоматизация процесса прогнозирования продаж является логическим продолжением использования статистических и машинно-обучающих методов. Основной целью автоматизации является снижение трудозатрат, повышение воспроизводимости и стабильности прогнозов, а также обеспечение оперативного обновления моделей при поступлении новых данных.

Современные подходы к автоматизации включают построение ML-пайплайнов, применение систем AutoML, интеграцию моделей с корпоративными информационными системами и внедрение модулей мониторинга качества прогнозов. Автоматизированный пайплайн позволяет последовательно выполнять очистку данных, генерацию признаков, обучение моделей, прогнозирование и визуализацию результатов без постоянного вмешательства специалистов. AutoML обеспечивает автоматический подбор моделей, оптимизацию гиперпараметров и построение ансамблей, что повышает точность прогнозов и сокращает время на эксперименты.

Важным элементом автоматизации является интеграция прогнозов в бизнес-процессы. Это включает предоставление прогнозов отделам закупок, маркетинга и логистики, отображение их в BI-панелях, а также настройку системы оповещений о критических изменениях качества моделей. Такой подход позволяет поддерживать актуальность прогнозов, минимизировать ошибки и повышать эффективность принятия управленческих решений. Автоматизация прогнозирования продаж создаёт гибкую, масштабируемую и воспроизводимую систему, способную адаптироваться к изменениям рынка и обеспечивать поддержку стратегического и оперативного планирования.

Глава 2. Анализ предметной области и постановка задачи

2.1. Характеристика данных о продажах

Данные, используемые для прогнозирования продаж, представляют собой совокупность записей транзакционного и справочного характера, объединённых временным индексом. В типичном корпоративном хранилище каждый элемент наблюдения содержит дату или временную метку продажи, идентификатор товарной позиции (SKU), наименование группы или категории, идентификатор точки продаж (магазин, склад, онлайн-канал), количество реализованных единиц, суммарную выручку, цену за единицу, а также код метода оплаты и сведения о возвратах. Наряду с этими базовыми полями часто доступны метаданные о промоакциях (тип акции, скидка, период проведения), остатках на складе, закупочных ценах, сроках поставок и данных о ценовой политике. Для повышения качества прогнозов целесообразно интегрировать внешние источники: календарь праздников и специальных событий, погодные данные по регионам, маркетинговые метрики (расходы на рекламу, охваты), данные о конкурентных ценах и макроэкономические индикаторы, такие как индекс потребительских цен и показатели безработицы, если они релевантны для рассматриваемой товарной категории.

Качество исходных данных и их периодичность являются ключевыми характеристиками. Исторические ряды могут иметь различную частоту: дневную, недельную, месячную. Для розничной торговли чаще используются дневные или недельные наблюдения, тогда как для оптовых контрактов и B2B-сделок характерна редкая и нерегулярная частота. Важным свойством является полнота данных: пропуски появляются из-за сбоев в учёте, смены систем учёта или реструктуризации товарного каталога. Кроме того, в данных нередко встречаются выбросы, связанные с единичными крупными поставками, ошибками ввода или коллективными акциями. Для построения устойчивых моделей необходимо описать структуру NULL-значений, динамику изменения объёма записей во времени и соотношение между уровнями агрегации: SKU → категория → категория уровня выше. Наконец, требуется оценка объёма исторических данных — число записей, период наблюдения и доля товарных позиций с достаточной историей (например, более 12–24 месяцев), поскольку для многих алгоритмов машинного обучения и статистических моделей требуется минимальная длина ряда для выявления сезонных и трендовых компонент.

2.2. Факторы, влияющие на объёмы продаж

Объёмы продаж формируются под воздействием комплекса взаимосвязанных внутренних и внешних факторов, определяющих структуру спроса, характер поведения потребителей, динамику рыночной конъюнктуры и доступность товаров. Внутренние факторы обычно находятся под прямым контролем

предприятия и включают ценовую политику, маркетинговую активность, управление ассортиментом, логистику и политику запасов. Изменения в уровне розничной цены способны существенно влиять на наблюдаемую динамику продаж, поскольку ценовая эластичность спроса для разных категорий товаров выражена по-разному и требует учёта в моделях. Наличие скидок и промоакций формирует краткосрочные колебания спроса, и при этом важно учитывать не только факт снижения цены, но и детальные характеристики акции: глубину скидки, длительность, тип продвижения, наличие подарков или бонусных программ. Промоактивность, ориентированная на расширение аудитории, может приводить к изменению структуры потребителей и переходу части спроса в новые каналы продаж, что необходимо фиксировать в данных.

Ассортиментная политика также оказывает значительное влияние, поскольку появление новых SKU, вывод старых товаров, объединение или разделение товарных групп меняют структуру продаж и могут приводить к появлению разрывов в данных. Кроме того, качество логистики и своевременность поставок определяют уровень товарной доступности. Часто реальные продажи ограничены не спросом, а отсутствием товара на полке или на складе; такие ситуации формируют так называемый «lost sales», которые не отражены в данных, но искажают реальную картину потребительского спроса. В результате информация о минимальных остатках, перебоях поставок, сроках доставки и распределении запасов между каналами становится важным компонентом фактического спроса и должна учитываться в аналитической системе.

К внешним факторам относятся сезонные и календарные эффекты, отражающие устойчивую циклическую природу спроса. Они проявляются в виде роста продаж в определённые сезоны года или в связи с календарными событиями: праздниками, корпоративными распродажами, спортивными мероприятиями и иными социально значимыми периодами. Сезонность может быть как длительной (годовой), так и краткосрочной (недельной), и её структура различается по товарным категориям. Погодные условия влияют на спрос на одежду, продукты питания, товары для отдыха и бытовые товары. Температура, осадки, уровень влажности и погодные аномалии способны вызывать как всплески, так и падения продаж, при этом эффект зависит от региона, времени года и социально-экономических характеристик потребителей.

Экономическая среда формирует макроуровневые тенденции спроса. Колебания доходов населения, уровень инфляции, изменения процентных ставок, рост безработицы, введение ограничительных мер или стимулирующих программ могут изменять структуру потребления и предпочтения покупателей. Конкурентная ситуация также оказывает ощутимое влияние: изменение цен конкурентами, вывод новых товаров, расширение маркетинговых кампаний, появление новых точек продаж или онлайн-платформ приводит к перераспределению спроса. Наконец, существенное значение имеют регуляторные факторы — изменения в налогообложении, санитарных нормах,

правилах торговли, таможенных тарифах, которые могут изменять стоимость продукции, требования к её маркировке и структуру цепочки поставок.

Учитывая многообразие факторов, задача аналитика состоит в том, чтобы корректно выделить релевантные переменные, оценить их значимость и способ включения в модель прогнозирования. Факторы могут быть статичными, динамическими, линейными, нелинейными, проявляющимися с задержкой либо формирующими длительный тренд. Задача усложняется взаимосвязями между факторами: рост спроса, вызванный скидками, может совпадать с сезонным подъёмом; погода может влиять на эффективность промоакций; конкурентные действия могут накладываться на макроэкономическую нестабильность. Таким образом, точное прогнозирование требует комплексного анализа факторов и построения признаков, отражающих как прямое, так и косвенное влияние условий продаж.

2.3. Формулировка цели, задач и требований к системе автоматизации

Целью данного исследования является разработка научно обоснованной методики автоматизации процесса прогнозирования продаж, обеспечивающей устойчивое качество прогнозов, возможность масштабирования под различные товарные категории и гибкость при интеграции в текущие информационные системы предприятия. Предлагаемая система должна обеспечить непрерывность, воспроизводимость и прозрачность процедур подготовки данных, обучения моделей, валидации и мониторинга качества прогнозов, создавая единый управляемый контур для аналитической деятельности.

Для достижения поставленной цели формулируются следующие исследовательские задачи. Первая задача состоит в анализе структуры и качества исторических данных, определении обязательных атрибутов транзакций и справочной информации, а также выявлении проблемных элементов данных — пропусков, выбросов, нестыковок между источниками, различий в форматах и периодичности. Вторая задача направлена на исследование применимых методов прогнозирования и выбор наиболее подходящих алгоритмов для условий предприятия с учётом ограничений длины временных рядов, выраженности сезонности, чувствительности к внешним факторам и количества SKU. Третья задача заключается в разработке процедур преобразования и обогащения данных, включая очистку, нормализацию, агрегацию, генерацию новых признаков и подготовку обучающих выборок для различных горизонтов прогнозирования. Четвёртая задача связана с построением архитектуры автоматизированного пайплайна, охватывающего этапы ETL, обучение моделей, периодическую переоценку качества и управляемое обновление моделей. Пятая задача предполагает разработку комплекса метрик, формализующих качество прогнозов как с точки зрения математической точности, так и с позиции бизнес-ценности. Шестая задача включает оценку экономического эффекта от внедрения автоматизированного прогнозирования, что позволит обосновать

целесообразность проекта и спрогнозировать влияние улучшенной точности на уровень запасов, скорость оборачиваемости и потери от отсутствия товара.

На основе поставленных задач формируются требования к системе. Функциональные требования предусматривают возможность автоматического получения данных из разнородных источников, корректную идентификацию товарных позиций, унификацию форматов, формирование витрин данных, запуск регулярного обучения моделей и генерацию прогнозов в заданные временные интервалы. Система должна обеспечивать возможность использования различных моделей прогнозирования, их сравнения, выбора оптимальных и хранения версий для целей аудита. Важным функциональным компонентом является мониторинг качества моделей, включающий выявление деградации прогнозов, отслеживание дрейфа данных, анализ метрик и автоматическое уведомление ответственных специалистов при значительном отклонении фактических продаж от предсказаний.

Нефункциональные требования включают надёжность, отказоустойчивость, стабильное время отклика и способность к масштабированию при увеличении числа товарных позиций или расширении частоты расчётов. Система должна обеспечивать безопасность данных, соблюдение требований к конфиденциальности и соблюдение внутренних корпоративных политик по хранению и обработке информации. Значимой является требование к прозрачности — возможность отслеживать происхождение данных, трассировку этапов обработки, документирование моделей и их параметров. Система также должна быть удобной для пользователей и предоставлять доступ к прогнозам через API, отчёты или интеграцию с BI-панелями. Завершая постановку задачи, формулируются критерии успешности проекта: повышение точности прогнозирования по сравнению с текущими методами, снижение потерь и избыточных запасов, сокращение времени подготовки прогнозов, а также положительные результаты пилотной эксплуатационной проверки.

Глава 3. Разработка методики автоматизированного прогнозирования

3.1. Архитектура системы автоматизации

Архитектура автоматизированной системы прогнозирования продаж представляет собой совокупность взаимосвязанных компонентов, обеспечивающих полный цикл работы с данными: от их сбора и очистки до выдачи прогнозов и мониторинга моделей в реальном времени. При проектировании архитектуры необходимо учитывать особенности предметной области, требования к надёжности и масштабируемости, а также необходимость интеграции с существующими корпоративными сервисами. В современных организациях система прогнозирования должна функционировать как часть единой цифровой экосистемы, обеспечивая автоматическую обработку больших массивов исторических данных, поддержку сложных алгоритмов машинного обучения, возможность масштабирования под растущие объёмы данных и высокий уровень отказоустойчивости.

Одним из ключевых принципов построения такой архитектуры является модульность. Каждый модуль системы выполняет строго определённую функцию и может развиваться независимо от других компонентов. Это позволяет легко модернизировать отдельные части платформы — например, заменять используемые алгоритмы на более современные, менять систему хранения данных или внедрять новые каналы загрузки информации — без необходимости перестраивать всю архитектуру. Кроме того, модульность обеспечивает гибкость: в зависимости от потребностей бизнеса проект может быть развернут в облаке, на локальных серверах предприятия или в гибридном варианте.

На нижнем уровне архитектуры располагаются источники данных, которые могут быть как внутренними, так и внешними. К внутренним источникам относятся системы управления продажами, складскими запасами, логистикой, кассовые терминалы, ERP и CRM-системы, а также маркетинговые платформы и системы управления промо-активностями. Внешние источники могут включать данные о погодных условиях, официальную экономическую статистику, индексы потребительской активности, данные о поведении покупателей в онлайне, сведения о праздничных и специальных событиях. Важно обеспечить единый механизм подключения данных, поддерживающий как потоковые (streaming), так и пакетные (batch) методы передачи информации. При проектировании архитектуры следует предусмотреть инструменты обработки ошибок, дедупликации данных и восстановления после сбоев.

Над уровнем источников данных располагается слой интеграции и предварительной обработки — ETL/ELT. В его задачи входит приём данных, проверка их структуры и качества, нормализация, стандартизация форматов и

синхронизация различных источников данных между собой. На данном этапе выполняется согласование справочников: например, названий товаров, кодов SKU, идентификаторов магазинов и регионов. ETL-пайплайн должен обеспечивать возможность инкрементальной загрузки данных, чтобы система могла работать в режиме, близком к реальному времени, без необходимости повторной полной обработки всего массива данных. Для обеспечения высокой надёжности пайплайны сопровождаются системой логирования, уведомлений и автоматического повторного запуска в случае ошибок.

Следующий компонент архитектуры — хранилище данных. Оно может быть организовано по принципу двухуровневой структуры: "озера данных" (data lake) для хранения необработанных массивов и data warehouse для хранения структурированных, очищенных и агрегированных данных, готовых к использованию моделями. Такая схема обеспечивает гибкость: вместо жёсткой структуры базы данных организация получает возможность хранить данные в их первичном виде, использовать их для последующего анализа, переобучения моделей и построения новых признаков. На уровне data warehouse создаются витрины данных: тематические наборы, структурированные под удобное использование процессами моделирования. Например, витрина "Продажи по дням" или "Промо-активности" может содержать агрегированные данные, необходимые для обучения моделей прогнозирования спроса.

Важную роль в архитектуре играет сервис хранения признаков — feature store. Он предназначен для стандартизации процессов генерации признаков, их хранения, повторного использования, версионирования и синхронизации между обучением и эксплуатацией моделей. Feature store гарантирует, что модель в продакшне работает с теми же признаками, что и при обучении, что критически важно для стабильности прогнозирования. Признаки, такие как лаги продаж, показатели сезонности, агрегированные статистики или данные о промо, сохраняются в feature store вместе с метаданными и историей вычисления. Это также позволяет разным моделям использовать повторно вычисленные признаки, что существенно снижает нагрузку на инфраструктуру.

Центральным элементом архитектуры является модуль обучения и экспериментирования. Он должен поддерживать различные фреймворки машинного обучения, предоставлять инструменты для отслеживания экспериментов, фиксирования параметров, метрик и артефактов моделей. Немаловажной частью этой подсистемы является система распределённых вычислений, которая позволяет параллельно обучать несколько моделей или оптимизировать гиперпараметры. Наличие специализированного окружения для экспериментов позволяет автоматизировать сравнение результатов и сохранять лучшие модели в реестр моделей — model registry.

Элемент model registry играет роль системы контроля версий моделей, где фиксируются все параметры обучения, наборы данных, конфигурации

признаков, метрики, результаты валидации и дополнительные артефакты. Это позволяет не только отслеживать историю улучшений, но и в любой момент восстановить модель, использованную в продакшене. При развертывании модели system registry предоставляет API, через которое система сервинга моделей выбирает нужную версию модели, проверяет её статус и управляет процессом вывода в эксплуатацию.

Сервис выдачи прогнозов (model serving) реализует функциональность предоставления прогнозов в режиме пакетной обработки и в режиме реального времени. В пакетном варианте прогнозы могут генерироваться ежедневно, еженедельно или ежемесячно и загружаться в корпоративные системы планирования закупок или управления запасами. В онлайн-режиме прогнозы могут использоваться, например, в e-commerce для отображения ожидаемой даты доставки или для динамической оптимизации ассортимента. Сервис сервинга должен быть масштабируемым, обеспечивать низкую задержку при обработке запросов и поддерживать работу нескольких моделей параллельно.

Важнейшей частью архитектуры является система мониторинга и контроля. Она отслеживает не только метрики качества и точности прогнозов, но и технические характеристики работы системы: нагрузки, задержки, ошибки, потребление ресурсов. Кроме того, мониторинг включает контроль дрейфа данных и дрейфа модели, обнаружение аномалий и оценку стабильности признаков. Для предотвращения деградации качества прогнозов архитектура должна предусматривать механизмы автоматического или полуавтоматического переобучения модели, а также возможность безопасного развёртывания обновлённых моделей через канареечные релизы или теневое тестирование.

Завершающим элементом архитектуры является система оркестрации процессов, которая управляет расписанием, зависимостями и логикой выполнения всех задач: обновлением данных, обучением моделей, генерацией прогнозов и контрольными процедурами мониторинга. Благодаря оркестрации обеспечивается согласованная и непрерывная работа всей системы, гарантируется воспроизводимость её работы и возможность масштабирования при увеличении объёма данных и сложности моделей.

3.2. Предобработка и подготовка данных

Предобработка и подготовка данных являются фундаментальными этапами разработки автоматизированной системы прогнозирования продаж, так как качество входных данных напрямую влияет на точность и стабильность моделей. В рамках данного этапа выполняются операции очистки, нормализации, трансформации, агрегации и обогащения данных внешними источниками, а также формирование признаков для обучения моделей. Все процедуры должны быть воспроизводимыми, документированными и интегрированными в общий ETL/ML-пайплайн.

1. Сбор и интеграция данных

Сбор данных начинается с идентификации всех релевантных источников. Источники делятся на внутренние и внешние. Внутренние включают системы продаж (POS), ERP и CRM-системы, склады и логистику, маркетинговые платформы, данные о промо-акциях и скидках. Внешние источники включают погодные данные, макроэкономические индикаторы, календарь праздников и событий, данные о действиях конкурентов, социальные и веб-метрики.

Интеграция данных требует согласования справочников (SKU, магазины, категории), стандартизации форматов времени и единиц измерения, устранения дубликатов и несоответствий между системами. Используются методы контроля целостности данных, например, сверка суммарных продаж по различным источникам, проверка уникальности идентификаторов и сопоставление исторических рядов. Для потоковых данных и событий реализуется механизм обработки потоков с очередями сообщений (Kafka, RabbitMQ), а для пакетной загрузки — периодические ETL-задания.

2. Очистка и обработка пропусков

Очистка данных включает удаление или исправление ошибок ввода, дубликатов и неконсистентных записей. Пропуски в данных анализируются по источникам и причинам появления. Временные пропуски короткой длительности корректируются с помощью интерполяции или заполнения скользящей медианой/средним. Длительные пропуски требуют либо агрегации данных на более крупном временном интервале (например, из дня в неделю), либо специальной обработки, учитывающей их влияние на модель.

Выбросы выявляются с использованием статистических методов (z-оценка, межквартильный диапазон) и алгоритмов детекции аномалий. Важным является принятие решения, как поступать с выбросами: корректировать значения, удалять их или сохранять с пометкой для последующего анализа. При этом необходимо сохранять бизнес-контекст, чтобы система могла учитывать сезонные и разовые события.

3. Агрегация и ресемплинг

Для построения моделей прогнозирования часто требуется агрегация данных по временным интервалам и уровням иерархии: SKU → категория → регион → сеть магазинов. В зависимости от частоты исторических данных (день, неделя, месяц) производится ресемплинг, а также формируются агрегированные показатели: средние продажи, медиана, стандартное отклонение, максимальные и минимальные значения.

Для прогнозирования на разных горизонтах (неделя, месяц, квартал) создаются скользящие окна и агрегации, которые позволяют модели выявлять тренды и сезонные паттерны. При этом важно учитывать временные лаги и корреляции между уровнями иерархии, чтобы сохранить согласованность прогнозов между SKU и агрегированными категориями.

4. Генерация признаков

Признаки (features) являются ключевым элементом качества модели. Они делятся на следующие группы:

Временные признаки: лаги продаж ($t-1$, $t-7$, $t-30$), скользящие средние, скользящие медианы, скользящее стандартное отклонение, индикаторы тренда.

Сезонные и календарные признаки: день недели, месяц, квартал, праздничные дни, распродажи, смена сезонов.

Внешние признаки: погодные показатели (температура, осадки), макроэкономические индикаторы (ИПЦ, курс валют, уровень безработицы), маркетинговые метрики (охват рекламы, расходы на кампании).

Признаки промо-акций: тип акции, глубина скидки, длительность, история предыдущих акций.

Иерархические и агрегированные признаки: средние продажи по категории, региону, каналу, кросс-SKU корреляции (заменители и комплементы).

Важным является управление связью между офлайн-признаками и онлайн-прогнозами. Для предотвращения утечки информации при обучении модели используется строгая логика временных лагов, чтобы значения будущих продаж или промо-акций не попадали в признаки обучающих данных.

5. Кодирование и нормализация

Категориальные признаки кодируются с помощью методов, подходящих для конкретных алгоритмов: порядковое кодирование, target-encoding с регуляризацией, one-hot или embedding для нейросетевых моделей. Числовые признаки нормализуются для стабильности обучения: стандартная нормализация, логарифмирование или Вох-Сох-преобразование для сильно скошенных распределений. Для товаров с интермиттирующим спросом применяются специализированные подходы, включая моделирование вероятности покупки и ожидаемого объёма.

6. Обогащение данных внешними источниками

Обогащение данных внешними источниками позволяет моделям учитывать экзогенные факторы. Например, погодные данные агрегируются по регионам и дате, макроэкономические показатели корректируются с учётом временного лага, маркетинговые расходы соотносятся с периодами кампаний. Такое обогащение улучшает способность моделей предсказывать нестандартные всплески и падения спроса.

7. Воспроизводимость и управление версиями

Все этапы предобработки реализуются в виде пайплайна с версионированием данных и кода. Используются инструменты автоматизации (Airflow, Kubeflow Pipelines, Prefect) для запуска ETL-процессов и обработки ошибок. Feature store обеспечивает единый источник признаков для офлайн-обучения и онлайн-сервинга, что гарантирует стабильность прогнозов и воспроизводимость результатов.

3.3. Выбор и обучение моделей прогнозирования

Выбор и обучение моделей прогнозирования представляют собой центральный этап разработки автоматизированной системы, поскольку именно на этом уровне реализуются алгоритмы, способные предсказывать будущие продажи с высокой точностью. На первом этапе проводится анализ характеристик данных и определяются требования к прогнозу, включая горизонты предсказаний, допустимые ошибки и бизнес-ограничения. Основываясь на этих требованиях, осуществляется выбор подходящего класса моделей. В зависимости от свойств данных и цели прогнозирования могут использоваться классические статистические модели, методы машинного обучения или нейросетевые архитектуры. Классические модели, такие как скользящее среднее, экспоненциальное сглаживание и ARIMA/SARIMA, подходят для рядов с выраженной сезонностью, относительно стабильной историей и небольшим числом экзогенных переменных. Их преимущество заключается в высокой интерпретируемости, что позволяет выделять тренд, сезонность и остаточную ошибку, обеспечивая аналитическую прозрачность для бизнес-пользователей. Методы машинного обучения, включая ансамбли деревьев решений и линейные модели с регуляризацией, позволяют эффективно учитывать большое количество признаков, сложные нелинейные взаимосвязи, внешние факторы и агрегированные характеристики. Эти модели устойчивы к шуму и позволяют моделировать влияние промо-акций, сезонных эффектов и взаимодействие между SKU. Нейросетевые модели, включая рекуррентные сети LSTM и GRU, свёрточные сети для временных рядов и трансформеры, дают возможность выявлять длительные и сложные зависимости, учитывать многомерные временные ряды и экзогенные признаки. Такие модели особенно эффективны для больших наборов данных, но требуют значительных вычислительных ресурсов и тщательной настройки гиперпараметров. Для товаров с интермиттирующим спросом, где наблюдается большое количество нулевых

продаж, используются специализированные модели, такие как двухкомпонентные алгоритмы, которые отдельно моделируют вероятность покупки и ожидаемый объём, включая модификации метода Croston.

Процесс обучения моделей строится с учётом временной структуры данных. Классическая кросс-валидация не применима, так как она нарушает хронологию временного ряда, поэтому используются схемы time series cross-validation с последовательными тренировочными и тестовыми наборами, которые обеспечивают корректную оценку способности модели к обобщению. При обучении моделей машинного обучения и нейросетей особое внимание уделяется выбору функции потерь. Средняя абсолютная ошибка (MAE) и корень из среднеквадратичной ошибки (RMSE) применяются для минимизации абсолютных и крупных ошибок, а относительные метрики, такие как MAPE или sMAPE, используются для сравнения моделей между разными товарами и категориями. Для бизнес-ориентированных задач могут применяться кастомные функции потерь, отражающие экономический эффект прогнозов, например, стоимость избыточных запасов или упущенной прибыли.

Гиперпараметры моделей оптимизируются с помощью различных методов, включая полный перебор, случайный поиск и адаптивные алгоритмы, такие как байесовская оптимизация или Hyperband. Для нейросетевых моделей дополнительно подбираются архитектура, глубина сети, количество нейронов, learning rate, batch size и регуляризация, чтобы минимизировать переобучение и повысить стабильность прогнозов. При работе с большим числом товарных позиций часто используются глобальные модели, обучаемые на объединённых рядах всех SKU. Такой подход позволяет выявлять общие закономерности, сокращает объём данных, необходимый для обучения отдельных моделей, и повышает стабильность прогнозов. Для согласованности прогнозов между уровнями иерархии, например, SKU и категории, применяются методы reconciliation, обеспечивающие, чтобы сумма прогнозов на нижнем уровне совпадала с прогнозом на агрегированном уровне.

Обучение моделей сопровождается тщательной фиксацией всех параметров, метрик и экспериментальных результатов в системах управления экспериментами, таких как MLflow или Weights & Biases. Производится сравнение моделей с простыми базовыми методами, например naïve или сезонным naïve, для оценки добавочной ценности более сложных алгоритмов. Также проводится визуальный анализ остатков, проверка автокорреляций ошибок, оценка важности признаков и проверка устойчивости моделей на различных временных срезах. Для категорий с редким спросом применяются специализированные подходы, включая двухкомпонентное моделирование и индивидуальное дообучение глобальных моделей на отдельных SKU для повышения точности прогнозов. Все обученные модели сохраняются в model registry с указанием версии, метрик, набора признаков и временных границ

обучения, что обеспечивает воспроизводимость, прозрачность и управление жизненным циклом модели.

3.4. Создание AutoML / ML-пайплайна

Создание AutoML и ML-пайплайна является ключевым этапом автоматизации процесса прогнозирования продаж, так как именно здесь реализуется последовательная обработка данных, обучение моделей, генерация прогнозов и их интеграция в бизнес-процессы. Пайплайн обеспечивает воспроизводимость всех этапов работы, минимизирует человеческий фактор и позволяет масштабировать систему на большое количество SKU, категорий и регионов.

Процесс начинается с подготовки данных и их централизованного хранения. Сырые данные из ERP, CRM, POS-систем и внешних источников загружаются в единое хранилище, где проходит первичная очистка, проверка на пропуски и аномалии, стандартизация форматов и кодирование категориальных признаков. После этого данные поступают в слой генерации признаков, где формируются временные лаги, скользящие средние, статистики, календарные и сезонные индикаторы, а также внешние признаки, влияющие на спрос. Эти признаки сохраняются в Feature Store — специализированной структуре данных, обеспечивающей единый источник признаков для всех моделей и упрощающей воспроизводимость прогнозов.

Следующий этап — настройка AutoML-системы. AutoML отвечает за автоматический выбор моделей, оптимизацию гиперпараметров и построение ансамблей моделей на основе исторических данных. В рамках пайплайна реализуется последовательное тестирование различных классов моделей: статистические алгоритмы (Holt-Winters, ARIMA/SARIMA), методы машинного обучения (LightGBM, XGBoost, CatBoost) и нейросетевые модели (LSTM, GRU, TCN, трансформеры для временных рядов). AutoML оценивает модели по заранее определённым метрикам качества (MAE, RMSE, sMAPE, MAPE) на валидационной выборке, автоматически выбирает наилучшую конфигурацию и создаёт ансамбли для повышения устойчивости прогнозов.

Особое внимание уделяется управлению гиперпараметрами и конфигурациями моделей. AutoML использует адаптивные методы оптимизации, включая байесовскую оптимизацию, случайный поиск и Hyperband, что позволяет эффективно находить оптимальные параметры при минимальных вычислительных затратах. Для нейросетевых моделей AutoML также подбирает архитектуру сети, количество слоёв и нейронов, learning rate, методы регуляризации и длину входной последовательности.

ML-пайплайн интегрирует этапы предобработки данных, генерации признаков и AutoML в автоматическую цепочку, где каждая стадия выполняется по расписанию или по событию. Для потоковых данных реализуется обработка

событий в реальном времени с использованием очередей сообщений и систем потоковой аналитики (Kafka, RabbitMQ), а для пакетной загрузки используется периодический ETL. Такой подход обеспечивает регулярное обновление прогнозов и поддерживает актуальность моделей при изменении спроса или структуры данных.

Важной частью пайплайна является валидация и мониторинг моделей. Система отслеживает качество прогнозов на текущих данных, дрейф распределений признаков и отклонения метрик, что позволяет выявлять деградацию моделей и вовремя инициировать их переобучение. Для этого используются статистические методы контроля качества, контрольные карты, а также метрики, рассчитанные на отдельных SKU, категориях и регионах. AutoML-пайплайн также фиксирует все версии данных, моделей и признаков в Model Registry, обеспечивая воспроизводимость и прозрачность работы системы.

Кроме того, пайплайн предусматривает интеграцию с внешними системами: прогнозы автоматически передаются в ERP и CRM для планирования закупок и управления запасами, а также отображаются в BI-панелях для анализа и поддержки принятия решений. Для повышения устойчивости и отказоустойчивости внедряются механизмы логирования, алертинга и автоматического отката к предыдущей версии модели в случае критических ошибок.

AutoML и ML-пайплайн позволяют также легко масштабировать систему на новые категории товаров, новые регионы и дополнительные источники данных. Добавление новых SKU или внешних признаков не требует ручной переработки всех этапов, так как пайплайн автоматически обрабатывает новые данные, обновляет признаки и выбирает оптимальные модели для прогнозирования.

В результате внедрения AutoML/ML-пайплайна достигается высокая точность прогнозов при минимальном участии специалистов, обеспечивается стабильность и воспроизводимость результатов, ускоряется цикл обновления прогнозов и повышается эффективность бизнес-процессов, связанных с управлением запасами, планированием закупок и прогнозированием спроса. Пайплайн создаёт гибкую и масштабируемую инфраструктуру, способную адаптироваться к изменяющимся условиям рынка, сезонным колебаниям и влиянию внешних факторов, что делает его ключевым элементом автоматизации прогнозирования продаж.

3.5. Система валидации и мониторинга моделей

Система валидации и мониторинга моделей является критически важным компонентом автоматизированного процесса прогнозирования продаж, так как именно она обеспечивает контроль качества прогнозов, устойчивость моделей к изменениям данных и своевременное обнаружение деградации их точности.

Валидация и мониторинг позволяют минимизировать риски ошибок в прогнозах, которые могут привести к избыточным запасам, упущенной прибыли или нарушению цепочек поставок.

Процесс начинается с этапа внутренней валидации моделей, который проводится ещё на стадии обучения и настройки алгоритмов. Для этого используется подход временной кросс-валидации, известный как *rolling window*, когда обучающие и тестовые выборки формируются последовательно во времени. Такой метод позволяет сохранять хронологию данных и избегать утечки информации о будущем в процесс обучения модели. Для оценки качества прогнозов применяются стандартные метрики, включая MAE, RMSE, MAPE и sMAPE, а также дополнительные метрики, учитывающие бизнес-ценность прогнозов, такие как экономический эффект недопродаж или избыточных запасов.

Кроме метрик точности, система валидации анализирует распределение остатков моделей. Остатки проверяются на автокорреляцию, наличие сезонных паттернов и аномальные отклонения, что позволяет выявить недооцененные тренды или некорректно учтённые внешние факторы. Важной частью является визуальный контроль прогнозов: строятся графики фактических и предсказанных продаж, распределение ошибок, тепловые карты отклонений по SKU и регионам. Такая визуализация облегчает интерпретацию работы моделей бизнес-пользователями и позволяет выявлять систематические ошибки, которые могут быть незаметны на уровне агрегированных метрик.

Мониторинг моделей включает в себя непрерывное отслеживание их производительности после внедрения. Система фиксирует значения ключевых метрик прогнозирования для всех SKU, категорий и регионов и сравнивает их с историческими результатами, чтобы выявить дрейф модели или деградацию точности. Особое внимание уделяется мониторингу изменений в распределении признаков (*feature drift*) и распределении целевой переменной (*target drift*), поскольку такие изменения могут снижать качество прогнозов даже при стабильной архитектуре модели. Для обнаружения дрейфа применяются статистические методы, такие как тесты Колмогорова-Смирнова и Chi-Square для категориальных и числовых признаков, а также контрольные карты и скользящие окна для анализа распределений.

Система мониторинга также предусматривает автоматическое уведомление пользователей о критических событиях. В случае, если точность прогнозов падает ниже заданного порога или выявляются значительные отклонения в распределении данных, генерируются алерты и уведомления ответственным специалистам, что позволяет своевременно инициировать переобучение моделей или вмешательство экспертов. Дополнительно предусмотрены механизмы отката к предыдущим версиям моделей, сохранённым в Model Registry, что обеспечивает отказоустойчивость и непрерывность работы системы.

Для повышения прозрачности и доверия к прогнозам реализуются инструменты интерпретации моделей. Для методов машинного обучения и нейросетевых моделей рассчитываются важности признаков (feature importance), строятся графики SHAP-значений, позволяющие определить влияние отдельных признаков на прогнозы. Это особенно важно при принятии управленческих решений, так как позволяет объяснить бизнес-аналитикам причины изменения прогнозов и корректировать стратегию планирования.

Мониторинг моделей интегрируется с корпоративными системами, включая BI-платформы, ERP и CRM. Это позволяет не только отслеживать метрики качества, но и визуализировать прогнозы, отклонения и ошибки в реальном времени, обеспечивая оперативное принятие решений на уровне управления запасами и планирования закупок. Для обеспечения масштабируемости и стабильности работы пайплайн мониторинга использует облачные и потоковые технологии обработки данных, что позволяет одновременно отслеживать сотни или тысячи SKU и категорий без снижения производительности.

Таким образом, система валидации и мониторинга моделей обеспечивает комплексный контроль качества прогнозов на всех этапах: от обучения и внутренней валидации до эксплуатации моделей в реальном времени. Она фиксирует все версии данных, признаков и моделей, отслеживает изменения в данных и метрики качества, уведомляет о критических отклонениях и предоставляет инструменты интерпретации прогнозов. Это позволяет поддерживать высокую точность прогнозирования, адаптироваться к изменениям рынка и бизнес-условий и минимизировать риски, связанные с использованием автоматизированной системы прогнозирования продаж.

Глава 4. Экспериментальная часть

4.1. Описание используемого датасета

Для проведения экспериментов был использован комплексный набор исторических данных о продажах за период более двух лет, охватывающий более тысячи SKU в различных категориях товаров, распределённых по более чем ста точкам продаж в нескольких регионах. Датасет включал следующие ключевые признаки: уникальный идентификатор товара, дату транзакции, количество проданных единиц, цену продажи, категорию и подкатеорию товара, идентификатор торговой точки, остаток на складе на момент продажи, наличие и тип промо-акции.

Кроме внутренних данных о продажах и остатках, датасет был дополнен внешними источниками: погодными данными (температура, осадки, влажность) по регионам, календарём праздничных и выходных дней, макроэкономическими индикаторами (ИПЦ, курс валют, уровень потребительской активности), а также информацией о маркетинговых кампаниях и акциях конкурентов. Данные внешних источников агрегировались по регионам и датам, чтобы их можно было интегрировать с внутренними данными о продажах.

Перед проведением анализа все данные были стандартизированы. Даты были приведены к единому формату, цены — к одной валюте, а единицы измерения остатков и продаж — к общепринятому виду. Пропущенные значения в количественных признаках были заполнены интерполяцией или медианными значениями по схожим SKU, а категориальные признаки — с использованием наиболее частых значений или категории «неизвестно». Были удалены полностью дублирующиеся записи и исправлены неконсистентные коды товаров и магазинов.

Для организации работы с данными была подготовлена многослойная структура хранения. В «озере данных» (data lake) хранились сырые, необработанные данные, а в «хранилище данных» (data warehouse) — агрегированные и очищенные витрины по категориям, регионам, каналам продаж и временным интервалам. Это обеспечивало возможность быстро формировать обучающие выборки, агрегированные признаки и витрины для моделей, а также повторно использовать обработанные данные для различных экспериментов.

Датасет был разбит на обучающую и тестовую выборки, при этом тестовая выборка представляла собой последние шесть месяцев исторических данных, что соответствовало реальному горизонту прогнозирования в бизнес-процессах компании. Также была выделена валидационная выборка для настройки гиперпараметров моделей и раннего выявления переобучения.

4.2. Анализ исходных данных

Анализ данных проводился в несколько этапов. Сначала была выполнена статистическая характеристика всех признаков: расчет среднего, медианы, стандартного отклонения, коэффициента вариации, минимальных и максимальных значений. Это позволило выявить экстремальные значения и определить распределение данных для разных категорий товаров и регионов. Были построены гистограммы распределения продаж, остатков на складе и цен для каждой категории, что позволило визуально оценить вариативность данных и выявить группы товаров с необычным поведением.

Временные ряды продаж были визуализированы по SKU, категориям и регионам, что позволило выявить тренды, сезонность и циклические колебания. Автокорреляционный анализ и спектральный анализ использовались для определения периодичности, выявления долгосрочных трендов и скрытых циклических паттернов. Для товаров с интермиттирующим спросом анализ показал высокую долю нулевых продаж, что потребовало применения специализированных подходов при обучении моделей и формировании признаков.

Также был проведён корреляционный анализ между продажами различных SKU и между признаками, включая внешние факторы. Были выявлены заменители и комплементарные товары, которые могли влиять на спрос, а также определены ключевые внешние факторы, такие как погодные условия, праздничные дни и маркетинговые кампании. Влияние этих факторов оценивалось с помощью регрессионного анализа и коэффициентов корреляции.

Кроме того, для оценки качества исходных данных использовались методы обнаружения аномалий. Были построены графики остатков после базовых моделей сезонного скользящего среднего и выявлены точки с необычными отклонениями. Все выявленные аномалии документировались и, при необходимости, корректировались с учетом бизнес-логики.

4.3. Реализация алгоритмов и получение прогнозов

Для построения прогностической системы был разработан пайплайн, включающий предобработку данных, генерацию признаков, обучение моделей, получение прогнозов и их сохранение. На этапе предобработки пропуски заполнялись интерполяцией или медианными значениями, выбросы корректировались с использованием межквартильного метода и анализа остатков. Категориальные признаки кодировались с помощью one-hot и target-encoding, числовые признаки нормализовались и масштабировались.

Генерация признаков включала создание лагов продаж ($t-1$, $t-7$, $t-30$), скользящих средних и стандартных отклонений, календарных признаков (день недели, месяц, квартал, праздничные дни), а также внешних признаков (температура, осадки, ИПЦ, промо-акции). Для нейросетевых моделей были подготовлены

последовательности временных рядов с заданной длиной окна, что позволяло обучать рекуррентные сети на исторических последовательностях.

Были реализованы три направления моделей. Классические статистические модели, включая Holt-Winters и ARIMA/SARIMA, учитывали сезонность и тренд, обеспечивая базовую интерпретируемую прогнозную основу. Методы машинного обучения, такие как LightGBM и XGBoost, позволяли учитывать сложные нелинейные взаимодействия признаков, кросс-эффекты и внешние факторы. Нейросетевые модели, включая LSTM и GRU, выявляли долгосрочные зависимости, учитывали многомерные признаки и взаимодействия между SKU. Для товаров с редким спросом использовались двухкомпонентные модели Croston, разделяющие вероятность продажи и ожидаемое количество.

Обучение моделей проводилось с использованием временной кросс-валидации (rolling window) и подбором гиперпараметров через байесовскую оптимизацию и случайный поиск. Для нейросетевых моделей дополнительно подбирались архитектура, количество слоёв и нейронов, learning rate, batch size и методы регуляризации (dropout, weight decay).

Реализация проводилась в среде Python с использованием pandas, numpy, scikit-learn, XGBoost, LightGBM, statsmodels, TensorFlow и Keras. Все этапы фиксировались в MLflow для обеспечения воспроизводимости экспериментов. Прогнозы сохранялись в стандартизированном формате, позволяющем их интеграцию в корпоративные BI-системы.

4.4. Сравнение качества моделей

Оценка моделей проводилась с использованием метрик MAE, RMSE, sMAPE и MAPE. Метрики рассчитывались на уровне SKU, категорий, регионов и каналов продаж, что позволяло оценивать качество моделей как на микро-, так и на макроуровне. Для визуального анализа строились графики фактических продаж и прогнозов, распределение ошибок и остатки моделей.

Статистические модели демонстрировали хорошую производительность на стабильных сезонных рядах, однако показывали низкую точность на интермиттирующих и шумных данных. Методы машинного обучения позволяли учитывать большое количество признаков и взаимодействий, что повышало точность прогнозов для сложных товаров. Нейросетевые модели выявляли долгосрочные тенденции и сложные паттерны, но требовали больших вычислительных ресурсов и долгого времени обучения.

Для SKU с редким спросом двухкомпонентные модели Croston показали наилучшие результаты, особенно при прогнозировании вероятности продажи.

Были проведены эксперименты по дообучению глобальных моделей на отдельных SKU, что улучшило точность прогнозов на микроуровне. Также оценивалось влияние различных комбинаций признаков и гиперпараметров на качество моделей, что позволило выделить оптимальные конфигурации для внедрения.

4.5. Внедрение автоматизированного решения

На основе экспериментов была разработана концепция внедрения автоматизированной системы. Пайплайн включает регулярное обновление данных, предобработку, генерацию признаков, обучение и валидацию моделей, получение прогнозов и публикацию их в корпоративные системы. Интеграция с ERP и CRM системами обеспечивает автоматическое планирование закупок, управление запасами и поддержку бизнес-решений. BI-системы используются для визуализации прогнозов, анализа отклонений и мониторинга эффективности моделей.

Система мониторинга отслеживает качество прогнозов, дрейф данных, отклонения признаков и ошибки моделей. Система алертинга уведомляет о критических изменениях в данных или снижении точности, что позволяет своевременно реагировать. Внедрение предполагает тестирование на ограниченном наборе SKU и регионов, с последующим масштабированием на весь ассортимент.

Жизненный цикл моделей управляется с помощью versioning, возможности отката к предыдущим версиям и ручной проверки прогнозов. Такая организация обеспечивает безопасное, эффективное и масштабируемое использование автоматизированной системы, снижает риск ошибок и повышает доверие пользователей к прогнозам.

Для полноценной реализации автоматизированного прогнозирования продаж необходима детальная формализация всех этапов обработки данных, генерации признаков, обучения моделей и оценки качества прогнозов. Основой эффективного прогноза являются корректно подготовленные данные. Исторические данные о продажах проходят централизованную очистку и стандартизацию, включающую заполнение пропусков, удаление дубликатов и исправление неконсистентных значений. Важно отметить, что для категориальных признаков применяется кодирование с использованием методов one-hot и target-encoding, а числовые признаки нормализуются и масштабируются для обеспечения устойчивости алгоритмов машинного обучения и нейросетевых моделей.

После очистки данных формируется комплекс признаков, отражающих динамику продаж. Применяются лаги временных рядов, скользящие статистики и показатели тенденций, которые позволяют модели учитывать прошлые

продажи при прогнозировании будущего спроса. Скользящие средние и стандартные отклонения рассчитываются для различных временных окон, что позволяет улавливать краткосрочные и долгосрочные колебания спроса. Кроме того, создаются календарные признаки, включая день недели, месяц, квартал и праздничные дни, а также внешние факторы, такие как погодные условия, экономические индикаторы и данные о маркетинговых активностях конкурентов. Все эти признаки интегрируются с основными данными и хранятся в едином Feature Store, что обеспечивает повторное использование и воспроизводимость результатов.

После формирования признаков данные разбиваются на обучающие и тестовые выборки с учётом временной структуры. Тестовая выборка формируется из последних месяцев исторических данных, что соответствует практическому горизонту прогнозирования. Обучение моделей проводится на обучающих данных с использованием различных подходов: классические статистические модели позволяют учитывать сезонность и тренд, методы машинного обучения выявляют сложные нелинейные зависимости между признаками и целевой переменной, а нейросетевые модели способны улавливать долгосрочные закономерности и взаимодействия между различными факторами. Для товаров с редким спросом применяются специализированные двухкомпонентные модели, которые разделяют вероятность продажи и ожидаемое количество, что позволяет повысить точность прогнозов для интермиттирующих временных рядов.

Для выбора оптимальной модели используется автоматизация через AutoML, которая обеспечивает тестирование различных алгоритмов, подбор гиперпараметров и построение ансамблей моделей. В процессе работы AutoML оценивает модели по метрикам MAE, RMSE, MAPE и sMAPE на валидационной выборке, автоматически выбирает наилучшие конфигурации и формирует ансамбли для повышения устойчивости прогнозов. Для нейросетевых моделей автоматизация включает подбор архитектуры сети, количества слоёв и нейронов, learning rate, методов регуляризации и длины входной последовательности. Такой подход позволяет минимизировать ручной труд, ускоряет процесс подбора оптимальных моделей и обеспечивает высокую точность прогнозов на различных SKU и категориях товаров.

Важным аспектом является контроль качества прогнозов и мониторинг моделей в реальном времени. После внедрения системы прогнозы постоянно оцениваются по ключевым метрикам, проводится проверка распределения признаков и целевой переменной, что позволяет выявлять дрейф модели и деградацию её точности. В случае выявления критических отклонений система автоматически уведомляет ответственных специалистов и при необходимости инициирует переобучение моделей или откат к предыдущей версии. Для анализа ошибок и интерпретации результатов используются графики остатков, визуализация фактических и прогнозных продаж, тепловые карты ошибок по

SKU и регионам, а также диаграммы важности признаков и SHAP-графики, которые показывают влияние каждого фактора на прогноз.

Пайплайн построен таким образом, чтобы обеспечивать масштабируемость и воспроизводимость. Все версии данных, признаков и моделей фиксируются в Model Registry, что позволяет повторно запускать эксперименты и отслеживать динамику качества прогнозов. Автоматизация включает регулярное обновление данных, предобработку, генерацию признаков, обучение моделей, генерацию прогнозов и публикацию их в корпоративные системы. Прогнозы интегрируются с ERP и CRM для планирования закупок и управления запасами, а также отображаются в BI-системах для анализа и поддержки принятия решений.

Особое внимание уделяется практическому применению системы. С помощью мониторинга и визуализации можно выявлять проблемные SKU, регионы и категории товаров, где точность прогнозов ниже требуемого уровня, и своевременно корректировать модели. Автоматизация позволяет масштабировать систему на сотни и тысячи товаров и регионов, обрабатывать потоковые данные и поддерживать актуальность прогнозов при изменении структуры данных или внешних факторов. Благодаря комплексному подходу к генерации признаков, обучению моделей, валидации, мониторингу и визуализации прогнозов создаётся надёжная, воспроизводимая и эффективная инфраструктура прогнозирования, способная адаптироваться к изменяющимся условиям рынка и обеспечивать поддержку управленческих решений на всех уровнях.

Таким образом, дополнение к экспериментальной части включает все аспекты практической реализации: подготовку и стандартизацию данных, генерацию признаков, обучение моделей с использованием AutoML, автоматический контроль качества прогнозов, визуализацию результатов и интеграцию с корпоративными системами. Такой подход обеспечивает высокую точность прогнозирования, минимизирует человеческий фактор и создаёт устойчивую и масштабируемую систему автоматизации прогнозирования продаж, полностью готовую к внедрению в бизнес-процессы компании.

Заключение

В ходе выполнения настоящей научно-исследовательской работы была проведена всесторонняя теоретическая и практическая проработка темы автоматизации процесса прогнозирования продаж на основе исторических данных. Рассмотрены ключевые концепции прогнозирования, методы и алгоритмы анализа временных рядов, современные подходы машинного обучения и принципы автоматизации бизнес-процессов. Исследование позволило выявить существующие проблемы традиционных методов прогнозирования, включая ограниченность классических статистических моделей при работе с нестабильным спросом и недостаточную эффективность экспертных оценок при обработке больших объемов данных, а также предложить комплексное решение, интегрирующее возможности современных технологий.

Анализ теоретических аспектов показал, что прогнозирование продаж является неотъемлемой частью стратегического и оперативного управления предприятиями. Его роль заключается в снижении рисков, связанных с неопределенностью рынка, оптимизации запасов, планировании закупок и управлении финансовыми потоками. Современные методы машинного обучения, такие как градиентный бустинг, случайные леса, рекуррентные нейронные сети и трансформеры для временных рядов, обеспечивают более точные прогнозы по сравнению с традиционными методами, позволяя учитывать большое количество признаков, сложные нелинейные зависимости и сезонные колебания.

В практической части исследования была разработана методика автоматизированного прогнозирования продаж, включающая построение ML-пайплайна с предобработкой данных, генерацией признаков, обучением моделей, подбором оптимальных гиперпараметров с использованием AutoML и валидацией прогнозов с последующим мониторингом качества моделей. Пайплайн обеспечивает воспроизводимость результатов, минимизацию человеческого фактора, возможность масштабирования на большое количество SKU, категорий и регионов, а также оперативное обновление прогнозов при поступлении новых данных.

Экспериментальная проверка показала, что предложенная методика обеспечивает высокую точность прогнозов и позволяет эффективно использовать результаты в корпоративных информационных системах для поддержки принятия управленческих решений. Расчёт метрик качества прогнозов, таких как MAE, RMSE, MAPE и sMAPE, подтвердил превосходство автоматизированного подхода с использованием машинного обучения по сравнению с традиционными методами статистического анализа. Визуализация результатов прогнозирования, анализ остатков, тепловые карты ошибок и диаграммы важности признаков позволили выявить ключевые факторы,

влияющие на спрос, и обеспечить прозрачность работы моделей для бизнес-пользователей.

Автоматизация процесса прогнозирования позволяет интегрировать прогнозы непосредственно в бизнес-процессы, включая ERP, CRM и BI-системы, что способствует улучшению планирования закупок, управления запасами и маркетинговой деятельности. Внедрение системы мониторинга и оповещений о критических изменениях качества прогнозов обеспечивает своевременную корректировку моделей и поддерживает устойчивость системы в условиях изменения внешней среды.

Научная и практическая значимость работы заключается в комплексном подходе к решению задачи прогнозирования продаж. Предложенная методика объединяет статистические и современные ML-подходы, позволяя создавать точные прогнозы для различных категорий товаров, регионов и горизонтов планирования, автоматизировать процесс построения моделей и обеспечить их интеграцию с корпоративными системами. Это обеспечивает устойчивое развитие компании, снижение издержек, повышение эффективности управления продажами и конкурентоспособности на рынке.

В результате выполнения НИР можно сделать следующие ключевые выводы. Во-первых, автоматизация прогнозирования продаж является необходимым условием повышения точности прогнозов и эффективности бизнес-процессов в современных условиях. Во-вторых, использование методов машинного обучения и AutoML позволяет значительно повысить точность прогнозов по сравнению с традиционными статистическими и экспертными методами. В-третьих, построение ML-пайплайна с интеграцией этапов предобработки данных, генерации признаков, обучения моделей, валидации и мониторинга обеспечивает воспроизводимость результатов, масштабируемость системы и оперативное обновление прогнозов. В-четвёртых, интеграция прогнозов в корпоративные информационные системы позволяет эффективно использовать результаты для планирования закупок, управления запасами, формирования маркетинговых стратегий и поддержки принятия управленческих решений.

Таким образом, проведённая работа подтверждает актуальность и необходимость автоматизации прогнозирования продаж на основе исторических данных, демонстрирует практическую применимость разработанной методики и её эффективность для решения задач бизнеса. Результаты исследования могут быть использованы в дальнейшем для совершенствования систем прогнозирования, внедрения новых моделей машинного обучения, расширения функционала AutoML и интеграции с другими бизнес-процессами предприятия. Дальнейшие исследования могут быть направлены на улучшение точности прогнозов для товаров с интермиттирующим спросом, адаптацию моделей к потоковым данным в реальном времени и разработку механизмов

прогнозирования с учётом влияния внешних макроэкономических факторов и маркетинговых активностей конкурентов.

В заключение можно отметить, что автоматизация процесса прогнозирования продаж является важным инструментом повышения эффективности управления предприятием. Комплексный подход, объединяющий статистические методы, машинное обучение и автоматизацию бизнес-процессов, обеспечивает точность, воспроизводимость и масштабируемость системы, создавая устойчивую основу для стратегического и оперативного планирования, оптимизации ресурсов и повышения конкурентоспособности компании на рынке.

Список использованных источников

1. Бланк И.А., Трунов С.В. *Прогнозирование продаж: теория и практика*. — Москва: Инфра-М, 2020. — 256 с.
2. Аркадьев В.И. *Машинное обучение и прогнозирование временных рядов*. — Санкт-Петербург: Питер, 2019. — 312 с.
3. Шапиро С.М., Козлов А.А. *Применение методов машинного обучения в бизнес-аналитике*. — Москва: ДМК Пресс, 2021. — 288 с.
4. Makridakis S., Wheelwright S.C., Hyndman R.J. *Forecasting: Methods and Applications*. — 5th Edition. — Wiley, 2018. — 752 p.
5. Hyndman R.J., Athanasopoulos G. *Forecasting: Principles and Practice*. — OTexts, 2018. — 604 p.
6. Bishop C.M. *Pattern Recognition and Machine Learning*. — Springer, 2006. — 738 p.
7. Goodfellow I., Bengio Y., Courville A. *Deep Learning*. — MIT Press, 2016. — 800 p.
8. Lundberg S.M., Lee S.I. *A Unified Approach to Interpreting Model Predictions*. — Advances in Neural Information Processing Systems, 2017. — Vol. 30.
9. Zhang G., Eddy Patuwo B., Hu M.Y. *Forecasting with Artificial Neural Networks: The State of the Art*. — International Journal of Forecasting, 1998. — Vol. 14, Issue 1, pp. 35–62.
10. Hyndman R.J., Khandakar Y. *Automatic Time Series Forecasting: The forecast Package for R*. — Journal of Statistical Software, 2008. — Vol. 27, Issue 3.
11. Wang S., Wang H. *Sales Forecasting Using Machine Learning and AutoML*. — Journal of Business Analytics, 2022. — Vol. 5, Issue 2, pp. 112–128.

Приложения

Приложение А. Примеры исходных данных о продажах

Ниже приведён фрагмент таблицы исходного датасета, используемого для построения прогнозов. Данные включают исторические продажи по SKU, даты, регионы и дополнительные признаки.

Дата	SKU	Категория	Регион	Продажи, шт	Цена, руб	Акция	Праздник	Температура, °C
2024-01-01	1001	Напитки	Москва	120	50	Да	Нет	-5
2024-01-01	1002	Снеки	Санкт-Петербург	85	35	Нет	Нет	-7
2024-01-02	1001	Напитки	Москва	110	50	Нет	Нет	-3
2024-01-02	1002	Снеки	Санкт-Петербург	90	35	Да	Нет	-6

Описание признаков:

SKU – уникальный идентификатор товара.

Категория – товарная категория.

Регион – регион продажи.

Продажи, шт – количество проданных единиц.

Цена, руб – цена продажи.

Акция – признак проведения акции.

Праздник – признак праздничного дня.

Температура, °C – внешняя температура (как пример внешнего фактора).

Приложение Б. Псевдокод предобработки данных и генерации признаков

Python

```
# Загрузка данных
data = load_csv("sales_data.csv")

# Очистка данных
data = remove_duplicates(data)
data = fill_missing_values(data, method='median')

# Кодирование категориальных признаков
data['Категория'] = one_hot_encode(data['Категория'])
data['Регион'] = target_encode(data['Регион'], target='Продажи, шт')

# Генерация временных признаков
data['День_недели'] = data['Дата'].dt.weekday
data['Месяц'] = data['Дата'].dt.month
data['Квартал'] = data['Дата'].dt.quarter

# Создание лагов и скользящих статистик
data['Продажи_лаг_1'] = data.groupby('SKU')['Продажи, шт'].shift(1)
data['Продажи_скользящее_cp_7'] =
data.groupby('SKU')['Продажи,шт'].rolling(7).mean().reset_index(0, drop=True)
```

Описание: Псевдокод демонстрирует основные этапы подготовки данных для моделей прогнозирования: очистку, кодирование категориальных признаков, генерацию временных и скользящих признаков.

Приложение В. Архитектура ML-пайплайна

Схема пайплайна прогнозирования:

Исходные данные --> Предобработка --> Генерация признаков --> Разделение на train/test
--> Обучение моделей --> Валидация --> Подбор гиперпараметров (AutoML) --> Прогнозы
--> Мониторинг и визуализация --> Интеграция в ERP/BI

Описание: Пайплайн обеспечивает воспроизводимость прогнозов, автоматический подбор моделей, генерацию признаков и интеграцию результатов в бизнес-процессы.

Приложение Г. Формулы расчёта метрик качества прогнозов

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Рисунок 1. Средняя абсолютная ошибка (MAE):

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Рисунок 2. Среднеквадратичная ошибка (RMSE):

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i}$$

Рисунок 3. Средняя абсолютная процентная ошибка (MAPE):


$$sMAPE = \frac{100\%}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

Рисунок 4. Симметричная средняя абсолютная процентная ошибка (sMAPE):

Описание: Метрики применяются для оценки точности прогнозов на уровне отдельных товаров, категорий и регионов.

Приложение Д. Визуализация результатов прогнозирования

1. График фактических и прогнозных продаж для одного SKU



2. Тепловая карта ошибок по SKU и регионам

- Красным цветом выделены SKU с наибольшей ошибкой прогнозирования.
- Синим цветом – SKU с точными прогнозами.

3. Диаграмма важности признаков (SHAP)

- Позволяет определить, какие признаки сильнее всего влияют на прогноз модели.

Приложение Е. Программные коды и настройки моделей

Python

```
from lightgbm import LGBMRegressor
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error

# Разделение данных
X_train, X_test, y_train, y_test = train_test_split(features, target,
test_size=0.2, shuffle=False)

# Инициализация модели
model = LGBMRegressor(
    n_estimators=500,
    learning_rate=0.05,
    max_depth=7,
    random_state=42
)

# Обучение
model.fit(X_train, y_train)

# Прогноз
y_pred = model.predict(X_test)

# Оценка
mae = mean_absolute_error(y_test, y_pred)
print("MAE:", mae)
```

Описание: Приведен пример кода для обучения модели LightGBM на подготовленных данных и оценки точности прогнозов с использованием MAE.