

СОДЕРЖАНИЕ

СОДЕРЖАНИЕ	1
ВВЕДЕНИЕ	2
1. ОБЗОР ТЕКУЩЕГО СОСТОЯНИЯ ПРЕДМЕТА ИССЛЕДОВАНИЯ .	3
1.1 Обзор зарубежных исследований.....	3
1.2 Обзор отечественных исследований	4
1.3 Общая характеристика проблемы исследования	4
2. ОБЗОР ТЕХНОЛОГИЙ И МЕТОДОВ РЕШЕНИЯ ПРОБЛЕМЫ	6
2.1 Основные методы решения проблемы и их характеристики ..	6
2.2 Основные технологии решения проблемы и их характеристики.....	7
2.3 Алгоритм выбора методов и технологий решения проблемы .	9
3 ФОРМИРОВАНИЕ ТРЕБОВАНИЙ К РЕШЕНИЮ ПРОБЛЕМЫ	11
3.1 Общая характеристика предлагаемого решения	11
3.2 Функциональные требования к предлагаемому решению	12
3.3 Нефункциональные требования к предлагаемому решению	16
ЗАКЛЮЧЕНИЕ	21
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	23
(Gupta, 2025) (B. Durga Bhavani1, 2024) Ошибка! Закладка не определена.	

ВВЕДЕНИЕ

Актуальность исследования на тему «Разработка интеллектуальной системы обнаружения телефонного мошенничества с применением моделей машинного обучения» обусловлена быстрым ростом телефонного мошенничества. С появлением искусственного интеллекта у мошенников появилось больше возможностей для обмана такие, как голосовые и видео DeepFake и RoboCall. Ежедневно жертвами мошенников в России становятся от 50000 до 70000 человек, переводя тем свои деньги. Около 6-8 млн звонков ежедневно поступает россиянам от мошенников. Традиционные методы такие, как чёрные списки, оказываются недостаточно эффективными. Современные методы машинного обучения позволяют выявлять сложные и скрытые паттерны в метаданных и аудиопотоке, снижая число ложных срабатываний и обеспечивая адаптацию к новым тактикам мошенников. Разработка такой системы решает практические задачи защиты абонентов, поддерживая оперативное реагирование операторов и банков, и имеет высокий прикладной и научный потенциал. Для достижения поставленной цели требуется решить ряд задач, включающих изучение текущего состояния предметной области в отечественных и зарубежных источниках, проведение сравнительного анализа существующих методов и технологий, а также формулирование требований к предлагаемому решению. Практическая значимость работы заключается в создании теоретического фундамента для последующей разработки программного комплекса в рамках выпускной квалификационной работы.

1. ОБЗОР ТЕКУЩЕГО СОСТОЯНИЯ ПРЕДМЕТА ИССЛЕДОВАНИЯ

1.1 Обзор зарубежных исследований

Анализ зарубежных научных публикаций и технической документации свидетельствует о значительном внимании научного сообщества к проблематике обнаружения телефонного мошенничества и защиты голосовой связи. В работах таких авторов, как Сандип Гупта «An Intelligent System for Identifying Fraud Phone Calls Using Machine Learning Algorithms», коллектива Malla Reddy Engineering College for Women «Artificial Intelligence Based Fake or Fraud Phone Calls Detection» и коллектива GMR Institute of Technology «Enhanced Fraud Call Detection through Cybersecurity and Machine Learning Integration.», основное внимание уделяется применению методов машинного обучения и глубоких нейронных сетей для комбинированного анализа метаданных вызовов, акустических признаков и семантики разговоров (ASR(Automatic Speech Recognition) и NLP(Natural Language Proccessing)) с целью детекции vishing, RoboCall и голосовых подделок. Наблюдается четкий тренд в сторону интеграции облачных вычислений и микросервисной архитектуры в связке с потоковой обработкой данных, что позволяет создавать более масштабируемые, отказоустойчивые решения для реального времени. Параллельно развивается направление применения графовых нейронных сетей для анализа связей между номерами и выявления организованных схем массовых рассылок. Ключевым вызовом, обсуждаемым в современных зарубежных исследованиях, остается проблема нехватки репрезентативных размеченных данных и дисбаланса классов, а также обеспечение конфиденциальности персональных данных в условиях строгой регуляции, что стимулирует исследования по federated learning и методам приватности и по повышению устойчивости моделей к адаптивным атакам мошенников.

1.2 Обзор отечественных исследований

В рамках отечественной научной школы также ведется активная работа по направлению разработки интеллектуальных систем обнаружения телефонного мошенничества. Российские исследователи, в частности коллективы, связанные с Нижнекамским химико-технологическим институтом и Финансовым университетом при Правительстве Российской Федерации, часто фокусируются на вопросах импортозамещения и создании решений, адаптированных к требованиям локального рынка и национального законодательства. В трудах отечественных специалистов подчёркивается важность создания систем с повышенными требованиями к информационной безопасности, соответствующих требованиям ФЗ и регуляторов, а также обеспечение конфиденциальности при обработке разговоров и метаданных. Другими ключевыми аспектами являются практическая интеграция с инфраструктурой операторов, оптимизация вычислительных алгоритмов под локальные аппаратные платформы и энергоэффективность решений для работающих в реальном времени систем. Можно отметить, что, несмотря на заметное отставание в ряде направлений фундаментальных исследований по сравнению с лучшими зарубежными центрами, в прикладных областях — например, в разработке криптографических и безопасных распределённых схем обработки данных, адаптации методов ASR и антиспуфинга (фильтрация IP-адресов на входе в сеть) под русскоязычную среду, а также в интеграции с операторами связи — имеются конкурентоспособные наработки, активно внедряемые в промышленности.

1.3 Общая характеристика проблемы исследования

Синтез данных, полученных в результате анализа литературных источников, позволяет сформулировать основную проблему исследования. Она заключается в отсутствии эффективного и универсального подхода к

обнаружению телефонного мошенничества, который сочетал бы высокую точность детекции в реальном времени при обработке больших потоков вызовов, устойчивость к адаптивным стратегиям злоумышленников, низкую ресурсоёмкость для развёртывания в инфраструктуре операторов и полное соответствие требованиям информационной безопасности и защите персональных данных. Существующие решения либо демонстрируют недостаточную производительность и устойчивость при работе с реальными объёмами и разнообразием данных, либо обладают избыточной сложностью развёртывания и сопровождения, что ограничивает их практическую применимость. Таким образом возникает объективная необходимость в разработке нового или комбинированного подхода, лишённого указанных недостатков и учитывающего особенности локальной предметной области, ограничений инфраструктуры и нормативных требований.

2. ОБЗОР ТЕХНОЛОГИЙ И МЕТОДОВ РЕШЕНИЯ ПРОБЛЕМЫ

2.1 Основные методы решения проблемы и их характеристики

Для решения обозначенной проблемы в современной практике применяется спектр методов, каждый из которых обладает определёнными достоинствами и ограничениями. Среди них можно выделить статистические методы анализа, которые характеризуются простотой интерпретации и низкими вычислительными требованиями, но часто не пригодны для сложных нестационарных данных; Классические методы машинного обучения (логистическая регрессия, SVM, решающие деревья, Random Forest, градиентный бустинг) — хорошо работают на структурированных признаках, требуют относительно небольших объёмов размеченных данных и просты в развёртывании, однако ограничены в способности обрабатывать неструктурированные аудио- и текстовые данные; Методы глубокого обучения (CNN, RNN, Transformer и их варианты для аудио и текста) позволяют выявлять сложные нелинейные зависимости и извлекать представления из сырых сигналов и транскриптов, но требуют больших датасетов и вычислительных ресурсов; Методы обнаружения аномалий и несупервизированное обучение (Isolation Forest, One-Class SVM, автокодировщики и вариационные автокодировщики) полезны при недостатке размеченных примеров и для выявления новых типов мошенничества, но чаще дают повышенное число ложных срабатываний; Графовые методы и анализ связей (link analysis, графовые нейронные сети) эффективны для обнаружения мошеннических цепочек и спуффинга номеров, однако требуют построения и поддержки сложной графовой инфраструктуры; Гибридные и ансамблевые подходы комбинируют сильные стороны разных методов и повышают стабильность детекции, но усложняют архитектуру и сопровождение; Методы

обработки речи и NLP (ASR, speaker recognition, diarization, семантические эмбединги) критичны для анализа содержания разговоров и идентификации признаков социальной инженерии, при этом их качество зависит от точности распознавания и языковой специфики; Онлайн-алгоритмы и лёгковесные модели для потоковой обработки обеспечивают низкую задержку и масштабируемость в инфраструктуре операторов, но иногда уступают в точности тяжёлым моделям; Методы обеспечения приватности и распределённого обучения (Federated Learning, differential privacy) позволяют соответствовать нормативным требованиям и ограничивать передачу персональных данных, но добавляют сложность реализации и могут снижать качество моделей; Наконец, инструменты объяснимости и валидации моделей (SHAP, LIME, тесты на смещение) повышают доверие и помогают соответствовать регуляторным требованиям, но требуют дополнительных вычислительных и организационных ресурсов. Выбор конкретного набора методов напрямую зависит от природы доступных данных (акустика, метаданные, транскрипты, граф вызовов), требований к задержке и точности, допустимому уровню ложных срабатываний, ограничений инфраструктуры и нормативных требований.

2.2 Основные технологии решения проблемы и их характеристики

На технологическом уровне реализация указанных методов опирается на разнообразные программные платформы, фреймворки и инструменты, выбор которых определяется требованиями к задержкам, объёму данных и ограничениями инфраструктуры. Для задач, связанных с интенсивными вычислениями и обработкой больших массивов признаков, часто используется стек на основе языка Python с библиотеками NumPy, pandas и SciPy для предобработки; для классического машинного обучения — scikit-learn и

XGBoost; для обучения глубоких нейросетей — PyTorch или TensorFlow (включая высокоуровневые обёртки и трансформеры из Hugging Face). Для задач распознавания речи и извлечения признаков из аудио применяются инструменты типа Kaldi, Whisper, librosa и специализированные модели для speaker-recognition (pyannote). При необходимости ускорения инференса используются форматы ONNX и оптимизаторы (TensorRT, OpenVINO), а также аппаратные ускорители (GPU, TPU, NPU) или лёгкие архитектуры для edge-депоя.

Для обработки потоковых данных и реализации детекции в реальном времени применяются брокеры и стриминговые платформы (Apache Kafka, RabbitMQ, Apache Flink, Spark Streaming) совместно с микросервисной архитектурой, контейнеризацией (Docker) и оркестрацией (Kubernetes). Веб-ориентированные компоненты и API обычно строят с помощью FastAPI, Flask или более полнофункциональных фреймворков (Django, Spring) в зависимости от требований к интеграции с корпоративными системами операторов. Важно продумать слой сервисов для feature-store, трансформаций и кэширования (например, Feast, Redis) для обеспечения низкой задержки.

Выбор системы управления данными критичен: реляционные СУБД (PostgreSQL, включая расширения типа TimescaleDB) подходят для транзакционной надёжности и согласованности, тогда как NoSQL (MongoDB, Cassandra) удобны для хранения гибких метаданных и больших объёмов неструктурированных записей. Для аналитики и OLAP-запросов целесообразны колоночные движки и хранилища (ClickHouse) и системы хранения аудио/логов в объектных хранилищах (S3-совместимые). Для метрик, мониторинга и алертинга используются Prometheus и Grafana; для централизованного логирования — ELK/EFK-стек.

MLOps-инструменты (MLflow, Kubeflow, DVC) обеспечивают трекинг экспериментов, версионирование данных и моделей, CI/CD-пайплайны и воспроизводимость. Для развёртывания и сервинга моделей применимы

Seldon, BentoML, TorchServe или кастомные inference-сервисы. Для контроля качества данных и моделей используются Great Expectations, тестирование на смещения и инструменты объяснимости (SHAP, LIME) — это важно для регуляторного соответствия и отладки. Наконец, реализация должна учитывать вопросы приватности и безопасности: шифрование каналов и данных, ограничение передачи персональных данных, возможность федеративного обучения или дифференциальной приватности, а также процессы аудита, резервного копирования и отказоустойчивости. Выбор конкретного набора технологий определяется требованиями к задержке, объёму и типам данных (аудио, метаданные, транскрипты, графы вызовов), ап инфраструктурным бюджетом и нормативными ограничениями.

2.3 Алгоритм выбора методов и технологий решения проблемы

На основании проведённого анализа сформирован алгоритм выбора, представляющий собой последовательность практических шагов. Сначала выполняется детальный анализ предметной области и специфики задачи: оцениваются объём и структура входных данных (аудио, метаданные, транскрипты, графы вызовов), требуемое время отклика и допустимый уровень ложных срабатываний, ограничения по бюджету и вычислительным ресурсам, а также требования к защите персональных данных и нормативному соответствию. На втором этапе эти параметры сопоставляются с характеристиками рассмотренных методов машинного обучения и инженерных решений — точностью, скоростью инференса, потребностью в размеченных данных, устойчивостью к адаптивным атакам, сложностью развёртывания и сопровождения. По результатам сопоставления отбирается группа наиболее релевантных методов и архитектур, после чего для каждой кандидатуры проводится быстрая прототипная оценка с использованием реальных или приближённых данных и ключевых метрик качества (ROC/AUC,

precision/recall, latency). Финальный выбор производится на основе совокупной оценки эффективности, затрат на интеграцию и эксплуатации, риска перехода на сторонние компоненты и способности решения масштабироваться и эволюционировать; при этом учитываются критерии выбора технологий — производительность, зрелость, поддержка сообщества и качество документации. Заключительным этапом является пилотное развёртывание с мониторингом показателей в продакшн-условиях, итеративная оптимизация и формализация процедур валидации, отката и обеспечения приватности.

3 ФОРМИРОВАНИЕ ТРЕБОВАНИЙ К РЕШЕНИЮ ПРОБЛЕМЫ

3.1 Общая характеристика предлагаемого решения

В качестве предлагаемого решения рассматривается программный комплекс, предназначенный для автоматизированного обнаружения и предотвращения телефонного мошенничества на основе анализа акустики вызовов, метаданных соединений и текстовых транскриптов. Архитектурно решение будет построено по модульному принципу с четким разделением функциональности на независимые компоненты (ингест и нормализация данных, извлечение аудио- и текстовых признаков, модули ASR и speaker-recognition, движок детекции/инференса, подсистема графового анализа связей, сервис алертинга и интерфейс мониторинга), что повысит сопровождаемость и позволит независимо масштабировать наиболее нагруженные части системы. Для обработки потоковых событий предусматривается слой стриминговой обработки и очередей (реальное время), одновременно с пакетной аналитикой для переобучения моделей и ретроспективного анализа. Ожидается, что данное решение позволит преодолеть ограничения, присущие существующим аналогам, за счет гибридного подхода, комбинирующего статистические правила, классические алгоритмы машинного обучения, глубокие нейросетевые модели для распознавания речи и эмбеддингов, а также графовые методы для выявления мошеннических цепочек и аномалий. Важной составляющей является замкнутый цикл с Sampler/Labeler и human-in-the-loop верификацией для постоянного улучшения моделей и снижения числа ложных срабатываний. Для обеспечения надёжности и соответствия нормативам в дизайн включены механизмы журналирования, explainability-модули (для интерпретации решений), методы защиты персональных данных (анонимизация, шифрование, возможность федеративного обучения) и инструменты MLOps для автоотчетов, версионирования моделей и отката. В результате внедрения

ожидается повышение точности детекции и скорость реакции, снижение экономических потерь от мошенничества и уменьшение операционных затрат за счёт автоматизации рутинных проверок.

3.2 Функциональные требования к предлагаемому решению

Функциональные требования определяют точный набор задач, которые должна выполнять интеллектуальная система обнаружения телефонного мошенничества. Ниже приведён подробный и проверяемый перечень таких требований:

1. Источники данных
 - Приём и хранение CDR/Call Detail Records (формат CSV/Parquet/JSON), SIP-логов и сигнализации (Syslog), аудио-записей разговоров (WAV, 8/16 kHz), транскриптов ASR (JSON), метаданных абонентов (CRM), пользовательских жалоб/репортов и внешних чёрных списков (CSV/JSON/API).
 - Система должна поддерживать одновременный приём данных из не менее чем 3 типов источников и гарантировать целостность и валидацию формата при загрузке.
2. Предобработка и базовые операции
 - Нормализация и валидация полей (таймстемпы в UTC, проверка формата номеров, удаление дубликатов).
 - Фильтрация по правилам (блокировка внутренних/тестовых номеров), очистка шумов и выделение активных сегментов (Voice Activity Detection) для аудио.
 - Агрегация и группировка по временным окнам (например, 1 мин, 1 час, 24 часа) и по сущностям (номер вызывающего, номер вызываемого, account_id).
 - Извлечение признаков: статистические (количество вызовов, средняя

длительность), поведенческие (время суток, частота повторных звонков), аудио-признаки (MFCC, эмбединги), и графовые признаки (степень вершины, центральности).

- Все операции должны быть определены в виде воспроизводимых пайплайнов (код/конфиги) и иметь покрытие тестами единичной и интеграционной проверки.

3. Алгоритмы детекции

- Реализация гибридного алгоритма: ансамбль XGBoost для табличных признаков + BiLSTM/Transformer-модель для последовательностных/аудио-признаков + Graph Neural Network (GNN) для анализа связей абонентов.

- В дополнение — модуль аномальности на базе Isolation Forest для выявления неожиданных сценариев.

- Модель должна отдавать вероятность мошенничества в диапазоне $[0,1]$ и набор объяснений (важность признаков, релевантные соседние узлы графа).

- Критерии приёмки: $\text{ROC-AUC} \geq 0.90$ (на тестовом наборе с заданным класс-балансом), precision@topK и recall на целевых сценариях должны соответствовать заранее согласованным порогам.

4. Инфраструктурные и производственные требования

- Онлайн-инференс: задержка принятия решения для одного события $\leq 200 \text{ ms}$ (p95) при объёме до $N = 1000$ решений/сек (порог уточняется проектно).

- Пакетная обработка для переобучения: поддержка обработки до 10 TB исторических данных в задаче ETL.

- Поддержка форматирования выходных данных в JSON/CSV и публикации через REST API и/или Kafka topics.

5. Интерфейсы визуализации и отчётности

- Дашборды в реальном времени с графиками: поток инцидентов по времени,

карта геолокаций вызовов, гистограммы по типам мошенничества, таблицы инцидентов с возможностью фильтрации и экспорта.

- Визуализация графов связей (adjacency graph / Sankey) с возможностью интерактивного расширения узлов.

- Генерация регламентированных отчётов в формате PDF/CSV по ежедневным и месячным метрикам; экспорт выборок подозрительных вызовов для дальнейшей экспертизы.

- Каждый вид визуализации должен иметь acceptance-критерий: корректность данных при пересчёте, время отклика дашборда ≤ 2 s для выборки до 10k записей.

6. Управление пользователями и разграничение прав

- Роли: администратор, аналитик, оператор, аудитор. Для каждой роли заданы действия (просмотр, пометка инцидента, подтверждение/отклонение, изменение конфигураций, доступ к логам и отчётам).

- Аутентификация через SSO (OAuth2/SAML) и поддержка MFA; журналирование входов и действий (audit trail).

- Механизм тонких прав (RBAC) и возможность временного делегирования прав. Acceptance - критерий: возможности разных ролей проверяются тестами сценариев доступа.

7. Обратная связь и human-in-the-loop

- Интерфейс для маркировки инцидентов с хранением метаданных разметки; очередь для верификации оператором.

- Поддержка горячей выборки (sampling) для ручной проверки неочевидных случаев и механизма подачи данных в тренировочные наборы.

- Метрика времени до верификации (SLA) ≤ 24 часа для приоритетных инцидентов.

8. Надёжность, безопасность и соответствие

- Шифрование данных в покое и в канале (TLS, AES-256), хранение ключей по политике KMS.
- Политика хранения и удаления данных (retention): аудио — максимум 90 дней по умолчанию; логи и метаданные — 1 год (параметризуемо).
- Возможность анонимизации персональных данных и режим работы с псевдонимизацией.
- Логирование всех решений модели и метрик для последующего аудита (traceability).

9. MLOps и сопровождение моделей

- Автоматизация CI/CD для моделей и пайплайнов; версионирование моделей и данных (MLflow/DVC).
- Мониторинг производительности моделей (drift, degradation) и метрик (precision, recall, latency) с алертингом при отклонениях.
- Процесс ретренинга: периодическое переобучение не реже 1 раза в месяц и возможность срочного переобучения по сигналу изменения данных.

10. Тестируемость и критерии приёмки

- Каждое функциональное требование должно быть сформулировано с конкретными критериями приёмки (метрики, SLA, форматы входа/выхода).
- Предусмотреть набор автоматизированных тестов: unit, integration, load тесты и тесты на безопасность.
- Финальная проверка — пилот в реальных условиях с набором заранее согласованных KPI (детекция мошенничества, FPR, время реакции, нагрузочная устойчивость).

Каждое требование будет подробно расписано в виде пользовательских историй и acceptance-критериев в бэклоге проекта, чтобы обеспечить проверяемость и реализуемость в рамках технических и регуляторных ограничений.

3.3 Нефункциональные требования к предлагаемому решению

Нефункциональные требования описывают качественные свойства интеллектуальной системы обнаружения телефонного мошенничества и задают измеримые критерии её работы. Ниже приведён набор таких требований с конкретными и проверяемыми показателями (параметры могут быть уточнены на этапе проектирования и согласованы с заказчиком).

1. Производительность
 - Онлайн-инференс: время отклика сервиса принятия решения по одному событию (p95) $\leq$ 200 ms.
 - Обработка потоков: способность обрабатывать до 1 000 событий/сек в режиме реального времени с сохранением целевых SLA по латентности.
 - Дашборды и отчёты: время отклика интерфейса при выборке до 10k записей $\leq$ 2 s.
 - Пакетная аналитика: возможность обработки ETL-задач на исторических данных объёмом до 10 TB в рамках планового окна переобучения.
2. Масштабируемость
 - Архитектура должна быть горизонтально масштабируемой: stateless-сервисы для API/инференса, отдельные масштабируемые хранилища для метрик/логов/объёмных данных.
 - Поддержка автоматического масштабирования (autoscaling) контейнеров под нагрузкой и возможность вертикального расширения узлов для вычислительно тяжёлых задач.
 - Горизонтальное шардирование/partitioning для потоковых данных (Kafka/streaming) и хранение больших объёмов в распределённом хранилище (HDFS/S3-совместимое).
3. Надёжность и отказоустойчивость

- Коэффициент готовности (availability) $\geq 99.9\%$ (не более ~8.8 часов простоя в год).
- RTO (Recovery Time Objective) для критичных сервисов ≤ 60 минут; RPO (Recovery Point Objective) для бизнес-данных ≤ 15 минут.
- Механизмы отказоустойчивости: репликация сервисов, автоматическое переключение на резервные инстансы, graceful degradation (снижение функциональности вместо полного отказа).
- Поведение при перегрузке: очереди, схемы сброса нагрузки, circuit breaker, бэ-офф и повторные попытки.

4. Безопасность и контроль доступа

- Аутентификация: поддержка SSO (OAuth2/SAML/OpenID Connect) и обязательная многофакторная аутентификация (MFA) для привилегированных ролей.
- Авторизация: ролевая модель (RBAC) с тонкой гранулярностью прав; политически управляемые политики доступа.
- Шифрование: TLS 1.2+ для канала, шифрование данных в покое AES-256; управление ключами через KMS с регулярной ротацией.
- Хранение секретов — через безопасный менеджер секретов (Vault/KMS).
- Безопасная разработка: статический и динамический анализ кода, регулярные pentest и сканирование уязвимостей, процедуры обработки инцидентов безопасности.
- Логирование действий пользователей и решений модели (audit trail) с неизменяемым хранением критичных записей.

5. Конфиденциальность и соответствие требованиям

- Поддержка анонимизации/псевдонимизации персональных данных и возможность работы в «privacy-preserving» режимах (маскирование, удаление аудио-фрагментов по требованию).
- Соответствие нормативам: GDPR, локальные требования по защите данных;

документированные политики retention & deletion.
- Механизмы согласия на обработку данных и управление запросами субъектов данных (право на удаление/выгрузку).

6. Удобство использования и эргономика
- Интуитивный пользовательский интерфейс с минимальным временем обучения — типичный новый оператор должен достичь продуктивности за ≤ 2 рабочих часа.

- Критерии приемки UI: SUS (System Usability Scale) ≥ 70 и успешность выполнения контрольных сценариев $\geq 90\%$.

- Поддержка ролей: персонализированные представления данных и рабочие процессы для оператора, аналитика и администратора.

7. Наблюдаемость и управление эксплуатацией
- Централизованный сбор метрик, логов и трассировок (Prometheus/Grafana, ELK/EFK, Jaeger/Zipkin).

- Мониторинг KPI моделей (precision, recall, latency, throughput), обнаружение drift и аномалий данных с генерацией алертов.

- Настроенные оповещения (e-mail/Slack/pager) при превышении порогов и плейбуки реагирования.

8. Поддерживаемость и сопровождение
- CI/CD для микросервисов и моделей; автоматические тесты (unit, integration, e2e) в пайплайне.

- Версионирование кода, моделей и данных (Git, MLflow/DVC) с возможностью быстрого отката.

- Документация: эксплуатационная (SOP), архитектурная и пользовательская, поддерживаемая в актуальном состоянии.

9. Портруемость и развёртывание

- Контейнеризация (Docker) и оркестрация (Kubernetes) для единообразного развёртывания в облаке и on-premise.
- Возможность работы в мульти-облачной среде и гибридных сценариях, совместимость с основными провайдерами (AWS/Azure/GCP) и локальными ЦОД.

10. Восстановление и резервное копирование

- Регулярное резервное копирование критичных данных (ежечасное для транзакционных метаданных, ежедневное — для аналитики) и тесты восстановления резервных копий не реже 1 раза в квартал.
- Хранение резервов в гео-реплицированном хранилище и проверяемые процедуры восстановления.

11. Интероперабельность и API-контракты

- Явные контракты API (OpenAPI/Swagger) для интеграции с внешними системами; поддержка форматов JSON/CSV/Parquet и очередей (Kafka).
- Гарантии совместимости при обновлениях API (версирование, backward compatibility policy).

12. Объяснимость и прозрачность решений

- Механизмы explainability: предоставление ключевых факторов и краткого описания причин высоких скоринговых оценок; latency создания объяснения ≤ 500 ms.
- Сохранение трассы решения для аудита и последующего анализа ошибок модели.

Каждое из перечисленных требований должно иметь конкретный критерий приёмки и тестовую процедуру, описанные в рамках проектной документации. В дальнейшем показатели по времени отклика, нагрузке и политикам

безопасности согласуются с бизнес-требованиями и регуляторными ограничениями проекта.

ЗАКЛЮЧЕНИЕ

В рамках выполнения научно-исследовательской работы был проведён всесторонний анализ проблемной области, связанной с обнаружением телефонного мошенничества с применением методов машинного обучения, включая обработку аудио-записей вызовов, анализ метаданных соединений и построение графов коммуникаций. В результате исследования были систематизированы и критически оценены существующие подходы и технологии — от классических правил и статистических методов до современных нейросетевых моделей (ASR, эмбединги речи, модели последовательностей и графовые нейронные сети) — применяемые как в зарубежной, так и в отечественной практике, с учётом их преимуществ и ограничений в контексте чувствительности данных, латентности и эксплуатационных требований.

На основе проведённого анализа разработан алгоритм выбора средств решения, учитывающий ключевые параметры задачи: характер и объём доступных данных, требования по времени ответа и масштабируемости, требования по приватности и соответствию регулированию, объяснимость решений, а также ресурсные и интеграционные ограничения. Алгоритм позволяет формализованно сопоставлять классы методов и конкретные инструменты с целями распознавания и эксплуатационными ограничениями.

Важнейшим итогом работы стало формирование комплекса функциональных и нефункциональных требований к перспективному программному решению. Эти требования задают чёткие рамки и критерии для последующей проектной и разработческой деятельности и создают прочный теоретический и методологический фундамент для перехода к практической стадии — детальному проектированию архитектуры, выбору конкретных инструментов из рассмотренных классов и поэтапной реализации

программного комплекса в рамках выпускной квалификационной работы, включая валидацию в пилотной эксплуатации и организацию цикла дообучения моделей.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. (B. Durga Bhavani¹, 2024)
2. (Gupta, 2025)
3. (A.B., 2024)
4. (Филимонов Андрей Викторович, 2022)