

Аннотация

Выпускная квалификационная работа в виде стартапа посвящена аналитическому проектированию рекомендательной системы “Search My Way” - мобильного приложения для интеллектуального подбора мест по проведению досуга с диалоговым ИИ-ассистентом и групповым свайп-голосованием. Актуальность исследования обусловлена проблемой когнитивной перегрузки пользователя при взаимодействии с традиционными агрегаторами, выполняющими подбор мест для досуга, а также отсутствием эффективных инструментов для совместного принятия решений в группе.

В рамках исследования проведен обзор и сравнительный зарубежных и отечественных сервисов, выявлены их функциональные ограничения. На основе анализа сформированы функциональные и нефункциональные требования к системе, а также обоснован выбор технологического стека (Go, Flutter, PostgreSQL + pgvector, Groq API с моделями OpenAI GPT-OSS-120B, Llama 4 Scout и multilingual-e5-base). Разработана архитектура приложения, включая диаграммы вариантов использования, последовательности обработки запроса, информационную модель базы данных и диаграмму состояний групповой сессии.

В практической части работы была спроектирована информационная модель, а также было осуществлено развертывание и настройка базы данных PostgreSQL с расширением pgvector для гибридного семантического поиска, создана структура таблиц и связей.

Практическая ценность работы заключается в создании детализированной аналитической спецификации, готовой к передаче команде разработки для реализации минимально жизнеспособного продукта.

Общий объем работы составляет __ страниц основного текста, __ страниц приложений.

СОДЕРЖАНИЕ

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ	5
ВВЕДЕНИЕ	6
1. Анализ проблем выбора в цифровых сервисах досуга и обзор рынка рекомендательных систем.....	10
1.1 Зарубежные исследования и глобальные тренды	10
1.2 Отечественные исследования и специфика рынка Российской Федерации	12
1.3 Общая характеристика проблемы исследования	15
2. Проектирования рекомендательной системы “Search My Way”: технологии, требования и архитектура	17
2.1 Анализ и обоснование выбора технологий	17
2.2 Функциональные и нефункциональные требования	22
2.3 Архитектурная модель системы	24
3. Аналитическая проработка данных и оценка качества рекомендательной системы.....	31
3.1 Анализ доступных источников данных.....	31
3.2 Формирование тестового набора данных	33
3.3 Подготовка данных к загрузке в базу данных и векторизация	35
3.4 Тестирование гибридного поиска на тестовых данных.....	36
3.5 Определение метрик эффективности для MVPError! Bookmark not defined.	
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	39

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И ОБОЗНАЧЕНИЙ

1. ВКРС — выпускная квалификационная работа в виде стартапа.
2. RAG — Retrieval-Augmented Generation, генерация с дополненной выборкой.
3. MVP — Minimum Viable Product, минимально жизнеспособный продукт.
4. ИИ — искусственный интеллект
5. UX — User Experience, пользовательский опыт
6. UI — User Interface, пользовательский интерфейс
7. LLM — Large Language Models, большие языковые модели
8. NLU — Natural Language Understanding, понимание естественного языка
9. LPU — Language Processing Unit, тип процессора, разработанный для ускорения работы ИИ для LLM
10. ML — Machine Learning, машинное обучение
11. API — Application Programming Interface, прикладной программный интерфейс
12. СУБД — Система Управления Базами Данных
13. FPS — Frames per Seconds, кадры в секунду

ВВЕДЕНИЕ

Развитие цифровых экосистем и сервисов бронирования приводит к трансформации модели потребительского поведения в индустрии досуга и туризма. Современные платформы-агрегаторы ориентированы на предоставление максимального количества вариантов (сотни ресторанов, десятки развлекательных событий), которые отличаются по локации, ценовой категории и рейтинговым показателям.

Важной проблемой становится когнитивная перегрузка пользователя, возникающая при обработке избыточных массивов данных. Традиционные методы фильтрации контента, такие как фасетный поиск, недостаточно эффективны в условиях, когда пользователю важна не просто выборка по параметрам, а персонализированная рекомендация, учитывающая скрытый контекст, например: настроение, состав группы, временные ограничения. Одним из основных направлений развития в данной области является создание интеллектуальных диалоговых агентов, Conversational AI, способных брать на себя функцию предварительного отбора и сужения выборки для пользователя.

Актуальность исследования обусловлена противоречием между стремительным ростом количества предложений на рынке досуга и ограниченными психофизиологическими ресурсами человека для принятия решений. Значительная часть пользователей сталкивается с феноменом «парадокса выбора» (Choice Overload), когда изобилие альтернатив ведет не к удовлетворенности, а к отказу от совершения действия или снижению субъективной оценки результата [1]. В связи с этим возникает необходимость разработки технологий, обеспечивающих интеллектуальное ограничение выдачи на основе анализа предпочтений пользователя.

Объектом исследования являются рекомендательные системы и диалоговые интерфейсы как инструмент для организации досуга и планирования времени.

Предмет исследования — методы и алгоритмы персонализированного поиска, направленные на снижение когнитивной нагрузки пользователя посредством сужения выборки релевантных альтернатив.

Цель данной выпускной квалификационной работы заключается в персонализации подбора мест для проведения досуга на основе приложения, использующего RAG подход, для формирования ответов по запросам пользователей

Для достижения поставленной цели необходимо **решить следующие задачи:**

1. Провести сравнительный анализ существующих сервисов подбора досуга и выявить ограничения используемых в них алгоритмов рекомендаций и поиска;
2. Провести анализ предметной области и исследовать проблему избыточного выбора в цифровых сервисах досуга;
3. Спроектировать структуру базы данных, определить основные сущности, связи и требования к хранению данных;
4. Определить источники данных и выполнить постановку задачи по сбору и подготовке данных для наполнения базы данных и обеспечения работы рекомендательной системы;
5. Описать основные алгоритмы функционирования системы и сценарий взаимодействия пользователей с системой;
6. Спроектировать и разработать базу данных.

Проблема исследования заключается в том, что существующие агрегаторы позволяют осуществлять поиск по формальным критериям, однако они лишены механизмов контекстного понимания запроса и инструментов для совместного принятия решений группой пользователей. В условиях отсутствия «умного ограничения» наблюдается повышенная вероятность

неудовлетворенности пользователя, известная как «усталость от принятия решений» (Decision Fatigue) [1].

Теоретическая значимость исследования заключается в систематизации подходов к проблеме парадокса выбора в цифровой среде и обосновании эффективности модели «умный короткий список» (Smart Shortlist) по сравнению с моделью «бесконечная лента» (Infinity Scroll).

Практическая значимость работы заключается в создании детализированной аналитической спецификации мобильного приложения “Search My Way”, включающей в себя функциональные и нефункциональные требования, архитектуру модели, информационную структуру базы данных, а также алгоритмы работы RAG-пайплайна и группового голосования. Полученные результаты могут быть непосредственно использованы командой разработки для реализации MVP.

Структура выпускной квалификационной работы соответствует требованиям методических рекомендаций и включает аннотацию, оглавление, перечень сокращений и обозначений, введение, три основных раздела, заключение, список использованных источников и приложения.

В первой главе рассматриваются теоретические основы проблемы когнитивной перегрузки пользователя в цифровых сервисах, проводится обзор зарубежных и отечественных решений для подбора досуга, выявляются их функциональные ограничения и обосновывается актуальность разработки интеллектуальной рекомендательной системы.

Вторая глава посвящена анализу методов и технологий реализации рекомендательных систем на основе диалогового ИИ, обоснованию выбора технологического стека, а также формированию функциональных и нефункциональных требований и архитектурному проектированию приложения.

Третья глава ориентирована на практическую аналитическую проработку данных, которые необходимы для функционирования рекомендательной системы. В ней представлены результаты анализа доступных открытых источников информации, а также обоснована необходимость создания собственного тестового набора данных и описан процесс его ручного формирования. Проводится детальное описание структуры датасета и процедура нормализации, векторизации и загрузки в базу данных. Проведено тестирование гибридного поиска.

1. Анализ проблем выбора в цифровых сервисах досуга и обзор рынка рекомендательных систем

1.1 Зарубежные исследования и глобальные тренды

Современные зарубежные исследования в области электронной коммерции и психологии потребления характеризуются пересмотром парадигмы «чем больше выбор, тем лучше». Ключевым теоретическим базисом является концепция «парадокса выбора», сформулированная социологом Барри Шварцем. Согласно аналитическим публикациям и монографиям, экспоненциальный рост вариантов ведет к снижению мотивации пользователя.

Одним из наиболее заметных теоретических положений является утверждение Б. Шварца о нелинейной зависимости благополучия от свободы выбора. В зарубежных работах подчеркивается, что при пересечении определенного порога изобилие начинает играть деструктивную роль. Как отмечает Шварц: «По мере роста числа вариантов...позитивные аспекты сменяются негативными. По мере дальнейшего роста числа вариантов негативные эффекты нарастают до тех пор, пока мы не становимся перегруженными. В этой точке выбор больше не освобождает, а ослабляет» [1].

Для наглядной демонстрации зависимости между количеством альтернатив и уровнем удовлетворенности пользователя целесообразно привести графическую интерпретацию модели Б. Шварца (Рисунок 1.1).

Рисунок 1.1 — График зависимости удовлетворенности от количества опций



Как видно из графика, функция полезности имеет форму перевернутой параболы. На начальном этапе (зона А) увеличение выбора воспринимается позитивно, так как дает ощущение свободы. Однако после прохождения точки экстремума (зона Б — «Пик удовлетворенности») каждая новая добавленная опция начинает снижать субъективную ценность выбора из-за роста когнитивных издержек на сравнение и страха упущенной выгоды. Большинство современных агрегаторов находятся в правой части графика (зона В), где эффективность взаимодействия критически падает [1]. Наша система стремится вернуть пользователя в зону Б за счет искусственного ограничения выдачи.

Эмпирическим подтверждением данной теории служат исследования поведения потребителей (Iyengar & Lepper), которые демонстрируют прямую корреляцию между сокращением ассортимента и ростом конверсии. В классическом эксперименте сокращение набора альтернатив с 24 до 6 привело к десятикратному росту покупок (с 3% до 30%) [2]. Это создает основу для пересмотра UX/UI стратегий глобальных сервисов.

В ответ на эти вызовы индустрия TravelTech внедряет новые стандарты взаимодействия. Согласно отчету Booking.com “Travel Predictions 2024”, наблюдается фундаментальный сдвиг в сторону делегирования планирования искусственному интеллекту [3]. Так 48% пользователей готовы доверить ИИ

построение маршрутов путешествия, чтобы избежать рутинной работы по сравнению десятков вкладок браузера.

Особое внимание уделяется гиперперсонализации. Исследования консалтинговой компании McKinsey & Company показывают, что 71% потребителей ожидают от сервисов предиктивного поведения — предложения вариантов, основанных на их прошлых действиях и текущем контексте, а не просто выдачи каталога с фильтрами. Компании, внедряющие такие подходы, демонстрируют рост выручки на 40% [4].

Таким образом, анализ зарубежных источников позволяет выделить следующие устойчивые направления развития сервисов досуга:

- переход от поисковых строк к диалоговым интерфейсам — Conversational AI;
- использование алгоритмов искусственного интеллекта для ограничения выдачи;
- интеграция психографических параметров, таких как настроение, стиль отдыха, в алгоритмы ранжирования.

Данные тенденции подтверждают высокий интерес индустрии к созданию систем, способных не только агрегировать данные, но и брать на себя ответственность за первичный отсев нерелевантных вариантов.

1.2 Отечественные исследования и специфика рынка Российской Федерации

В Российской Федерации рынок цифровых сервисов для организации досуга находится на этапе зрелости технологий агрегации, но активного развития рекомендательных алгоритмов. Для отечественных исследований и продуктов характерна высокая степень централизации данных в рамках крупных экосистем.

Согласно данным Mediascope (2024), охват сервисов компании Яндекс составляет 83% населения, что делает платформы «Яндекс.Карты» и «Яндекс.Еда» доминирующими игроками [5]. В работах российских аналитиков отмечается, что данные сервисы эффективно решают задачу навигации и транзакций, однако их рекомендательный потенциал ограничен моделью «геопозиция + рейтинг».

Функциональный анализ ключевых отечественных игроков на рынке выявляет следующие особенности:

- Яндекс.Карты [6] / 2ГИС [7]: ориентированы на работу с каталогом. Пользователь вынужден самостоятельно настраивать множество фильтров. Рекомендации строятся на массовой популярности «Топ мест...», что часто не соответствует индивидуальному запросу «здесь и сейчас»;
- KudaGo [8]: специализируется на событийном контенте. Основной формат потребления — просмотр редакционных подборок «Куда пойти в выходные». Это снижает усилия на поиск, но не решает проблему персонализации, так как подборки статичны и одинаковы для всех;
- локальные стартапы (например, «Кавёр» [9]): предпринимают попытки внедрения свайп-механик, однако ограничены узкой географией (Москва, Санкт-Петербург) и отсутствием инструментов для анализа групповых предпочтений.

Для систематизации недостатков существующих решений было проведено функциональное сравнение ключевых игроков рынка. Результаты анализа представлены в Таблице 1.1

Таблица 1.1 — Матрица функционального сравнения сервисов досуга

Функция / Критерий	Яндекс.Карты / 2ГИС	KudaGo	TripAdvisor	Search My Way (Разрабатываемое)
--------------------	---------------------	--------	-------------	---------------------------------

Основной сценарий	Навигация и поиск конкретного места	Просмотр афиши событий	Чтение отзывов туристов	Интеллектуальный подбор
Учет контекста (ИИ)	Нет (только фильтры)	Нет (статичные подборки)	Нет	Есть
Групповой выбор досуга	Нет (пересылка ссылок)	Нет	Нет	Есть (групповые лобби в реальном времени)
Свайп-механика	Нет	Нет	Нет	Есть
Персонализация	История поиска	История просмотров	История оценок	Векторный профиль интересов

На основе данной матрицы можно сделать вывод, что ни один из прямых конкурентов не закрывает потребность в социальной координации (групповой выбор) и диалоговом поиске, что подтверждает наличие свободной рыночной ниши для разрабатываемого продукта.

В отечественной практике остается нерешенной проблема группового выбора. Для молодежного сегмента (18-25 лет) критически важен процесс согласования места встречи. В текущих реалиях это происходит в мессенджерах, что приводит к дезорганизации и конфликтам между участниками группы ввиду того, что приходится постоянно переключаться между мессенджером и приложением или сайтом с подбором места. На российском рынке практически отсутствуют массовые инструменты, автоматизирующие компромисс через игровые механики.

Актуальные направления развития отечественных сервисов включают создания суперприложений, однако ниша специализированных ИИ-помощников для досуга, работающих по принципу «консьерж-сервиса», остается свободной.

1.3 Общая характеристика проблемы исследования

Анализ зарубежных трендов и отечественного рынка позволяет сформулировать основные проблемы, препятствующие эффективной реализации пользовательских сценариев при поиске досуга.

Во-первых, наблюдается технологический разрыв между ожиданиями пользователей и функционалом интерфейсов. С одной стороны, 89% пользователей готовы использовать ИИ для упрощения жизни [3]. С другой стороны, существующие агрегаторы предлагают интерфейсы десятилетней давности, заставляющие пользователя выполнять роль «фильтра» данных.

Во-вторых, проблема когнитивной нагрузки, она же «парадокс выбора», игнорируется большинством сервисов в угоду рекламной модели монетизации, которая требует показа максимального количества позиций. Это приводит к снижению лояльности аудитории и увеличению времени принятия решения.

В-третьих, существующие решения не учитывают динамический контекст. Потребности пользователя в пятницу вечером с друзьями и в понедельник днем, например бизнес-ланч, кардинально отличаются, однако традиционные алгоритмы часто предлагают одни и те же заведения, основываясь только на истории посещений, без возможности уточнения «намерений» через диалог.

Кроме того, остается нерешенной задача социальной координации. Процесс выбора места для группы людей является стрессовым фактором, и отсутствие инструментов для «слепого голосования» или автоматического подбора пересечений интересов снижает частоту совместных выходов.

Таким образом, разработка приложения “Search My Way” является ответом на подтвержденный рыночный запрос на снижение информационной перегрузки и автоматизацию рутины выбора. Решение проблемы требует перехода от модели «Поиск» к модели «Рекомендация и Действие».

Выводы по первой главе

В главе 1 был проведен анализ предметной области, который показал, что:

1. Феномен «парадокса выбора» и связанная с ним когнитивная перегрузка пользователей являются фундаментальной проблемой современных сервисов-агрегаторов;
2. Зарубежные тренды демонстрируют переход к диалоговым ИИ-интерфейсам и гиперперсонализации, что подтверждается исследованиями Booking.com и консалтинговой компанией Mckinsey & Company;
3. Отечественный рынок представлен агрегаторами, лишенными механизмов группового выбора и контекстного диалогового поиска;
4. Выявлена свободная ниша для стартапа “Search My Way”, сочетающего в себе интеллектуальный подбор через чат-интерфейс и уникальную механику спайп-голосования.

Полученные выводы обосновывают актуальность и своевременность разработки рекомендательной системы “Search My Way”.

2. Проектирования рекомендательной системы “Search My Way”: технологии, требования и архитектура

2.1 Анализ и обоснование выбора технологий

Проектирование архитектуры интеллектуальной системы поиска досуга требует анализа существующих методологических подходов к обработке естественного языка и ранжированию данных, а также тщательного подбора технологического стека, обеспечивающего высокую производительность, масштабируемость и соответствие бизнес-требованиям стартапа. В рамках данного раздела проведен сравнительный анализ ключевых компонентов системы, а именно: серверной платформы, лингвистических моделях, системы хранения данных и клиентского фреймворка.

Серверная платформа: сравнение Go и Python

Выбор языка программирования для серверной части (бэкенда) определяет производительность, надежность и стоимость эксплуатации приложения.

Рассматривались два основных претендента — Python и Go.

Таблица 2.1 – Сравнительный анализ серверных технологий

Характеристика	Python	Go	Влияние на проект “Search My Way”
Модель конкурентности	Ограничена из-за особенностей внутреннего механизма выполнения кода. При большом количестве одновременных соединений возможны задержки.	Специально спроектирован для эффективной работы с тысячами параллельных подключений с помощью легковесных горутин.	В приложении будет много пользователей в групповых комнатах. Go позволит держать их все без падения производительности.

Производительность	Средняя скорость работы. Требуется дополнительных настроек для ускорения.	Высокая скорость работы. Код компилируется в быстрый исполняемый файл, близкий к скорости C/C++.	Долгий ответ для пользователя, может сказаться на негативном опыте использования приложения, Go обеспечит быстрый отклик системы.
Типизация	Типы переменных определяются автоматически во время работы, что может привести к множественным ошибкам	Все типы данных проверяются на этапе сборки приложения, что снижает вероятность ошибок.	Серверная часть должна быть надежной. Строгая проверка в Go минимизирует риски падения сервера из-за случайной опечатки.
Экосистема ML	Python — основной язык для машинного обучения.	Экосистема для ИИ слабо развита.	Т.к. инференс ML вынесен в API/контейнеры, преимущество Python нивелируется.

Благодаря своей производительности, надежности и устойчивой работе с real-time функционалом группового выбора, было принято решение использовать Go для разработки бэкенда [10].

Лингвистическая платформа: выбор моделей для RAG-пайплайна

Для нашего приложения критическим важным компонентом системы является набор моделей искусственного интеллекта, отвечающих за понимание запросов, семантический поиск и генерацию ответов пользователю. В качестве платформы для инференса выбран сервис Groq, предоставляющий высокоскоростной доступ к современным LLM через API [11].

Таблица 2.2 – Сравнительный анализ LLM-провайдеров для рынка РФ

Критерий	OpenAI GPT-OSS-120B (Groq) [12]	Llama 4 Scout 17B (Groq) [13]	Intfloat/multilingual-e5-base [14]
Назначение в проекте	Основная чат-модель: генерация персонализированных рекомендаций,	NLU-модуль [21]: быстрая классификация интенгов, извлечение	Эмбединг-модель: векторизация текстовых запросов и описаний заведений для

	ведения диалога с пользователем.	параметров, предварительная фильтрация.	семантического поиска [20].
Ключевые особенности	120 млрд параметров, контекстное окно 128 тысяч токенов, встроенная поддержка вызова функций.	17 млрд параметров, нативная мультимодальность, рекордное контекстное окно 10 млн токенов.	Модель с открытым исходным кодом, обучена на 100+ языках, размерность вектора – 768.
Производительность	Более 500 токенов/с на GroqCloud.	Высокая скорость инференса на LPU Groq.	Лучший среди мультязычных моделей.
Роль в архитектуре	Генерация итогового ответа пользователю на основе контекста и истории диалога.	Предварительная обработка запроса, классификация интента, выделение сущностей.	Поиск семантически близких заведений в базе данных.

Примечание: Llama 4 Scout разработана компанией Meta Platforms Inc., которая признана экстремистской организацией и запрещена на территории Российской Федерации.

Для проекта была выбрана гибридная структура с использованием трех специализированных под разные задачи моделей. Такой подход позволит распределить нагрузку и достичь максимальной эффективности на каждом этапе обработки запроса при сохранении экономической целесообразности.

Стратегия хранения данных: PostgreSQL + pgvector

Для реализации гибридного поиска, объединяющего геопространственные запросы и семантическое ранжирование, было принято решение использовать единую реляционную СУБД с векторным расширением. Сравнение подходов представлено в таблице 2.3

Таблица 2.3 – Сравнительный анализ архитектур хранения векторов

Критерий	Специализированная Векторная БД (Qdrant)	Расширение для Реляционной БД (PostgreSQL + pgvector)	Решение аналитика
Архитектура	Нужно поддерживать и настраивать два разных хранилища данных. Сложнее делать резервные копии и следить за согласованностью	Единый сервис. Проще администрировать.	Для стартапа важна простота поддержки, поэтому одна база снижает затраты на обслуживание.
Согласованность данных	Векторы и основная информация заведения могут расходиться при сбоях.	Обновления происходят в рамках одной транзакции. Данные всегда согласованны.	Надежность для нас критичная, так как не можем допустить неверную рекомендацию или устаревшую информацию для пользователя.
Сложность запросов	Сложно комбинировать поиск «по смыслу» с обычными фильтрами. Придется делать два запроса и объединять вручную.	Можно в одном SQL-запросе одновременно и искать по критерию, и фильтровать по другому критерию.	Так как у нас гибридный поиск, нужно одновременно учитывать геопозицию и семантическую

			близость. Pgvector позволяет делать это просто и быстро.
Производительность	Может обрабатывать миллиарды векторов, но для старта это избыточно и дорого.	Справляется с десятками миллионов векторов без потери скорости.	На старте в базе будет ограниченное количество заведений, так что возможностей pgvector хватит с запасом.

Решение: выбран стек PostgreSQL с расширением pgvector [15], позволяющим хранить и совершать поиск по эмбедингам. Это минимизирует инфраструктурную сложность и гарантирует целостность данных.

Клиентская часть: Flutter

Для мобильного приложения проведено сравнение кроссплатформенных фреймворков Flutter и React Native.

Таблица 2.4 – Сравнительный анализ фреймворков мобильной разработки

Параметр	React Native	Flutter [16]	Преимущество для проекта
Графический движок	Использует нативные UI-компоненты.	Рисует каждый пиксель самостоятельно. Приложение выглядит одинаково на любых устройствах.	Один и тот же дизайн на разных системах.

Производительность	Связь между кодом и элементами происходит через мост. Возможны просадки FPS.	Код напрямую управляет графикой без посредников. Приложение работает плавно и быстро.	Стабильные 60–120 FPS критичны для плавности свайп-механики.
Стабильность	Зависит от изменений в сторонних библиотеках. После обновления операционной системы могут возникать ошибки.	Не зависит от обновлений в системе, поэтому работает стабильно даже на новых версиях.	Снижение затрат на поддержку старых устройств.

Клиентская часть, разрабатываемая на фреймворке Flutter, обеспечит высокое качество пользовательского интерфейса и плавность анимации, необходимых для реализации механики свайпов.

2.2 Функциональные и нефункциональные требования

На основе анализа предметной области и выбранных технологий были сформулированы требования к разрабатываемой системе. Они разделены на функциональные, которые определяют поведение системы, и нефункциональные, которые определяют качественные характеристики.

Таблица 2.5 – Функциональные требования

Требование	Описание
Авторизация и профилирование	Система должна обеспечивать регистрацию пользователей (номер телефона), хранение их устойчивых предпочтений (любимые кухни, аллергии, средний чек) и истории взаимодействий.
Семантический гео-поиск	Система должна обрабатывать естественно-языковые запросы (например, «где поесть рамен недалеко от центра») и ранжировать

	результаты на основе векторной близости (multilingual-e5-base) и удаленности пользователя (PostGIS).
ИИ-консультант (RAG)	Система должна поддерживать диалог с пользователем, отвечая на уточняющие вопросы о меню, атмосфере и ценах, используя контекст, извлеченный из базы данных, для минимизации галлюцинаций.
Управление Лобби (Group Lobby)	Система должна позволять создавать виртуальные «комнаты» для группы пользователей, генерировать ссылки для приглашения и синхронизировать статус участников через WebSocket соединение.
Коллективное свайп-голосование	Система должна реализовывать механику «свайпов» (лайк/дизлайк) для списка заведений. Алгоритм должен в реальном времени определять совпадение (Match) и уведомлять всех участников об одобрении одного места.
Генерация резюме	Система должна отображать карточку заведения с фото, рейтингом и сгенерированным кратким резюме, объясняющим, почему это место рекомендовано конкретной группе.

Таблица 2.6 — Нефункциональные требования


Категория	Требование
Производительность	Время ответа на поисковый запрос, включая RAG-генерацию не должно превышать 2 секунд. Синхронизация свайпа в групповом режиме не должна происходить с задержкой более 100 мс.
Масштабируемость	Архитектура должна поддерживать горизонтальное масштабирование серверной части для обслуживания большого количества одновременных пользователей без деградации сервиса.
Кроссплатформенность	Клиентское приложение на Flutter должно обеспечивать идентичное отображение интерфейса и функциональность на операционной системе Android и iOS

2.3 Архитектурная модель системы

Архитектурная система спроектирована в соответствии с принципом Clean Architecture [17], при котором фреймворк и базы данных независимы друг от друга, что обеспечивает гибкость, разделение ответственности, тестируемость и долгосрочную поддержку системы, а также принципом микросервисного подхода.

Варианты использования, определяющие взаимодействие основных акторов с системой, представлены на диаграмме Use Case.

Рисунок 2.1 — Use Case диаграмма




В системе выделены два ключевых актора:

- пользователь — инициатор запросов, которые имеет возможность управлять личным профилем, инициировать одиночный поиск через чат и создавать групповые комнаты;
- ИИ-ассистент LLM модуля — внешний актор, который обеспечивает классификацию интенентов, векторизацию запросов и генерацию ответов.

Центральным же процессом в системе является обработка пользовательского запроса с использованием RAG-пайплайна [18], [22]. Диаграмма последовательности этого процесса приведена на рисунке 2.2.

Рисунок 2.2 — Диаграмма последовательности обработки запроса




Составляющие потока данных:

1. Инициация запроса: пользователь вводит естественно-языковой запрос в чате мобильного приложения;
2. Классификация интента (NLU): бэкенд направляет запрос к модели Llama 4 Scout для быстрой классификации интента и извлечение ключевых параметров (тип заведения, ценовая категория, особые пожелания);
3. Векторизация запроса: текст запроса передается модели multilingual-e5-base для получения векторного представления, он же эмбединг;
4. Гибридный поиск: бэкенд выполняет SQL-запрос к PostgreSQL, объединяя пространственную фильтрацию по радиусу от текущей геопозиции пользователя и ранжирование по сходству между вектором запроса и векторами заведений. База данных возвращает ограниченный список из наиболее релевантных заведений;
5. Генерация ответа: сервер формирует системный промпт, который включает в себя: роль ассистента, параметры, извлеченные на этапе NLU, структурированный контекст и историю диалога. Запрос отправляется к модели OpenAI GPT-OSS-120B для генерации финального персонализированного ответа;

6. Доставка итогового результата: бэкенд объединяет сгенерированный текст и структурированные карточки заведений и возвращает его клиентскому приложению для отображения пользователю.

Схема базы данных спроектирована на рисунке 2.3 и отражает структуру хранения информации, необходимую для функционирования рекомендательной системы “Search My Way”.

Рисунок 2.3 — ER-диаграмма базы данных



Центральное место в модели занимают две ключевые сущности, а именно Пользователь и Заведение. Остальные таблицы реализуют связи между ними или расширяют их атрибутивный состав. Рассмотрим эти таблицы:

Таблица users хранит учетные и профильные данные зарегистрированных пользователей. Помимо стандартных атрибутов, таких

как имя, фамилия, дата рождения и контактные данные, таблица содержит важное для проекта поле `context`, в котором в структурированном виде сохраняется профиль предпочтений пользователя, формируемый на основе его истории взаимодействия с приложением, что позволяет системе быстро адаптировать рекомендации без повторного анализа всей истории.

Таблица `places` содержит основную информацию о заведениях. Ее ключевые атрибуты включают в себя:

- `coordinate` — географические координаты, используемые для пространственных запросов;
- `price_level` — оценка уровня цен заведения;
- `rating` — среднее значение пользовательского рейтинга заведения.

Таблицы `place_media`, `place_dining`, `place_parks` и `place_leisure` реализуют связь «один-ко-многим» с таблицей `place`, а также расширяют ее атрибуты. Например, атрибуты `type` и `cuisine_type` в `place_dining` отвечают за тип заведения (кафе, ресторан, бар) и тип кухни заведения соответственно. Атрибуты `media_type`, `park_type` и `activity_type` в таблицах `place_media`, `place_parks` и `place_leisure` схожим образом отвечают за тип заведения: для `media` – это кинотеатры, театры, музеи и т.д., для `park` – это парки, скверы, ботанические сады и т.д., а для `leisure` – это разнообразные развлечения, например, аквапарки, парки аттракционов, боулинг и т.д.

Также на рисунке 2.3 показаны таблицы для реализации механик взаимодействия:

- `user_swipes` — журнал действий пользователя в режиме свайп-голосования. Каждая запись фиксирует идентификатор пользователя и результат (`liked`: «1» — лайк, «0» — дизлайк);
- `user_favourites` — список избранных мест пользователя;
- `group_rooms` — временная сущность, которая описывает групповую сессию. Включает в себя идентификатор создателя, временные метки создания

и истечения срока действия, а также текущий статус комнаты (ожидание, голосование, завершено);

- `group_participants` — связующая таблица между пользователями и групповыми комнатами, которая определяет состав участников конкретной сессии;
- `group_votes` — таблица, фиксирующая голоса участников в рамках групповой сессии. Позволяет алгоритму в реальном времени определять совпадение (*match*), когда все участники выразили одобрение одному и тому же месту.

Связи между сущностями:

Пользователь может иметь множество записей о свайпах, избранных местах и участиях в групповых комнатах.

Заведение может иметь несколько фотографий и одну запись с дополнительной информацией.

Групповая комната содержит несколько участников и связана со множеством голосов.

Данная структура данных обеспечивает эффективное выполнение операций, таких как гибридный поиск, агрегацию предпочтений пользователя, синхронизацию групповых сессий и хранение взаимодействий для последующего анализа и улучшения качества рекомендаций.

Логика работы группового подбора описывается конечным автоматом. Диаграмма состояний сущности «Лобби» представлена на рисунке 2.4.

Рисунок 2.4 — Диаграмма состояний групповой сессии



Жизненный цикл сессии включает следующие состояния:

- Created (создано) — инициатор получил ссылку, ожидается подключение других участников;
- Active (голосование) — все участники подключены, система начинает отправлять карточки заведений. В этом состоянии сервер принимает входящие события “Swipe”;
- Matched (совпадение) — успешное завершение сессии. Система выдает финальную карточку всем участникам и закрывает возможность голосования;
- Expired (истекло) – состояние тайм-аута. Если активность в комнате отсутствовала в течение определенного времени, сессия завершается автоматически.

Выводы по второй главе

Во второй главе было выполнено проектирование рекомендательной системы “Search My Way”:

1. Проведен анализ и обоснован выбор технологического стека, а именно, серверная часть на языке Go, клиентская часть на Flutter, система хранения данных на базе PostgreSQL с расширением pgvector;

2. Выбрана гибридная архитектура ИИ-модуля с использованием трех моделей, доступных через платформу Groq: Llama 4 Scout для NLU-обработки, multilingual-e5-base для векторизации и OpenAI GPT-OSS-120B для генерации ответов;
3. Сформулированы функциональные и нефункциональные требования к системе, которые охватывают производительность, масштабируемость и кроссплатформенность;
4. Разработана архитектурная модель, которая включает в себя диаграммы вариантов использования, последовательности обработки RAG-запросов, Eг-диаграмму базы данных и диаграмму состояний групповой сессии.

Полученные результаты формируют полную проектную документацию, которой достаточно для перехода к аналитической детализации и последующей программной реализации MVP.

3. Аналитическая проработка данных и оценка качества рекомендательной системы

В данной главе представлены результаты практической составляющей работы, выполненной в рамках аналитического обеспечения стартапа “Search My Way”. Основное внимание было уделено процессам сбора, подготовки и оценки данных, так как это важнейшая составляющая для функционирования интеллектуальной рекомендательной системы. Рассмотрены этапы анализа доступных источников данных, формирования собственного набора данных, его структурирования и загрузки в базу данных, и в последствии, было проведено тестирование гибридного поиска с определением метрик качества для MVP.

3.1 Анализ доступных источников данных

Первым этапом практической работы стало исследование открытых источников данных, о заведениях различных типов категории, например, рестораны, кафе, а также культурные и развлекательные объекты города Москва. Целью анализа являлось получение готового структурированного набора данных, который мог бы напрямую быть использован для наполнения базы данных приложения и тестирования алгоритмов семантического поиска.

Первым ограничением стал очень маленький набор датасетов в открытых источниках, поэтому в качестве основного источника данных рассматривался Портал открытых данных Правительства Москвы [19], так как он содержал в себе разнообразные наборы данных о городской инфраструктуре. В результате поисков были изучены следующие датасеты:

- «Реестр объектов общественного питания»;
- «Перечень парков культуры и отдыха»;
- «Реестр организаций культуры и искусства»;
- «Список кинотеатров города Москва».

После проведенного анализа данных был выявлен ряд существенных ограничений, делающий невозможным прямое использование этих данных в целях разработки рекомендательной системы. В ряд ограничений входит:

1. Неполнота и неактуальность информации: значительная часть записей содержит устаревшие сведения о местонахождениях заведений, многие объекты на данный момент даже прекратили свою деятельность;
2. Отсутствие содержательных текстовых описание: для реализации семантического поиска на основе векторных представлений критически важным является наличие развернутого текстового описания каждого заведения, которое отражала бы его особенность, атмосферу, тип кухни и подобные характеристики. В открытых же данных такие описания либо полностью отсутствовали, либо были представлены краткими формальными строками («кафе», «ресторан»), что в корне не удовлетворяет критериям для построения качественных эмбедингов;
3. Абсолютное отсутствие мультимедийных материалов: в датасетах не содержалось ни файлов, ни ссылок на фотографии интерьеров или внешнего вида заведений, что не позволяло сформировать карточки мест для пользовательского интерфейса;
4. Отсутствие ценовой категории: информация о среднем чеке или уровне цен, которая необходима для фильтрации и персонализации рекомендаций, также не предоставлялась в открытых источниках;
5. Неоднородность форматов и классификации: разные наборы данных содержали различных схемы категоризации объектов, что требовало дополнительных усилий по унификации параметров;
6. Огромная часть лишней информации или лишних заведений: например, в категориях заведений общественного питания было представлено большое множество школьных столовых, вход в которые для обычного прохожего недоступны.

Таким образом, было определено, что использование открытых данных Правительства Москвы в исходном виде не соответствует требованиям проекта. Поэтому было принято решение самостоятельно сформировать тестовый набор данных, который будет включать в себя все необходимые атрибуты, а также будут отражать разнообразие мест и заведений для тестирования ключевых функций системы.

3.2 Формирование тестового набора данных

Для создания собственного датасета была сформирована методика ручного сбора и структурирования информации о заведениях города Москвы. Выборка составлялась таким образом, чтобы охватить различные категории объектов и географические районы, что необходимо для гибридного поиска, сочетающего семантическую близость и геопространственную фильтрацию.

Отбор заведений осуществлялся на основе личного знания городской инфраструктуры с помощью открытых картографических сервисов, в нашем случае, Яндекс.Карты [6]. Приоритет отдавался заведениям с развернутым описанием, большим количеством пользовательских отзывов, а также фотографиями самого заведения, что позволяло составить качественную информацию о нем.

Для каждого заведения в Microsoft Excel фиксировались следующие атрибуты:

- name — полное наименование места или заведения;
- category — категория объекта (dining, park, media, leisure);
- address — адрес места или объекта;
- coordinates — географические координаты, полученные с помощью встроенных функций Яндекс.Карт;
- description — текстовое описание, взятое с официальных сайтов, отзывов и информации в открытых источниках. Оно включало ключевые слова, характеризующие атмосферу, кухню, а также

другие особенности для повышения релевантности семантического поиска;

- price_level — средний чек;
- rating — усредненный пользовательский рейтинг заведения;
- type — тип заведения общественного питания (ресторан, кафе, бар);
- cuisine_type — тип кухни (русская, японская и т.д.);
- photo_url — ссылка на фотографию, доступную на открытых источниках.

В результате отбора был сформирован набор данных, состоящий из 82 заведений, распределенный по категориям:

Таблица 3.1 — Распределения заведений в тестовом датасете по категориям

Категория	Количество	Доля, %
Рестораны, кафе, бары (dining)	25	30,5
Парки и зоны отдыха (park)	13	15,9
Развлекательные объекты (leisure)	30	36,6
Культурные учреждения (media)	14	17,1
Итого	82	100

Структура записи в тестовом датасете выглядела следующим образом:

Таблица 3.2 — Пример структуры в тестовом датасете

Атрибут	Значение
name	Buba by Sumosan
category	dining
address	Пресненская наб., 8, стр. 1
coordinates	55.747314, 37.539168
description	Buba by Sumosan — камерный сетевой суши-бар с лояльными ценами на Цветном бульваре. Пространство лаконичное и светлое, с окнами в пол на

	бульвар. Азиатское настроение создают минималистичные фрески и яркий декор. В меню — суши, роллы, сашими, гедза, лапша.
price_level	1700
rating	4.5
type	Суши бар
cuisine_type	Японская
photo_url	https://rests.afisha.ru/uploads/6/b9/6b992ea97e94418997b2aeb123253d50.jpg

Далее сформированный датасет был экспортирован в формат CSV для последующей загрузки в базу данных PostgreSQL.

3.3 Подготовка данных к загрузке в базу данных и векторизация

Перед импортом датасета в базу данных потребовалось выполнить их предварительную обработку, включающую нормализацию текстовых полей и получение векторных представлений для описания заведений.

В Microsoft Excel были выполнены следующие операции:

- удаление лишних пробелов и символов переноса строк в текстовых полях;
- проверка корректности географических координат и формата адресов;
- унификация значений категорий (приведены к нижнему регистру).


Для обеспечения возможности семантического поиска каждое текстовое описание было преобразовано в векторное представление, эмбединг, с использованием модели multilingual-e5-base [14], которая отличается высоким качеством работы с русскоязычными текстами.

Процесс векторизации был реализован с использованием API платформы Groq. Полученные векторы были добавлены в датасет в виде отдельного столбца embedding, после чего данные были загружены в таблицы базы данных PostgreSQL согласно спроектированной ER-диаграмме (рисунок 2.3).

3.4 Тестирование гибридного поиска на тестовых данных

После загрузки данных в базу было проведено ручное тестирование гибридного поиска с целью оценки качества ранжирования и релевантности выдаваемых результатов. Тестирование выполнялось путем отправки поисковых запросов через тестовый интерфейс чата приложения и анализа полученных списков заведений (рисунок 3.1).

Рисунок 3.1 — Пример тестового запроса в интерфейсе чата приложения



Был подготовлен набор из 12 тестовых запросов, имитирующих типичные пользовательские сценарии. Запросы формулировались на естественном языке и охватывали различные комбинации семантических и географических критериев. Пример запроса показан на рисунке 3.1. Для

каждого запроса фиксировались результаты, выданные системой, и оценивалась их релевантность по трехбалльной шкале, где:

- 2 — полностью релевантно (заведение точно соответствует запросу);
- 1 — частично релевантно (соответствует не всем критериям или имеет косвенное отношение);
- 0 — нерелевантно.

Результаты тестирования приведены в таблице 3.3.

Таблица 3.3 — Результаты тестирования гибридного поиска

№	Тестовый запрос	Результат 1	Результат 2	Результат 3	Результат 4	Результат 5	Средняя релевантность
1	«Уютное кафе с десертами недалеко от метро Пушкинская»	Sapera vi Café (2)	Мама Тута (2)	Джонджоли (1)	Дом, в котором (1)	Кабинет 3,14 (1)	1,4
2	«Романтическое место для свидания при свечах»	Petite Decadence (2)	Balzi Rossi (2)	Assunta Madre (2)	Savva (1)	Мама Тута (1)	1,6
3	«Развлекательный центр с боулингом и бильярдом»	Дорожка (2)	8 Шаров (2)	LASERLAND (1)	Semenov Club (1)	JoyHouse Bowling (1)	1,4
4	«Театр с классическими	Большой	Московский Драматический	Государственный Кремлевский	Московский Международный	Кинозал Гума (0)	1,2

	постановка ми в центре»	театр (2)	ский Театр «Модернь » (2)	й Дворец (1)	дный Дом Музыки (1)		
5	«Парк для прогулки с собакой на северо- западе Москвы»	Парк Горько го (2)	Измайловс кий парк (2)	Лианозовск ий парк (1)	Ботаническ ий сад МГУ (0)	Сад «Эрмит аж»	1,0

Средняя релевантность по всем запросам составила 1,32 балла, что соответствует примерно 66% полностью релевантных результатов в топ-5 выдачи. Учитывая ограниченный объем тестового датасета и ручной характер тестирования, полученный показатель является приемлемым для этапа MVP и демонстрирует работоспособность выбранного подхода к гибриднему поиску.

Нерелевантные результаты с оценкой «0» возникали в следующих случаях:

- недостаточное количество заведений нужной категории в датасете;
- нечеткие текстовые описания, не содержащие ключевых слов запроса;
- ограничения географической фильтрации при малом радиусе поиска.

Выявленные недостатки указывают на направления дальнейшего улучшения, а именно расширения датасета, уточнение текстовых описаний и калибровка весов в алгоритме ранжирования.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Schwartz, B. The Paradox of Choice: Why More Is Less / B. Schwartz. — New York: Ecco, 2004. — 265 p.
- [2] Iyengar, S. S., Lepper, M. R. When choice is demotivating: Can one desire too much of a good thing? // Journal of Personality and Social Psychology. — 2000. — Vol. 79, No. 6. — P. 995–1006.
- [3] Travel Predictions 2024 [Электронный ресурс] // Booking.com: Newsroom. URL: <https://www.hospitalitynet.org/news/4118949.html> (дата обращения: 21.12.2025).
- [4] The value of getting personalization right—or wrong—is multiplying [Электронный ресурс] // McKinsey & Company: Business Functions. URL: <https://www.mckinsey.com/capabilities/growth-marketing-and-sales/our-insights/the-value-of-getting-personalization-right-or-wrong-is-multiplying> (дата обращения: 21.12.2025).
- [5] Обзор аудитории интернета в России [Электронный ресурс] // Mediascope: Библиотека данных. URL: <https://mediascope.net/data/> (дата обращения: 21.12.2025).
- [6] Яндекс.Карты [Электронный ресурс]. — URL: <https://yandex.ru/maps/> (дата обращения: 21.12.2025).
- [7] TripAdvisor [Электронный ресурс]. — URL: <https://www.tripadvisor.ru/> (дата обращения: 21.12.2025).
- [8] KudaGo [Электронный ресурс]. — URL: <https://kudago.com/> (дата обращения: 21.12.2025).
- [9] Кавёр [Электронный ресурс]. — URL: <https://caver.app/> (дата обращения: 21.12.2025).

- [10] Go Documentation [Электронный ресурс] // Gin-gonic.com. – URL: <https://go.dev/doc/>(дата обращения: 21.12.2025).
- [11] Groq Cloud Documentation [Электронный ресурс] // console.groq.com. – URL: <https://console.groq.com/docs>(дата обращения: 13.04.2026).
- [12] OpenAI GPT-OSS-120B Model Card [Электронный ресурс] // OpenAI. – URL: <https://platform.openai.com/docs/models/gpt-oss-120b> (дата обращения: 13.04.2026).
- [13] Meta Llama 4 Scout Technical Report [Электронный ресурс] // Meta AI. – URL: <https://ai.meta.com/research/llama4/> (дата обращения: 13.04.2026).
- [14] Multilingual-E5-base Model Card [Электронный ресурс] // Hugging Face. – URL: <https://huggingface.co/intfloat/multilingual-e5-base>(дата обращения: 13.04.2026).
- [15] pgvector: Open-source vector similarity search for Postgres [Электронный ресурс] // GitHub. – URL: <https://github.com/pgvector/pgvector> (дата обращения: 21.12.2025).
- [16] Flutter Architectural Overview [Электронный ресурс] // Flutter.dev. – URL: <https://docs.flutter.dev/resources/architectural-overview>(дата обращения: 21.12.2025).
- [17] Martin, R. C. Clean Architecture: A Craftsman's Guide to Software Structure and Design / R. C. Martin. – London: Prentice Hall, 2017. – 432 p.
- [18] Lewis, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks // Advances in Neural Information Processing Systems. – 2020. – Vol. 33. – P. 9459–9474.
- [19] Портал открытых данных Правительства Москвы [Электронный ресурс]. – URL: <https://data.mos.ru/> (дата обращения: 13.04.2026)

[20] Что такое эмбединги и как с ними работать. Вводная для начинающих [Электронный ресурс] // Habr. – URL: <https://habr.com/ru/articles/947216/> (дата обращения: 17.04.2026).

[21] Калинин, И. NLP и NLU: что это и как с ними работают? [Электронный ресурс] // TWIN. – URL: <https://twin24.ai/company/articles/nlp-i-nlu-cto-eto-i-kak-rabotayut/> (дата обращения: 17.04.2026).

[22] RAG: Retrieval-Augmented Generation [Электронный ресурс] // Habr. – URL: <https://habr.com/ru/articles/775842/> (дата обращения: 17.04.2026).