

Отчёт по практике на тему: «Разработка моделей машинного обучения для анализа финансовых рынков»

по дисциплине «Технологическая (проектно-технологическая) практика»

Разработал студент гр. ЭФБО-04-22 Трунин Кирилл Антонович

Проверил: к.т.н., Евдошенко О.И.

Москва, 2026

АННОТАЦИЯ

Выпускная квалификационная работа посвящена разработке информационной системы анализа и прогнозирования финансовых рынков на базе методов машинного обучения с использованием мультимодальных данных. В качестве предметной области рассматриваются фондовый рынок, валютный рынок Forex и криптовалютный рынок, отличающиеся высокой волатильностью, нестационарностью временных рядов и существенным влиянием новостного и социального фона на ценовую динамику. Цель работы заключается в создании прототипа информационной системы, реализующей модель машинного обучения для анализа финансовых рынков и учитывающей как числовые рыночные данные, так и неструктурированную текстовую информацию. Для достижения цели проведён анализ классических статистических моделей, традиционных методов машинного обучения и современных глубоких архитектур, включая рекуррентные нейронные сети и LSTM, обоснован выбор подхода на основе мультимодальной LSTM модели. В работе разработана архитектура программной системы, включающая модули сбора и предобработки рыночных и текстовых данных, модуль формирования мультимодальных признаков, модуль прогнозирования на базе LSTM, прикладной сервис API и пользовательский web интерфейс. Описан и реализован экспериментальный ML контур с использованием Python, PyTorch, библиотеки трансформеров для текстового модуля и MLflow для отслеживания экспериментов. Проведены вычислительные эксперименты на исторических данных по инструментам AAPL, EUR/USD и BTC/USDT с формулировкой регрессионной задачи прогнозирования с гибридным сценарием направления. Качество моделей оценивалось по статистическим метрикам (RMSE, MAE, MAPE), а также по торговым показателям, таким как коэффициент Шарпа, доля прибыльных сделок и фактор прибыльности. Практическая значимость работы заключается в создании действующего прототипа аналитической системы, позволяющего интегрировать мультимодальные данные в процессы поддержки принятия решений на финансовых рынках, переводить новостной фон и данные социальных медиа в количественные признаки и использовать их совместно с ценовыми рядами при формировании торговых сценариев.

Введение

К настоящему времени глобальная финансовая система достигла беспрецедентного масштаба и сложности: совокупная рыночная капитализация фондовых бирж мира по состоянию на конец 2025 года превысила \$147 трлн, продемонстрировав прирост в 19,3% за год. Среднесуточный объём торгов только на валютном рынке в начале 2025 года составил \$9,6 трлн, что почти в треть превышает показатели 2022 года и в годовом исчислении соответствует обороту порядка \$3,5 квадриллиона. Объём криптовалютного рынка к третьему кварталу 2025 года достиг \$4,2 трлн, а рыночная капитализация Bitcoin в отдельные периоды превышала \$2,5 трлн. Эти цифры свидетельствуют о том, что финансовые рынки превратились в многоуровневую экономическую систему с колоссальным потоком транзакций и информации, поведение и взаимодействие которой определяется множеством факторов, начиная от монетарной политики центральных банков, заканчивая настроений розничных участников в социальных сетях. Усложнение рыночной структуры в значительной мере обусловлено появлением новых классов активов: в частности, развитие технологии блокчейн породило самостоятельный, высоколиквидный и принципиально децентрализованный криптовалютный рынок, который с трудом поддаётся описанию в рамках традиционных экономических моделей.

Введение

При этом три ключевых сегмента глобальной финансовой системы, рассматриваемые в данной работе, — фондовый рынок, валютный рынок Forex и криптовалютный рынок — обладают принципиально различными характеристиками, что делает их совместное рассмотрение особенно ценным в методологическом отношении. Традиционные фондовые рынки, такие как NYSE и NASDAQ, отличаются относительно высокой регуляторной прозрачностью, богатой историей ценовых данных и умеренной волатильностью, что обеспечивает хороший баланс между предсказуемостью и сложностью задачи прогнозирования. Рынок Forex, обладая наибольшей в мире суточной ликвидностью, функционирует круглосуточно, реагирует на макроэкономические релизы, решения центральных банков и геополитические события практически мгновенно, порождая выраженную нестационарность временных рядов и частые режимные сдвиги. Криптовалютный рынок занимает особую нишу: он характеризуется сверхвысокой волатильностью, значительной ролью нарративов и настроений в социальных медиа в формировании цены, а также принципиальной децентрализованностью и непрерывностью торгов, что создаёт как серьёзные методологические трудности для классических эконометрических моделей, так и богатые возможности для применения текстового и сентимент-анализа.

Традиционный аналитический инструментарий, основанный на принципах технического анализа и эконометрических моделях с линейными допущениями, исторически служил основой для понимания рыночной динамики. Однако его ограничения стали очевидны с наступлением эпохи больших данных, когда объём, скорость поступления и разнообразие финансовой информации превысили возможности методов, опирающихся на сугубо статистические и математические основы. Нарастающий масштаб финансовых операций неразрывно связан с радикальным усложнением информационного потока, сопровождающего рыночную активность: современный аналитик имеет дело не только с традиционными структурированными данными в виде ценовых рядов, но и с огромными объёмами неструктурированной информации — новостными лентами, публикациями в социальных сетях, отчётами регуляторов, макроэкономической статистикой и геополитическими сигналами. Обработка всего этого разнородного потока в реальном времени и его интеграция в прогностические модели представляет собой одну из ключевых задач современных количественных финансов, которую классические инструменты решают лишь частично ввиду их принципиальной неспособности улавливать нелинейные зависимости и учитывать неструктурированные данные.

Актуальность

Актуальность работы обусловлена необходимостью интеграции более эффективных решений внутри информационных систем, связанных напрямую с финансовым сектором. Реализация подобных решений позволит точнее и глубже работать с ценами акций и других деривативов, ликвидностью и волатильностью. Результаты таких исследований могут иметь практическую ценность для финансовых институтов, инвестиционных фондов и частных трейдеров, которые стремятся к принятию более обоснованных инвестиционных решений.

Цели и задачи

Цели практики: систематизация и закрепление полученных теоретических знаний и практических умений по разработке информационных систем связанных и получения информационной системы, реализующей модель машинного обучения для анализа финансовых рынков.

.

Задачи практики:

1. Анализ предметной области и обзор современных методов машинного обучения для финансового анализа
2. Сбор, предобработка и первичный анализ данных финансовых рынков
3. Разработка архитектуры информационной системы для модели и модуля пользовательского интерфейса
4. Разработка и обучение базовых моделей для прогнозирования
5. Оценка эффективности разработанных моделей
6. Создание модуля пользовательского интерфейса для взаимодействия с моделями
7. Разработка рекомендаций по практическому применению и оценка экономической эффективности

1.1 Финансовый рынок как объект анализа и прогнозирования

Финансовый рынок в работе рассматривается как многокомпонентная система, включающая фондовый сегмент, валютный рынок Forex и рынок криптовалют. Эти подсегменты отличаются по степени регуляторной прозрачности, уровню волатильности и структуре участников, но объединены общими свойствами: высокой динамичностью, чувствительностью к новостям и значительным объёмом транзакций.

Фондовые рынки обладают глубокой историей котировок, развитой инфраструктурой и относительно умеренной волатильностью. Это создаёт условия для применения как классических эконометрических моделей, так и более сложных ML-подходов, при этом существенную роль играют корпоративная отчётность и макроэкономические показатели.

Рынок Forex характеризуется круглосуточной ликвидностью и моментальной реакцией на макроэкономические релизы, решения центральных банков и геополитические события. Для временных рядов валютных курсов типичны выраженная нестационарность, смена режимов и наличие резких ценовых скачков, что усложняет построение устойчивых прогностических моделей.

Криптовалютный рынок выделяется экстремальной волатильностью, доминирующей ролью ожиданий и нарративов в социальных медиа, а также децентрализованной инфраструктурой. Здесь ценовая динамика зачастую слабо объяснима классическими фундаментальными факторами, а значимую долю влияния получают новостной и социальный фон.

В совокупности эти особенности делают финансовый рынок сложным объектом для моделирования: требуется учитывать нелинейные зависимости, режимные сдвиги, асимметричную реакцию на новости и интеграцию неоднородных источников информации (числовых, текстовых, событийных).

1.2 Обзор статистических методов и методов машинного обучения для прогнозирования

В разделе рассматриваются три большие группы подходов: классические статистические модели временных рядов, традиционные алгоритмы машинного обучения и методы глубокого обучения. Такой обзор позволяет показать эволюцию инструментов анализа — от линейных моделей к гибким нелинейным архитектурам, способным работать с высокоразмерными и мультифакторными данными.

1. Классические модели (ARIMA, SARIMA, GARCH и их модификации) хорошо формализованы, интерпретируемы и успешно применяются для стационарных или слабо нестационарных процессов. Они позволяют моделировать автокорреляции и условную волатильность, но испытывают ограничения при работе с выраженной нелинейностью, сложными структурными сдвигами и большим количеством входных признаков.
2. Традиционные методы машинного обучения (линейная и логистическая регрессия, деревья решений, ансамбли вроде Random Forest, XGBoost, LightGBM) снимают часть линейных ограничений и лучше масштабируются на богатые по признакам датасеты. Однако в базовом виде они не учитывают последовательную природу финансовых временных рядов и требуют специальных приёмов для работы с автокоррелированными данными и временными зависимостями.
3. Методы глубокого обучения, в том числе полносвязные сети (MLP), рекуррентные архитектуры (RNN, LSTM, GRU) и свёрточные сети, позволяют непосредственно моделировать сложные, нелинейные и долгосрочные зависимости в последовательностях. Для финансовых рядов они особенно интересны тем, что не требуют жёстко задавать форму зависимости, а могут автоматически извлекать релевантные паттерны из данных.

Отдельное внимание уделяется архитектуре LSTM как варианту рекуррентной сети, способной бороться с затуханием и взрывом градиента и удерживать долгосрочный контекст. Это делает её естественным кандидатом для задач, где важна история движения цены и реакция рынка на накопленный информационный фон, а не только локальная динамика.

1.3 Обзор существующих решений

В практике финансовых организаций широко используются институциональные аналитические платформы, такие как Bloomberg Terminal и FactSet, которые агрегируют котировки, отчётность, макроданные и новости в единой среде анализа для банков, хедж-фондов и крупных инвесткомпаний. Их ML-компоненты, как правило, реализованы как закрытые сервисы, недоступные для модификации и исследования архитектуры моделей.

Существуют специализированные платформы для алготрейдинга и количественных исследований, например QuantConnect, предлагающие доступ к историческим данным по акциям, валютам, деривативам и инфраструктуру для бэктеста пользовательских стратегий, включая собственные ML-модели.

Широко распространены розничные и полу-профессиональные решения уровня TradingView, фокусирующиеся на техническом анализе, визуализации и скриптах на языке Pine Script; в них отсутствует единый экспериментальный ML-контур и полноценная поддержка мультимодальных моделей.

На фоне этих решений разрабатываемая в работе система позиционируется как исследовательский прототип, совмещающий: работу с OHLCV и техническими индикаторами, интеграцию новостного сентимента и явный ML-контур на базе LSTM с открытой архитектурой, метриками и артефактами.

1.4 Место разрабатываемой системы в бизнес-процессах предприятия


В типичном контуре финансовой организации процессы принятия решений включают мониторинг рынка и новостного фона, отбор активов, формирование прогнозов и сценариев, принятие решений и последующий анализ результатов. Эти шаги часто выполняются вручную, с опорой на разрозненные источники и офисные инструменты, что повышает нагрузку на аналитиков и снижает воспроизводимость решений.

Разрабатываемая система встраивается в бизнес-процесс как аналитический модуль поддержки принятия решений: она автоматизирует сбор рыночных и текстовых данных, расчёт признаков, запуск моделей прогнозирования направления и волатильности, а также формирование агрегированных показателей сентимента и качества на исторических данных.


Функционально система располагается между хранилищем первичных данных и фронт-офисными системами исполнения сделок: аналитик используя интерфейс, выбирает актив и таймфрейм, инициирует расчёт прогнозов и на выходе получает набор метрик, графиков и индикаторов, которые используются как один из входов при формировании торговых идей.

Архитектура разделяет оффлайн-контур (обучение, эксперименты, подбор конфигураций) и онлайн-контур (регулярное обновление прогнозов на актуальных данных, предоставление результатов пользователям), что позволяет развивать ML-часть без нарушения устойчивости прикладных процессов.

Диаграмма BPMN использования ИС в предприятии



USE CASE диаграмма



2.1 Формализация задачи

Во второй главе формализуется постановка задачи: прогнозирование нормализованной доходности инструмента на горизонте D1 и одновременное предсказание её знака (направления движения), что задаёт совмещённую регрессионно-классификационную постановку. Входом выступают последовательности признаков, сформированные на основе ценовых рядов и производных от них индикаторов, а также агрегированных текстовых признаков.

, включающий три группы: OHLCV-ряд (Open, High, Low, Close, Volume), технические индикаторы (RSI, MACD, Bollinger Bands, ATR и др.) и альтернативные текстовые признаки (сентимент, частота упоминаний и т.п.). Целевые переменные описывают как величину будущей доходности, так и её знак для последующей интерпретации в виде торговых сигналов.

Отдельный акцент делается на том, что данные не являются независимыми и одинаково распределёнными по времени, поэтому при формализации задачи учитывается последовательная природа выборки и необходимость специальных схем валидации, приближенных к реальному сценарию использования модели.

2.2 Инструменты разработки и схемы pipeline


В разделе 2.2 задаётся общая архитектура информационной системы и экспериментального контура: от получения сырых данных до инференса обученной LSTM-модели и предоставления результатов пользователю через API и web-интерфейс.

Описывается трёхслойная логика: пользовательский уровень (интерактивный интерфейс аналитика), сервисный уровень и вычислительный уровень (сбор и предобработка данных, формирование признаков, обучение и инференс моделей).


Фиксируется технологический стек: Python как основной язык, PyTorch для реализации LSTM, pandas/NumPy для работы с временными рядами, Transformers/FinBERT для текстов, MLflow для трекинга экспериментов, FastAPI для API, Streamlit для интерфейса и Docker для упаковки и развёртывания.

Предлагается разделение на два контура: экспериментальный (подготовка данных, обучение, подбор конфигураций) и прикладной (регулярный расчёт прогнозов по сохранённым моделям), что уменьшает связность и упрощает развитие системы.

СТЕК-технологий




Компонентная схема бэкенда




Фронтенд схема информационной системы

Структура клиента (Streamlit UI): слои и зависимости



ML-контур



2.3 Сбор и предобработка мультимодальных данных

Раздел 2.3 описывает, как в системе организован полный путь данных: от внешних источников (биржевые API, новостные ленты, соцмедиа) до готового мультимодального датасета, пригодного для обучения LSTM.

Процесс построен в два этапа: сначала выполняется извлечение и сохранение сырых рыночных и текстовых данных с явной схемой и временными зонами, затем — предобработка (очистка, ресемплинг, синхронизация по времени, расчёт технических индикаторов и текстовых признаков).


Рыночные и текстовые данные приводятся к единой временной сетке и объединяются в последовательности фиксированной длины (скользящие окна), на основе которых формируются обучающая, валидационная и тестовая выборки для мультимодальной модели.

Итогом работы контуров сбора и предобработки является единый, воспроизводимый мультимодальный датасет, где для каждого временного шага и инструмента доступны согласованные числовые и текстовые признаки, соответствующие формализации задачи из 2.1.


3.1 Реализация архитектуры информационной системы

В разделе 3.1 показано, как абстрактная архитектура из предыдущих глав воплощена в конкретной структуре кода: выделены отдельные слои для ML-моделей и инференса, сервисов backend-API и пользовательского интерфейса, организованы каталоги `app/`, `data/` и `artifacts/`, а также описан сквозной конвейер данных от файлов OHLCV и сентимента до ответа API и визуализации в Streamlit.


Страница для прогнозирования риска портфеля



Страница для прогнозирования волатильности



Страница для прогнозирования цены



3.2 Постановка и проведение вычислительных экспериментов

Раздел 3.2 посвящён конфигурации экспериментального ML-контура и процедуре проверки работоспособности модели и системы в целом. Описываются сценарии обучения LSTM-модели на мультимодальных данных, формирование обучающих выборок в режиме walk-forward для инструментов AAPL, EUR/USD и BTC/USDT, а также набор сравниваемых моделей, которые оцениваются по единому набору статистических и торговых метрик.

Отдельно рассматривается тестирование: для ML-части это временная валидация и тестирование на отложенных периодах, проверка устойчивости к смене рыночных режимов и влияния текстового компонента; для программной системы — корректность работы API и интерфейса на тестовых запросах, консистентность признаков между обучением и инференсом и стабильность конвейера при работе с различными инструментами и объёмами данных

3.3 Результаты экспериментов и анализ

Раздел 3.3 посвящён представлению и интерпретации результатов вычислительных экспериментов, проведённых на исторических данных по инструментам AAPL, EUR/USD и BTC/USDT для различных конфигураций LSTM-модели. Здесь последовательно рассматриваются статистические метрики и направленная точность, а также производные торговые показатели, рассчитываемые на основе простой стратегии, использующей сигналы модели.

В первой части раздела приводится сравнение базовой LSTM-модели, обученной только на ценовых и технических признаках, с мультимодальной модификацией, учитывающей агрегированный сентимент новостей и социальных медиа. Отмечается, на каких активах и интервалах включение текстового компонента даёт заметное снижение ошибок прогноза и рост DA, а где прирост качества невелик или носит локальный характер.

Далее анализируется устойчивость полученных результатов во времени: для каждого инструмента рассматриваются отдельные отрезки временного ряда, в том числе периоды повышенной волатильности и выраженных трендов, и оценивается поведение метрик на этих участках. Отдельно обсуждаются случаи, когда модель переобучается или теряет качество при смене рыночного режима, и показывается, как ходит себя мультимодальная архитектура по сравнению с ценовой.

Завершающая часть раздела посвящена интерпретации торговых метрик: сопоставляются значения Sharpe, WinRate и Profit Factor для разных конфигураций модели и активов, иллюстрируется, в каких сценариях стратегия на основе прогнозов LSTM даёт статистически осмысленное улучшение по сравнению с бенчмарками, а где результаты находятся на уровне шумового или случайного угадывания. На основе этого делаются выводы о практической применимости разработанного прототипа и ограничениях, которые нужно учитывать при его интеграции в реальные торговые процессы.

Заключение

Выпускная квалификационная работа была посвящена разработке информационной системы анализа и прогнозирования финансовых рынков на основе методов машинного обучения и мультимодальных данных. В качестве предметной области рассматривались три ключевых сегмента глобальной финансовой системы: фондовый рынок, валютный рынок Forex и криптовалютный рынок, отличающиеся по структуре участников, уровню волатильности и степени влияния новостного и социального фона. Проведённый анализ показал, что традиционный арсенал фундаментального, технического и эконометрического анализа, включая модели ARIMA и GARCH, важен как база, но не позволяет в полной мере учитывать нелинейные зависимости, нестационарность и влияние неструктурированной текстовой информации.

На основе обзора классических статистических методов, традиционных алгоритмов машинного обучения и современных глубинных архитектур обоснован выбор рекуррентных нейронных сетей типа LSTM в качестве ядра модели. LSTM-архитектура позволяет работать с последовательностями произвольной длины, удерживать долгосрочные зависимости и естественно расширяется до многомерных входов, включающих как ценовые и технические индикаторы, так и агрегированные текстовые признаки, полученные из новостей и социальных медиа. Это делает её подходящей для реализации мультимодальной модели, совмещающей анализ рыночной динамики и информационного фона.

Заключение

Разработана архитектура программной системы и проведены вычислительные эксперименты на исторических данных по инструментам AAPL, EUR/USD и BTC/USDT, в которых сравнивались базовая LSTM-модель на ценовых и технических признаках и мультимодальная модификация с текстовым компонентом. Результаты показали, что включение агрегированного сентимента приводит к снижению ошибок прогноза и росту направленной точности в ряде сценариев, особенно в периоды повышенной новостной активности и волатильности, хотя эффект зависит от класса актива и характеристик информационного потока. Анализ торговых метрик продемонстрировал, что прогнозы модели могут быть использованы в качестве основы для построения простых стратегий с улучшенными показателями риска-доходности по сравнению с базовыми бенчмарками, но требуют аккуратного выбора параметров и контроля устойчивости во времени.

Практическая значимость работы заключается в разработке действующего прототипа аналитической системы, способной интегрировать мультимодальные данные в процессы поддержки принятия решений на финансовых рынках и переводить субъективный новостной фон и динамику социальных медиа в количественные признаки, пригодные для использования в математических моделях. Ограничения исследования связаны с ограниченным набором инструментов и источников данных, а также с применением одной архитектуры LSTM без широкого сравнения с альтернативами например, трансформерами для временных рядов и гибридными FinBERT-LSTM-моделями. Перспективными направлениями дальнейших исследований являются расширение спектра активов и горизонтов прогнозирования, использование более сложных текстовых моделей и интеграция разработанного прототипа в реальные бизнес-процессы финансовых организаций.

Список использованных источников

- Фама Е. Ф. Эффективные рынки капитала: обзор теории и эмпирических исследований // Журнал финансов. 1970. Т. 25. № 2. С. 383–417.
- Lo A. W. The Adaptive Markets Hypothesis: Market Efficiency from an Evolutionary Perspective // The Journal of Portfolio Management. 2004. Vol. 30. No. 5. P. 15–29.
- Box G. E. P., Jenkins G. M., Reinsel G. C., Ljung G. M. Time Series Analysis: Forecasting and Control. 5th ed. Hoboken: John Wiley & Sons, 2015.
- Bollerslev T. Generalized Autoregressive Conditional Heteroskedasticity // Journal of Econometrics. 1986. Vol. 31. No. 3. P. 307–327.
- Hochreiter S., Schmidhuber J. Long Short-Term Memory // Neural Computation. 1997. Vol. 9. No. 8. P. 1735–1780.
- Goodfellow I., Bengio Y., Courville A. Deep Learning. Cambridge, MA: MIT Press, 2016.
- Chen T., Guestrin C. XGBoost: A Scalable Tree Boosting System // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016. P. 785–794.
- Ke G. et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree // Advances in Neural Information Processing Systems 30. 2017.
- Devlin J., Chang M.-W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding // Proceedings of NAACL-HLT. 2019. P. 4171–4186.
- Araci D. FinBERT: Financial Sentiment Analysis with Pre-trained Language Models // arXiv preprint arXiv:1908.10063. 2019.
- Wang J. et al. LSTM-based Sentiment Analysis for Stock Price Forecast // Journal of Healthcare Engineering. 2021. Article ID 6616331.
- Sentiment-Driven Forecasting LSTM Neural Networks for Financial Markets // International Journal of Advanced Computer Science and Applications. 2018. Vol. 14. No. 11.
- Paszke A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems 32. 2019.
- Ван Россум Г., Дрейк Ф. Справочное руководство по Python 3. Scotts Valley: CreateSpace, 2009.
- Документация FastAPI [Электронный ресурс]. URL: <https://fastapi.tiangolo.com> (дата обращения: 13.03.2026).
- Документация Streamlit [Электронный ресурс]. URL: <https://docs.streamlit.io> (дата обращения: 07.03.2026).