

Содержание

Содержание.....	3
Введение	4
1. Обзор текущего состояния предмета исследования	8
1.1 Обзор зарубежных исследований	8
1.2 Обзор отечественных исследований	10
2. Обзор технологий и методов решения проблемы.....	15
2.1 Основные методы решения проблемы и их характеристики	15
2.2 Основные технологии решения проблемы и их характеристики	18
2.3 Алгоритм выбора методов и технологий решения проблемы	21
3. Формирование требований к решению проблемы.....	24
3.1 Общая характеристика предлагаемого решения	24
3.1.1. Целевые пользователи и их сценарии взаимодействия.	25
3.2 Функциональные требования к предлагаемому решению	26
3.3 Нефункциональные требования к предлагаемому решению	29
Заключение.....	32
Список использованных источников	33

Введение

Финансовые рынки исторически являлись центральным механизмом глобального распределения капитала, ценового обнаружения и управления рисками. Феномен «больших данных» (Big Data [1]) в финансах приобретает особое измерение. Речь идет не только о традиционных структурированных временных рядах цен и объемов, которые сами по себе достигли титанических масштабов благодаря высокочастотной торговле. Современный аналитик должен одновременно учитывать фундаментальные показатели компаний, потоки новостей и аналитических отчетов на естественных языках, данные социальных сетей и веб-трафика, геопространственную информацию, сложные сетевые взаимосвязи между активами и институтами, а также транзакционные данные из блокчейнов. Каждый из этих источников обладает своей собственной структурой, семантикой, частотой обновления и уровнем шума. Традиционные методы финансовой математики и эконометрики, опирающиеся на строгие априорные допущения о стационарности, линейности и нормальности распределений, оказываются недостаточно гибкими и мощными для извлечения значимых сигналов из такого многомерного, неструктурированного и нестационарного информационного хаоса.

На этом фоне парадигма искусственного интеллекта (далее – ИИ) и, в частности, машинного обучения (далее – МО), представляет собой не просто новый инструментарий, а кардинально иную эпистемологическую основу для анализа финансовых рынков. Если классические подходы следуют дедуктивной логике, то машинное обучение основано на индукции: алгоритм сам обнаруживает скрытые закономерности, паттерны и зависимости непосредственно в данных, не будучи ограниченным заранее заданными моделями. Способность методов МО, особенно глубокого обучения, аппроксимировать сколь угодно сложные нелинейные функции открывает

принципиально новые возможности для прогнозирования, классификации рыночных состояний, оптимизации портфелей и управления рисками.

Таким образом, насущной необходимостью становится не столько открытие очередного нового алгоритма, сколько глубокая систематизация и структуризация уже существующего обширного арсенала.

Актуальность темы настоящего исследования детерминирована фундаментальными сдвигами в онтологии и гносеологии глобальных финансовых систем, переживающих фазу сингулярного усложнения. Финансовый рынок XXI века перестал быть арифметической суммой отдельных сегментов (фондового, валютного, товарного); он трансформировался в сложную адаптивную систему (Complex Adaptive System, CAS [2]), где элементы не просто взаимодействуют, а порождают эмерджентные свойства через нелинейные обратные связи и сетевые эффекты.

На этом фоне парадигма МО, и в особенности – глубокого обучения (Deep Learning [3]), предлагает онтологически иной подход. Это переход от дедуктивного моделирования к индуктивному обучению. Машинное обучение не требует априорных предположений о форме зависимостей; вместо этого оно учится аппроксимировать функцию, связывающую входы и выходы, сколь угодно сложной нелинейной структурой. Это делает его идеальным кандидатом для анализа сложных, разнородных и нестационарных систем, каковым является современный финансовый рынок.

Таким образом риск заключается не в отсутствии методов, а в их неправильном, несистемном применении, что может приводить к катастрофическим последствиям из-за переобучения, неучтенных рисков или неинтерпретируемости решений.

Целью настоящей научно-исследовательской работы является преодоление указанного парадокса через проведение фундаментальной систематизации современного арсенала инструментов и методов на основе машинного обучения для комплексного анализа разнородных финансовых рынков. Систематизация понимается не как простое перечисление, а как построение многослойной онтологической карты, устанавливающей семантические связи между задачами, данными, алгоритмами, технологиями и метриками качества. Конечным продуктом работы должна стать практико-ориентированная методологическая рамка, позволяющая осуществлять осознанный, обоснованный и эффективный выбор, комбинацию и внедрение методов МО.

Для достижения поставленной генеральной цели необходимо последовательно решить следующие **задачи**:

Задача декомпозиции и анализа предметного поля: Провести всесторонний критический обзор текущего состояния предметной области, выявив генезис, ключевые векторы развития и точки бифуркации в зарубежных и отечественных исследованиях. Сформулировать исчерпывающую и структурированную характеристику проблемы, разложив ее на методологические, технологические и организационные компоненты.

Задача таксономии и сравнительного анализа инструментария: Осуществить детальную инвентаризацию и таксономизацию алгоритмов машинного обучения и технологического стока. Разработать систему сравнительных критериев (accuracy, latency, interpretability, computational cost, robustness to non-stationarity) и провести на ее основе анализ «нишевой применимости» каждого класса методов. Создать и формализовать алгоритм адаптивного выбора и комбинирования методов в зависимости от специфики контекста.

Задача синтеза требований к интегрированному решению: На основе построенной таксономии и выявленных закономерностей сформулировать комплексные требования к проектируемому решению – прототипу модульной аналитической платформы. Определить ее архитектурные принципы (микросервисность, event-driven), детально специфицировать функциональные модули и установить строгие нефункциональные требования, обеспечивающие промышленную эксплуатацию.

Объект исследования – это целостный процесс преобразования разнородных финансовых данных в инвестиционные решения и оценки рисков, рассматриваемый как кибернетическая система с обратной связью, где методы машинного обучения выступают в роли ключевого преобразователя информации.

Предмет исследования – это дискретная, внутренне связанная совокупность:

- алгоритмических парадигм машинного обучения (обучение с учителем, без учителя, с подкреплением, глубокое обучение);
- конкретных реализаций этих парадигм (Random Forest, LSTM, Transformer, PPO);
- программно-технологических инструментов (языки, библиотеки, фреймворки, платформы), предназначенных для операционализации данных парадигм в контексте финансовых рынков.

Теоретическая значимость работы состоит в объединении принципов современного дизайна и возможностей ИИ для создания интерфейсов, «понимающих» ситуацию пользователя. Исследование вносит вклад в развитие методов проектирования бесшовных переходов от индивидуального использования сервиса к групповому взаимодействию.

Практическая значимость заключается в том, что результаты могут служить:

- Методическим руководством для исследователей и квантов, ускоряющим R&D-цикл.
- Сводом лучших практик для ML-инженеров и архитекторов.
- Framework для оценки зрелости ML-процессов для руководителей и риск-менеджеров.

Структура отчета по практике включает введение, три основные главы, заключение, список использованных источников и приложения:

Структура отчета включает введение, три главы, заключение и список источников.

1. Обзор текущего состояния предмета исследования

1.1 Обзор зарубежных исследований

Сегодня мировые исследования в области дизайна интерфейсов (UI) и пользовательского опыта (UX) направлены на создание максимально персонализированных цифровых экосистем. Ведущие исследовательские центры, такие как Nielsen Norman Group [3] и лаборатории Google, фиксируют фундаментальный сдвиг: современный интерфейс перестал быть просто графической оболочкой базы данных. Он трансформировался в адаптивного цифрового посредника, способного интерпретировать неявные запросы пользователя. В условиях перенасыщения рынка мобильных решений акцент смещается с «функционального избытка» на создание глубокой эмоциональной связи. Интерфейс теперь выступает в роли интеллектуального фильтра, который отсекает информационный шум, оставляя только релевантный контексту контент.

Зарубежная исследовательская мысль в области применения искусственного интеллекта к финансам пережила несколько сменяющих друг друга парадигм и сегодня представляет собой зрелую, но динамичную дисциплину с четко очерченными школами и исследовательскими программами. Истоки лежат в эре экспертных систем (Expert Systems) и

нейросетей первого поколения. Эти попытки, хотя и были пионерскими, потерпели неудачу из-за:

- узости базы знаний экспертных систем, не способных к обобщению;
- проблемы исчезающих градиентов и недостатка вычислительных мощностей для нейросетей.

Переломным моментом стала «тихая революция» статистического обучения (Statistical Learning Theory), связанная с работами В. Вапника. Метод опорных векторов (SVM) и более поздние алгоритмы вроде Random Forest предложили эффективный компромисс между емкостью модели и риском переобучения, базируясь на принципе минимизации структурного риска. Именно в этот период были заложены основы корректной валидации моделей на финансовых данных.

Возрождение глубокого обучения после 2012 года кардинально изменило ландшафт. В финансы пришли архитектуры, зарекомендовавшие себя в компьютерном зрении и NLP, что привело к формированию следующих ключевых направлений:

Проблема долгосрочных зависимостей: Классические RNN и LSTM, будучи прорывом, все еще страдали от забывания контекста на очень длинных последовательностях. Ответом стали Трансформеры, отказавшиеся от рекуррентности в пользу механизма внимания. Специализированные архитектуры, такие как Temporal Fusion Transformer (TFT), стали золотым стандартом. TFT не только прогнозирует, но и:

- обучается на ковариатах известного будущего,
- обеспечивает интерпретируемость через analysis of variable importance и temporal patterns,
- генерирует прогностические интервалы, что критически важно для оценки неопределенности.

Архитектуры, инвариантные ко времени: Временные сверточные сети (TCN) с расширенными каузальными свертками предложили альтернативу, обладающую большей параллелизуемостью, чем RNN, и более явно моделирующую мульти-масштабные зависимости.

Нейросетевые модели волатильности: Прямое моделирование условной волатильности (аналоги GARCH) с помощью нейросетей, например, LSTM-GARCH гибриды, где LSTM предсказывает параметры распределения доходностей, а не саму доходность.

1.2 Обзор отечественных исследований

Отечественные исследования в области применения машинного обучения к финансовым рынкам, выйдя из начальной фазы адаптации и верификации зарубежных методов, перешли к стадии углублённой специализации. Эта эволюция характеризуется концентрацией усилий на специфических проблемах, актуальных для российского контекста. Одним из ключевых направлений стал анализ влияния санкционного режима и геополитики. В его рамках развивается количественная оценка санкционных шоков, направленная на изоляцию эффекта конкретных ограничений на капитализацию и ликвидность компаний и целых секторов, таких как финансовый и энергетический. Параллельно моделируются системные риски, связанные с гипотетическим отключением от глобальных финансовых инфраструктур (SWIFT, Euroclear), с применением методов агентного моделирования и сетевого анализа для стресс-тестирования. Для работы в условиях принципиально возросшей неопределённости исследователи всё активнее обращаются к байесовским методам, включая Bayesian Neural Networks, и моделям, оперирующим прогностическими интервалами.

Другое, исключительно конкурентоспособное на мировом уровне направление, сформировалось благодаря сильной отечественной школе компьютерной лингвистики — это NLP для русскоязычного финансового

контента. Его развитие идёт по нескольким векторам: создание и opensource-распространение специализированных языковых моделей, таких как FinBERT-русский, обученных на обширных корпусах новостей, отчётов и транскриптов; переход от базового анализа тональности к сложному извлечению структурированных событий (event extraction), позволяющему идентифицировать конкретные типы корпоративных событий и их участников; а также мониторинг социальных медиа и мессенджеров для изучения влияния цифровых площадок на формирование «стадного» поведения розничных инвесторов и возникновение аномальной волатильности.

Ввиду своей глобальной природы и отсутствия жёстких национальных барьеров, рынок криптоактивов стал ещё одной активной областью изысканий, где российские учёные часто выступают соавторами в международных работах. Здесь применяются самые современные архитектуры: трансформеры для анализа временных рядов, графовые нейронные сети (GNN) для исследования транзакционных графов блокчейнов, а также методы обучения с подкреплением для задач маркет-мейкинга и арбитража на децентрализованных биржах (DEX). Значительное внимание уделяется задачам безопасности — обнаружению аномалий и мошеннических схем (таких как pump-and-dump) с помощью методов unsupervised learning.

Наконец, в ответ на внешние технологические ограничения активизировались работы по импортозамещению и разработке собственного инструментария. Это включает создание удобных Python-библиотек для работы с данными Московской биржи, разработку специализированных платформ для бэктестинга, учитывающих локальную специфику торговых режимов и риск-менеджмента, а также исследования в области использования отечественных процессоров и AI-ускорителей для задач финансового машинного обучения.

Однако, несмотря на очевидную практическую адаптивность и компетентность в решении локальных задач, отечественная исследовательская экосистема сталкивается с рядом системных ограничений. Её характеризует фрагментарность и слабая кооперация между отдельными университетами и компаниями, что препятствует формированию мощных открытых консорциумов. Серьёзным сдерживающим фактором является дефицит качественных, машиночитаемых открытых датасетов по российским компаниям, особенно в сегменте альтернативных данных. Преобладающий «догоняющий» характер большинства работ, где основным вкладом становится применение известных методов к локальным данным, пока не позволяет выйти на уровень фундаментальных прорывов и предложения новых архитектур. Кроме того, наблюдается слабая связь с реальным сектором: внедрение передовых ML-методов в крупных финансовых институтах идёт медленно из-за консерватизма, регуляторных барьеров и острого кадрового дефицита. Таким образом, для выхода на лидирующие мировые позиции отечественной школе необходима не только адаптация, но и целенаправленные усилия по формированию собственной исследовательской повестки и развитию инфраструктуры открытой науки.

1.3 Общая характеристика проблемы исследования

Ядро исследовательской проблемы, рассматриваемой в данной работе, представляет собой не изолированный вызов, а целостную констелляцию взаимосвязанных противоречий, пронизывающих теорию, технологию и практику применения искусственного интеллекта к финансам. Эта система вызовов может быть осмысленно декомпозирована на четыре иерархических, но неразрывно связанных уровня: эпистемологический, методологический, технологический и организационно-экономический.

На эпистемологическом уровне возникает фундаментальная проблема адекватности моделирования финансового рынка как сложной адаптивной

системы (CAS). Здесь сталкиваются базовые предпосылки машинного обучения с онтологической природой объекта изучения. Во-первых, существует имманентное противоречие между статичностью модели, обучаемой на историческом срезе в предположении стабильности закономерностей, и постоянной эволюционной нестационарностью рынка, где непрерывно меняются правила, участники и классы активов, подвергая сомнению саму возможность долгосрочного обучения. Во-вторых, исследователь сталкивается с принципиальной проблемой неполноты данных и скрытых переменных; ни один, даже самый исчерпывающий, датасет не в состоянии отразить всю совокупность факторов — от коллективной психологии до непубличных договорённостей, — что неизбежно порождает риск нахождения ложных корреляций и принятия следствия за причину. В-третьих, действует парадокс ЛиУвиллера: чем совершеннее и точнее модель становится в ретроспективном описании данных, тем более хрупкой и непредсказуемой оказывается её реакция на принципиально новые, не наблюдавшиеся ранее события — «Чёрных лебедей», что ставит под вопрос оправданность усложнения моделей.

Спускаясь на методологический уровень, мы обнаруживаем комплекс проблем, связанных с выбором, комбинацией и валидацией инструментов в условиях глубокой неопределённости. Здесь царит таксономический вакуум и кризис сравнимости: отсутствует общепринятый «периодический закон», который позволял бы обоснованно выбирать между, например, LSTM и Transformer или решать, когда Gradient Boosting предпочтительнее нейросети. Усложнение картины мира происходит и из-за «проклятия размерности», порождённого альтернативными данными: задача автоматического отбора и генерации признаков из десятков тысяч кандидатов становится отдельной методологической проблемой, от решения которой зависит успех всего анализа. Кроме того, стандартные метрики качества (Ассигасу, MSE и т.п.) демонстрируют слабую корреляцию с конечной финансовой целью — получением риск-скорректированной

прибыли, что требует разработки методологии интеграции специализированных экономических метрик (Sharpe Ratio, Maximum Drawdown) в процесс валидации. Наконец, крайнюю остроту приобретает проблема временной корректности (look-ahead bias) при работе с разнородными потоками данных, где малейшая ошибка в синхронизации меток публикации новостей или отчётности ведёт к некорректному «заглядыванию в будущее» и завышению результатов.

Технологический уровень раскрывает проблему трансляции методологических находок в промышленную реальность, демонстрируя колоссальный разрыв между прототипом и продакшеном. Создание работоспособной модели на исторических данных составляет лишь малую часть работы; основные усилия уходят на построение отказоустойчивого, масштабируемого конвейера, способного в реальном времени собирать данные, вычислять признаки, выполнять инференс, мониторить дрейфы и обеспечивать переобучение. Для высокочастотной торговли критически важным вызовом становится задержка (latency), вынуждающая к экстремальной оптимизации, квантизации моделей и использованию специализированного аппаратного обеспечения (FPGA, ASIC). Дополнительную сложность вносит необходимость интеграции десятков разнородных технологических компонентов — от стриминговых платформ и баз данных до сервисов моделей и оркестраторов пайплайнов, — что представляет собой нетривиальную инженерную задачу.

Наконец, организационно-экономический уровень фокусируется на барьерах внедрения и управления рисками в реальных институтах. Здесь на первый план выходит регуляторный риск и растущее требование интерпретируемости моделей, создающее конфликт между их потенциальной точностью и необходимостью прозрачности для таких органов, как Базельский комитет или ЦБ РФ. Острую проблему представляет кадровый дефицит специалистов, совмещающих глубокое понимание финансовых рынков, экспертизу в машинном обучении и навыки высокоуровневого

software engineering (DevOps/MLOps). Замыкает этот круг экономический вызов: высокая стоимость создания и поддержки полноценной ML-инфраструктуры требует разработки тонкой методологии оценки возврата на инвестиции (ROI), учитывающей не только потенциальную прибыль, но и стоимость данных, вычислений, труда специалистов и регуляторного комплаенса.

Таким образом, проблема предстаёт как многослойная система, где успешное продвижение на одном уровне немыслимо без учёта ограничений и возможностей на других. Преодоление этих взаимосвязанных вызовов и составляет суть данной работы.

Таким образом, ядро проблемы исследования можно сформулировать как отсутствие целостной, многоуровневой методологической рамки, которая позволяла бы системно преодолевать указанные вызовы: от эпистемологического выбора типа модели до организационных аспектов ее внедрения. Существующие работы фокусируются на отдельных аспектах, но не предлагают «карты местности» и «маршрутного листа» для навигации в сложном ландшафте.

2. Обзор технологий и методов решения проблемы

2.1 Основные методы решения проблемы и их характеристики

Предлагаемая в работе систематизация методов машинного обучения построена на фундаментальном принципе «задача-данные-метод». Это означает отказ от традиционной классификации по алгоритмическому семейству в пользу функциональной **таксономии**, где выбор метода детерминируется конкретной целью аналитика и структурой доступной информации, а не его внутренним устройством. Такой подход позволяет напрямую связывать инструмент с контекстом его наиболее эффективного применения.

В рамках этой парадигмы методы прогнозирования, как одна из ключевых функциональных групп, естественным образом разделяются на два принципиальных класса в зависимости от природы данных. Первый класс ориентирован на работу с табличными, кросс-секционными данными, где ключевым сигналом выступает взаиморасположение объектов по множеству признаков в определённый момент времени. «Рабочими лошадками» здесь выступают ансамбли деревьев решений, такие как Gradient Boosting Machines (XGBoost, LightGBM, CatBoost) и Random Forest. Их сила заключается в высокой точности на структурированных данных, устойчивости к аномалиям, скорости работы и хорошей интерпретируемости, обеспеченной встроенной оценкой важности признаков и методами пост-анализа (SHAP, LIME). Однако эти методы накладывают существенное методологическое бремя на этап feature engineering, требуя ручного конструирования лагов и скользящих статистик для учёта временной динамики, и не способны работать с сырыми последовательностями напрямую. Их область идеального применения — прогнозирование доходности акций на следующий день на основе сегодняшних фундаментальных, технических и новостных показателей сотен компаний.

Второй, активно развивающийся класс методов, предназначен для прямого моделирования последовательностей (Sequence Modeling), где прогностическая сила заложена во временной структуре и порядке наблюдений. Исторически эту нишу заняли рекуррентные нейронные сети, в частности их усовершенствованные варианты — LSTM и GRU, способные улавливать долгосрочные зависимости и работать с минимально обработанными данными, такими как поток ценовых баров. Несмотря на эту специализацию, они страдают от вычислительной неэффективности из-за последовательной природы обработки и склонны «забывать» контекст на экстремально длинных рядах.

Альтернативу им составляют временные свёрточные сети (TCN), которые благодаря полной параллелизуемости и использованию

расширенных каузальных свёрток обеспечивают более быстрое обучение и отлично выявляют повторяющиеся локальные паттерны, например, микроструктурные архетипы в стакане заявок или технические фигуры на графике. Однако и TCN, и RNN в определённой степени вытесняются новой парадигмой — трансформерами для временных рядов. Архитектуры, такие как Temporal Fusion Transformer (TFT) или Informer, используют механизм внимания (attention), позволяющий модели напрямую вычислять взаимовлияние любых, даже максимально удалённых друг от друга, точек последовательности. Это обеспечивает наилучшие результаты на задачах со сложной долгосрочной динамикой и множеством внешних ковариат, таких как прогноз индекса с учётом макроэкономического календаря. Несмотря на флагманский статус, трансформеры несут серьёзные компромиссы: квадратичную вычислительную сложность, экстремальные требования к объёму и качеству данных и высокий риск переобучения на небольших финансовых датасетах, что делает их инструментом, требующим значительных промышленных ресурсов и экспертизы. Таким образом, функциональный подход наглядно демонстрирует, что выбор между бустингом, LSTM, TCN и трансформером — это не вопрос моды, а следствие осознанного анализа задачи и характера доступных данных.

Таблица 2.1 — Основные методы решения проблемы и их характеристики

Метод	Сильные стороны	Слабые стороны	Идеальная область применения
Gradient Boosting	Точность на табличных данных, интерпретируемость, скорость	Точность на табличных данных, интерпретируемость, скорость	Прогноз на основе кросс-секционных признаков

Метод	Сильные стороны	Слабые стороны	Идеальная область применения
LSTM/RNN	Учёт временных зависимостей, работа с последовательностями	Долгое обучение, забывание контекста	Прогноз одномерных/многомерных рядов с акцентом на порядок
Трансформеры	Учёт долгосрочных зависимостей, параллелизуемость	Высокие требования к данным и вычислениям, риск переобучения	Сложное прогнозирование с множеством внешних факторов и длинной историей

2.2 Основные технологии решения проблемы и их характеристики

Предлагаемая систематизация технологического стека машинного обучения в финансах структурирована по уровням рабочего процесса, отражая переход от сырых данных к промышленной эксплуатации моделей. Этот подход позволяет не только каталогизировать инструменты, но и понять их роль в едином конвейере создания ценности.

Фундаментом всего процесса выступает уровень данных и feature engineering, где доминирующим языком де-факто является Python с его экосистемой библиотек для обработки (pandas, numpy). На этом этапе критически важна специализация инструментов под финансовую предметную область: доступ к рыночным данным обеспечивают библиотеки вроде yfinance и ccxt (для крипторынка), расчёт классических технических индикаторов — TA-Lib, а для работы с текстовыми потоками формируется отдельный подуровень, опирающийся на NLP-инструменты (spaCy,

transformers). Примечательно, что даже традиционные эконометрические пакеты (statsmodels, arch) находят здесь своё место не только в качестве бенчмарков, но и как генераторы сложных признаков, что подчёркивает гибридный характер современного финансового ML.

Следующий уровень моделирования и экспериментов характеризуется чётким разделением экосистем в зависимости от класса решаемых задач. Для классического машинного обучения и построения воспроизводимых пайплайнов стандартом стал scikit-learn. Задачи, требующие максимальной точности на структурированных данных, решаются с помощью высокооптимизированных фреймворков градиентного бустинга (XGBoost, LightGBM, CatBoost), каждый из которых развился в самостоятельную экосистему. В области глубокого обучения сложилось своеобразное разделение труда: PyTorch завоевал лидерство в академической среде и прототипировании благодаря гибкости и удобству отладки, в то время как TensorFlow с его интегрированной платформой MLOps (TFX) долгое время сохранял сильные позиции в промышленном внедрении. Отдельной, быстро развивающейся нишей стали фреймворки обучения с подкреплением, такие как Stable-Baselines3 для исследований и Ray RLlib для распределённых промышленных задач.

Особую важность в финансовом контексте приобретает уровень валидации и бэктестинга, где корректность методологии напрямую определяет экономический результат. Специализированные библиотеки (Backtrader, vectorbt) решают не просто задачу тестирования стратегий, но и обеспечивают строгую временную чистоту экспериментов, моделируя реалистичные условия торговли — ликвидность, комиссии и проскальзывание. Этой же цели служат специализированные схемы кросс-валидации для временных рядов, предотвращающие data leakage.

Растущие регуляторные требования и внутренняя потребность в доверии к моделям выдвинули на первый план уровень интерпретации (XAI). Здесь сосуществуют два основных подхода: теоретически обоснованный, но ресурсоёмкий SHAP и более легковесный LIME, предлагающий локальные аппроксимации. Параллельно развиваются встроенные механизмы интерпретации, такие как анализ весов внимания в трансформерах, что позволяет заглянуть в «мысленный процесс» сложнейших архитектур.

Переход от исследований к производству опосредуется уровнем MLOps, который превращает разрозненные эксперименты в управляемый инженерный процесс. Этот уровень сам по себе представляет собой многослойную систему: трекинг экспериментов (MLflow, wandb) обеспечивает воспроизводимость, оркестраторы пайплайнов (Airflow, Kubeflow) автоматизируют жизненный цикл, специализированные сервисы (TensorFlow Serving, TorchServe) обеспечивают высокопроизводительный инференс, а системы мониторинга (Evidently AI, Prometheus) следят за дрейфом данных и концептов в реальном времени. Базовой инфраструктурной основой для всего этого служат технологии контейнеризации и оркестрации (Docker, Kubernetes).

Завершает стек инфраструктурный уровень, где стратегический выбор заключается между построением собственного решения и использованием управляемых облачных платформ (AWS SageMaker, Google Cloud AI Platform). Эти платформы предлагают интеграцию всех предыдущих уровней «из коробки», но ценой возможной вендорской привязки. Не менее важной частью инфраструктуры становится специализированное аппаратное обеспечение (GPU, TPU, AI-ускорители), которое часто является критическим фактором для обучения крупных моделей и обеспечения low-latency инференса в высокочастотных сценариях. Таким образом, технологический стек финансового ML предстаёт не как случайный набор инструментов, а как целостная, многоуровневая архитектура, где каждый

компонент решает специфическую задачу в рамках общего процесса превращения данных в решения.

2.3 Алгоритм выбора методов и технологий решения проблемы

Ключевым результатом проведённого анализа является предложение структурированной методологии проектирования, которая формализует переход от бизнес-идеи к промышленной эксплуатации ML-модели. Данная методология реализуется в виде итеративного, циклического процесса, состоящего из шести последовательных этапов, каждый из которых оснащён контрольными точками для обоснованного принятия решений о продолжении работы или необходимости возврата на предыдущие шаги.

Процесс инициируется **этапом предпроектного анализа**, цель которого — трансформация нечёткой бизнес-идеи в конкретные, измеримые и релевантные технические требования. На этом этапе осуществляется критически важная работа по определению целевой переменной, горизонта прогноза, а также системы метрик успеха, включающей как алгоритмические (например, AUC-ROC), так и финансовые показатели (Sharpe Ratio, Maximum Drawdown). Параллельно оцениваются системные ограничения: допустимая задержка инференса, бюджетные рамки и регуляторные требования. Итогом этого этапа становится утверждённый документ — техническое задание на исследование (Research Proposal), которое служит формальным контрактом между бизнесом и исследовательской командой.

Следующим шагом является **этап инвентаризации и аудита данных**, направленный на формирование понимания о доступности, качестве и достаточности информационных ресурсов. Проводится комплексный анализ потенциальных источников: от традиционных ценовых рядов и фундаментальных показателей до альтернативных данных и новостных потоков. Статистическая проверка включает тесты на стационарность,

выявление пропусков и выбросов, анализ распределений, а также предварительную оценку прогностической силы признаков. Результатом становится аналитический отчёт (Data Audit Report), содержащий рекомендации по приоритетным источникам данных, оценку трудоёмкости их очистки и указание на потенциально критические информационные дефициты.

После утверждения данных начинается **этап проектирования исследовательского пайплайна**, на котором создаётся быстрая, гибкая и воспроизводимая среда для экспериментов. Архитектура этого пайплайна, как правило, базируется на стандартном технологическом стеке (Python, pandas, scikit-learn, XGBoost/LightGBM, MLflow), что позволяет оперативно проверять гипотезы. Ключевым элементом проектирования становится разработка переиспользуемых модулей для загрузки, очистки, трансформации данных и расчёта признаков, а также реализация простых, но методологически корректных моделей-бенчмарков. Фиксация работающей кодовой базы в системе контроля версий (Git) завершает данный этап, обеспечивая основу для воспроизводимости всех последующих экспериментов.

Центральное место в методологии занимает **этап итеративного моделирования**. Движение по этой спирали начинается с применения ансамблей деревьев на тщательно сконструированных признаках, что является наиболее надёжным и интерпретируемым подходом для многих финансовых задач. Строгая временная валидация (walk-forward cross-validation) с оценкой по финансовым метрикам служит контрольной точкой: если результаты не превосходят бенчмарк, происходит возврат к улучшению feature engineering или даже к пересмотру постановки задачи.

При наличии оснований полагать, что сигнал скрыт в долгосрочных временных зависимостях, осуществляется переход на второй виток спирали — к последовательным моделям (LSTM, TCN), работающим с минимально обработанными данными. Если же природа данных предполагает наличие

сложных структур (например, текстовые или сетевые взаимосвязи), а предыдущие подходы не приносят успеха, исследование может перейти к третьему витку, включающему современные гибридные архитектуры: трансформеры, графовые нейронные сети или мультимодальные модели. На этом уровне обязательным становится углублённый анализ интерпретируемости (XAI) для оценки оправданности усложнения системы. Отдельный, четвёртый виток спирали посвящён обучению с подкреплением, которое активируется для задач, по своей сути являющихся задачами последовательного принятия решений, таких как управление портфелем.

После завершения исследовательской фазы наступает **этап консервативного отбора и подготовки к продакшену**, руководствующийся принципом выбора не самой сложной, а самой надёжной и робастной модели. В рамках этого этапа проводится стресс-тестирование кандидатов на исторических периодах кризисов и внедряется архитектура «Чемпион-Претендент» (Champion-Challenger), позволяющая в безопасном режиме сравнивать новую модель с текущей лучшей. Дополнительно исследуется возможность дистилляции (упрощения) сложных моделей для повышения скорости и стабильности работы в промышленной среде.

Завершает процесс **этап промышленной реализации и мониторинга**, в ходе которого исследовательский прототип трансформируется в отказоустойчивую производственную систему. Это предполагает реинжиниринг пайплайнов feature engineering для работы в реальном времени, контейнеризацию и развёртывание модели как сервиса, а также настройку комплексного мониторинга, отслеживающего как дрейф данных и концептов, так и инфраструктурные показатели. Автоматизация процессов переобучения замыкает жизненный цикл модели, обеспечивая её постоянную адаптацию к изменяющимся рыночным условиям. Таким образом, предложенная методология представляет собой целостный framework,

системно управляющий рисками и ресурсами на всех стадиях создания финансового AI-продукта.

3. Формирование требований к решению проблемы

3.1 Общая характеристика предлагаемого решения

Платформа проектируется не как монолитное приложение, а как совокупность слабосвязанных, независимо развертываемых микросервисов, взаимодействующих через четко определенные API (REST/gRPC) и асинхронные сообщения (через брокер, например, Apache Kafka). Это обеспечивает:

- **Масштабируемость:** Возможность горизонтального масштабирования отдельных компонентов под нагрузкой (например, сервиса feature engineering в периоды высокой рыночной активности).
- **Устойчивость к отказам:** Отказ одного сервиса не приводит к коллапсу всей системы.
- **Технологическую гибкость:** Возможность использовать оптимальный технологический стек для каждой задачи (например, Go для высоконагруженных ingestion-сервисов, Python для ML-модулей, Java для оркестрации).
- **Независимость жизненных циклов:** Команды могут независимо разрабатывать, тестировать и развертывать свои сервисы.

Центральным элементом архитектуры является единое пространство данных (Data Mesh / Logical Data Warehouse), построенное на принципах:

- **Domain-Oriented Decentralized Data Ownership:** Данные принадлежат доменным командам (например, команда рыночных данных, команда альтернативных данных), которые отвечают за их

качество, документацию и предоставление через сервисы-продукты данных (Data Products).

- **Data as a Product:** Каждый источник данных (ценовые потоки, новостной фид, фундаментальные показатели) предоставляется как сервис с гарантированным SLA, схемой, метаданными и версионностью.
- **Federated Computational Governance:** Глобальные стандарты качества, безопасности и интероперабельности данных, контролируемые централизованно, но исполняемые децентрализованно.

3.1.1. Целевые пользователи и их сценарии взаимодействия.

1. **Квант-исследователь (Quant Researcher):** Основной пользователь. Создает новые модели, проводит эксперименты, анализирует альфа. Работает в среде JupyterHub, интегрированной с Платформой. Использует каталог данных, Feature Store, сервис запуска экспериментов и библиотеку воспроизводимых компонентов.
2. **ML-инженер (ML Engineer):** Отвечает за индустриализацию успешных прототипов от исследователей. Собирает пайплайны, оптимизирует код для продакшена, настраивает сервинг моделей и мониторинг.
3. **Треjder/Портфельный менеджер (Trader/PM):** Потребитель конечных сигналов и аналитики. Работает с веб-интерфейсом (дашбордом), где в реальном времени видит прогнозы моделей, их уверенность, интерпретации (XAI) и состояние портфеля.
4. **Риск-менеджер (Risk Manager):** Контролирует стабильность и адекватность моделей. Через дашборды мониторит метрики дрейфа данных, финансовые показатели моделей, анализирует отчеты XAI на предмет подозрительных паттернов принятия решений.

5. **Инженер данных (Data Engineer):** Отвечает за надежность и качество потоков данных, пополнение Feature Store, поддержку инфраструктуры.

3.2 Функциональные требования к предлагаемому решению

На основе разработанной методологии сформулирован комплекс требований к проектируемой интегрированной аналитической платформе. Эти требования детализируют, как методологические принципы должны быть воплощены в конкретные инженерные решения, обеспечивая системный подход к управлению полным жизненным циклом ML-моделей в финансах.

Модуль управления данными и метаданными является фундаментальным элементом платформы, отвечающим за целостность и доступность информационных активов. Его архитектура должна поддерживать гибридный приём данных, включающий как потоковую обработку (real-time) биржевых фидов через протоколы FIX, WebSocket, так и пакетную загрузку из REST API (Bloomberg, Refinitiv) и распределённых файловых хранилищ (S3, HDFS). Критически важным является наличие централизованного каталога данных (Data Catalog) с возможностью семантического поиска по метаданным, а также обязательная версионность всех наборов данных для обеспечения воспроизводимости экспериментов. Для поддержания качества данных модуль должен осуществлять автоматическую валидацию входящих потоков на соответствие схеме, детектировать аномалии и генерировать алерты при нарушении SLA. Хранение реализуется в двухслойной модели: сырые (raw) и очищенные (cleaned) данные сохраняются в колоночных форматах, оптимизированных для временных рядов (Apache Parquet), а для low-latency запросов используются специализированные СУБД, такие как Apache Druid или TimescaleDB.

Модуль feature engineering и Feature Store проектируется как ядро, преобразующее сырые данные в прогностические сигналы. Его функционал включает библиотеку высокооптимизированных, переиспользуемых трансформаторов для расчёта стандартных финансовых признаков: лагов, скользящих статистик, технических индикаторов на основе TA-Lib, а также метрик микроструктуры из ордербуков. Для работы с неструктурированными данными модуль обеспечивает интеграцию с NLP-сервисами, автоматически извлекающими из текста признаки тональности, новизны и сущности. Центральным компонентом становится Feature Store (например, на базе Feast), реализующий раздельное хранение признаков для обучения (Offline Store в S3) и для инференса в реальном времени (Online Store в Redis). Обязательным требованием является гарантия консистентности признаков между этими средами, управление доступом и полное отслеживание их происхождения (data lineage).

Модуль экспериментирования и обучения моделей создаёт среду для управления исследовательским циклом. Он предусматривает глубокую интеграцию с системами трекинга экспериментов (MLflow) для логирования всех атрибутов работы: параметров, метрик (включая финансовые), артефактов и версий данных. Для ускорения разработки модуль предоставляет шаблонные проекты с предопределённой структурой для стандартных задач — прогнозирования, классификации режимов, оптимизации портфеля. Сервис распределённого обучения должен автоматически масштабировать вычислительные ресурсы (включая GPU/TPU) через Kubernetes Jobs, поддерживая все основные фреймворки: PyTorch, TensorFlow, XGBoost. Обязательным элементом являются встроенные инструменты для строгой временной валидации (Purged Walk-Forward CV) с визуализацией, предупреждающей о рисках data leakage.

Модуль интерпретации моделей (XAI) и анализа ошибок реализует принцип прозрачности и управляемости. Он автоматически генерирует

детальные отчёты, включающие глобальную важность признаков (через Permutation Importance, SHAP), локальные объяснения для отдельных предсказаний и анализ attention-весов в трансформерах. Дополнительно модуль проводит глубокий анализ ошибок, выявляя календарные паттерны убытков, зависимость ошибок от рыночных режимов и различия в распределениях признаков для корректных и ошибочных прогнозов.

Модуль бэктестинга и симуляции выступает как виртуальный полигон для валидации стратегий. Его ядро — высокопроизводительный событийный бэктестер, способный работать на уровне тиков и баров, с точным учётом транзакционных издержек (комиссий, проскальзывания на основе модели ликвидности) и поддержкой различных типов ордеров. Модуль обеспечивает интеграцию с сервисами моделей для тестирования агентов обучения с подкреплением и формирует комплексные аналитические отчёты с расчётом риск-скорректированных метрик (Sharpe, Sortino, Max Drawdown).

Модуль сервинга моделей и управления жизненным циклом отвечает за переход моделей в промышленную эксплуатацию. Он предоставляет унифицированный сервис для развёртывания моделей в контейнерах (Docker) с автоматическим масштабированием в Kubernetes, поддерживая стратегии A/B-тестирования, canary-релизов и теневого режима (shadow mode). Единая точка входа (REST/gRPC) для получения прогнозов обеспечивает обращение к Online Feature Store, а система версионирования позволяет осуществлять быстрый откат (rollback) на стабильные версии.

Модуль мониторинга и алертинга обеспечивает операционный контроль над системой. Он непрерывно отслеживает дрейф данных (data drift) через статистические расстояния (PSI, KL-дивергенция) и дрейф концептов (concept drift) по падению accuracy и финансовых метрик. Параллельно ведётся инфраструктурный мониторинг задержек инференса, загрузки ресурсов и доступности сервисов. Все метрики агрегируются на

централизованной панели управления (дашборде) с системой алертов, интегрированной в корпоративные каналы коммуникации (Slack, PagerDuty).

Нефункциональные требования задают строгие количественные и качественные рамки для всей платформы. Требования к производительности включают целевые показатели latency (<10 мс для HFT, <1 с для среднесрочных стратегий), пропускной способности (1 млн событий/сек) и линейной масштабируемости. Требования к надёжности устанавливают планку доступности в 99.95%, отказоустойчивости на уровне Availability Zone, времени восстановления (RTO < 5 мин) и географического резервирования данных.

Требования к безопасности охватывают единую систему аутентификации и авторизации (OAuth 2.0, RBAC), сквозное шифрование данных, изоляцию пользовательского кода в sandbox-контейнерах и полное нефальсифицируемое логирование для аудита. Требования к сопровождаемости делают акцент на модульности архитектуры, полной документации и всеобъемлющей наблюдаемости (observability) через метрики, логи и трассировку.

Наконец, требования к регуляторному соответствию формализуют процессы управления моделью рисков (Model Risk Management), гарантируют возможность предоставления детальных отчётов по любой модели (включая XAI) и обеспечивают долгосрочное, соответствующее стандартам, сохранение всех артефактов и записей (Record Keeping). В совокупности данные требования формируют целостный технико-архитектурный образ платформы, способной стать основой для промышленного внедрения методологии финансового машинного обучения.

3.3 Нefункциональные требования к предлагаемому решению

Помимо функциональных возможностей, архитектура платформы должна соответствовать строгим критериям качества, определяющим её

надёжность, безопасность и эффективность в промышленной эксплуатации. Эти нефункциональные требования можно сгруппировать в несколько ключевых категорий.

Требования к производительности и масштабируемости устанавливают количественные ориентиры для отзывчивости и роста системы. Критическим параметром является сквозная задержка инференса, которая не должна превышать 10 миллисекунд для модулей высокочастотного трейдинга и 1 секунды — для среднесрочных стратегий. Пропускная способность платформы должна обеспечивать обработку как минимум миллиона рыночных событий в секунду. Архитектурные решения должны предусматривать возможность линейного масштабирования вычислительных ресурсов и хранилищ для десятикратного роста объёма данных без необходимости фундаментальной перестройки системы. Отдельное внимание уделяется производительности Feature Store: время выполнения онлайн-запроса признаков для одного инструмента должно быть менее 1 миллисекунды.

Требования к надёжности, доступности и отказоустойчивости определяют устойчивость платформы к сбоям. Общая доступность критически важных компонентов, таких как сервинг моделей и приём данных, должна составлять не менее 99.95%, что допускает не более 4.5 часов простоя в год. Система должна сохранять работоспособность при отказе одной зоны доступности в облаке или отдельного сервера, минимизируя простои и полностью исключая потерю данных. Время восстановления после инцидента для ключевых сервисов не должно превышать 5 минут, а для потоковых данных допустимая точка восстановления составляет 1 секунду. Все данные подлежат трёхкратному резервному копированию с географическим распределением копий.

Требования к безопасности охватывают защиту информации и контролируемый доступ. Внедряется единая система аутентификации и авторизации на основе ролевой модели, обеспечивающая дифференциацию

прав для исследователей, инженеров и трейдеров. Обязательным является сквозное шифрование данных как при передаче по сети, так и при хранении, с использованием внешнего сервиса управления ключами. Для изоляции потенциально небезопасного кода выполнение пользовательских задач (ноутбуков, заданий на обучение) происходит в изолированных контейнерах без доступа к внутренней инфраструктуре по умолчанию. Система ведёт детальные, нефальсифицируемые логи всех действий, которые хранятся в соответствии с регуляторными сроками, например, не менее 7 лет по стандарту MiFID II.

Требования к сопровождаемости, расширяемости и удобству использования направлены на обеспечение долгосрочной эффективности разработки и эксплуатации. Архитектура строится на принципах модульности и слабой связанности компонентов, что позволяет обновлять или заменять отдельные сервисы без глобальных изменений. Полнота и актуальность технической документации поддерживается за счёт её автогенерации. Для оперативного контроля состояния системы реализуется принцип наблюдаемости, подразумевающий сбор метрик, структурированных логов и трассировки распределённых транзакций. Для пользователей предоставляется единый веб-портал, интегрирующий все функции платформы, а также плагины для популярных сред разработки, позволяющие работать с данными и запускать код удалённо.

Требования к соответствию регуляторным нормам формализуют процессы, обеспечивающие прозрачность и подотчётность. Платформа должна позволять по запросу регулятора формировать детализированный отчёт по любой промышленной модели, включая объяснение её логики, историю изменений и результаты валидации. Встроенные процедуры управления моделью рисков регламентируют процессы валидации, утверждения и периодического пересмотра моделей в соответствии с международными стандартами. Гарантируется долгосрочное архивное

хранение всех артефактов: версий моделей, наборов данных для обучения и валидации, а также истории их работы в продакшене.

Заключение

Проведенное исследование было направлено на преодоление ключевого парадокса современного quantitative finance: обладая беспрецедентным арсеналом методов машинного обучения для анализа рынков, профессиональное сообщество испытывает острую потребность в их осмысленной систематизации и методологии применения. Работа достигла поставленной цели путем всесторонней систематизации современных инструментов и методов на основе машинного обучения для анализа разнородных финансовых рынков.

Основные научные и практические результаты работы заключаются в следующем:

1. Проведен критический анализ эволюции предметной области. В первой главе был выявлен и детализирован переход от изолированных алгоритмических экспериментов к построению комплексных, мультимодальных и системно-ориентированных исследовательских программ. Были четко дифференцированы тренды зарубежных исследований (фокус на архитектуры трансформеров, GNN, RL и XAI) и специфика отечественной школы (адаптация к локальному рынку, NLP для русского языка, анализ санкционных рисков). Сформулирована многоуровневая характеристика проблемы, раскрывающая ее эпистемологические (нестационарность, сложность систем), методологические (таксономический вакуум, проблемы валидации), технологические (разрыв prototype-production, MLOps) и организационные (регуляторные, кадровые) аспекты.

2. Разработана оригинальная функциональная таксономия и процессуальная методология выбора. Во второй главе предложена нестандартная классификация методов не по алгоритмическому семейству, а по их месту в решении конкретных финансовых задач (прогнозирование на табличных данных vs. последовательностях, классификация режимов, оптимизация стратегий через RL). Проведен сравнительный анализ технологического стека — от библиотек feature engineering до фреймворков MLOps. Ключевым результатом является **итеративный алгоритм выбора с двойной валидацией**, представляющий собой спираль нарастающей сложности. Этот алгоритм формализует путь от простых и интерпретируемых моделей к сложным, устанавливая строгие контрольные точки (checkpoints) для валидации экономической целесообразности каждого шага, что минимизирует риски «алхимии» и переобучения.

3. Сформирован комплекс детализированных требований к интегрированной аналитической платформе. В третьей главе осуществлен синтез: на основе проведенной систематизации спроектирован облик целевого решения. Сформулированы принципы его архитектуры (микросервисы, Data Mesh, Feature Store), детально описаны функциональные модули (от Data Catalog и XAI до бэктестера и мониторинга) и установлены строгие нефункциональные требования к производительности, надежности, безопасности и регуляторному соответствию. Эти требования представляют собой готовый каркас для технического проектирования промышленно

Список использованных источников

[1] Шварц Б. Парадокс выбора. Почему «больше» значит «меньше». М.: Добрая книга, 2005. 284 с.

[2] Николенко С., Кадури А., Архангельская Е. Глубокое обучение. Погружение в мир нейронных сетей. СПб.: Питер, 2018. 480 с.

[3] User-Centered Design Process // Nielsen Norman Group. URL: <https://www.nngroup.com/articles/user-centered-design-process/> (дата обращения: 21.12.2025).

[4] ГОСТ Р ИСО 9241-210-2016. Эргономика взаимодействия человек-система. Часть 210. Человеко-ориентированное проектирование интерактивных систем. М.: Стандартинформ, 2016. 32 с.

[5] Agile UX: Definition and Key Principles // Nielsen Norman Group. URL: <https://www.nngroup.com/articles/agile-ux-definition/> (дата обращения: 21.12.2025).

[6] Atomic Design Methodology // Brad Frost. URL: <https://atomicdesign.bradfrost.com/chapter-2/> (дата обращения: 21.12.2025).

[7] 10 Usability Heuristics for User Interface Design // Nielsen Norman Group. URL: <https://www.nngroup.com/articles/ten-usability-heuristics/> (дата обращения: 21.12.2025).

[8] Горбунов А. Дизайн-системы в российских экосистемах: опыт Яндекса и Сбера // Habr. URL: <https://habr.com/ru/articles/526748/> (дата обращения: 21.12.2025).

[9] System Usability Scale (SUS) // Usability.gov. URL: <https://www.usability.gov/how-to-and-tools/methods/system-usability-scale.html> (дата обращения: 21.12.2025).

[10] Талер Р., Санстейн К. Nudge. Архитектура выбора. Как улучшить наши решения о здоровье, благосостоянии и счастье. М.: Манн, Иванов и Фербер, 2017. 240 с.

[11] Figma: The Collaborative Interface Design Tool // Figma. URL: <https://www.figma.com/> (дата обращения: 21.12.2025).

[12] Сервис для UX-исследований «Фабрика Юзабилити» // Fabuza. URL: <https://www.fabuza.ru/> (дата обращения: 21.12.2025).

[13] Flutter: Build apps for any screen // Google Developers. URL: <https://flutter.dev/> (дата обращения: 21.12.2025).

[14] Introduction to LangChain // LangChain Documentation. URL: <https://docs.langchain.com/> (дата обращения: 21.12.2025).

[15] pgvector: Open-source vector similarity search for Postgres // GitHub. URL: <https://github.com/pgvector/pgvector> (дата обращения: 21.12.2025).

[16] Conversation Design: Speaking the same language // Google Design. URL: <https://design.google/library/conversation-design/> (дата обращения: 21.12.2025).

[17] Web Content Accessibility Guidelines (WCAG) 2.1 // W3C Recommendation. URL: <https://www.w3.org/TR/WCAG21/> (дата обращения: 21.12.2025).

[18] Human Interface Guidelines // Apple Developer. URL: <https://developer.apple.com/design/human-interface-guidelines/> (дата обращения: 21.12.2025).

[19] Material Design 3 // Google Design. URL: <https://m3.material.io/> (дата обращения: 21.12.2025).